Inferência Estatística

Alexandre Nicolella

Table of contents

1 Variáveis Aleatórias Bidimensionais **4**
1.1 Introdução . . . 4
1.2 Variáveis Aleatórias Discretas . . . 6
1.2.1 Visualização gráfica . . . 7
1.3 Variáveis Aleatórias Contínuas . . . 9
1.3.1 Visualização gráfica: Var. Contínuas . . . 11
1.4 Função Distribuição Acumulada . . . 13
1.4.1 Caso discreto . . . 13
1.4.2 Visualização gráfica . . . 14
1.4.3 Caso Contínuo . . . 16
1.4.4 Visualização gráfica . . . 16

2 Distribuição de Probabilidade Marginal e Condicional **18**
2.1 Distribuição de Probabilidade Marginal . . . 18
2.1.1 Para o caso discreto . . . 18
2.1.2 Para o caso continuo . . . 19
2.2 Distribuição de Probabilidade Condicional . . . 21
2.2.1 Para o caso contínuo . . . 22
2.3 Variáveis Aleatórias Independentes . . . 23
2.3.1 Para o caso discreto . . . 24
2.3.2 Para caso Contínuo . . . 24

3 Coeficiente de Correlação **26**
3.1 Visualização gráfica . . . 29

4 O Modelo Normal **30**
4.1 A Distribuição Normal . . . 30
4.2 Representação Gráfica: . . . 31
4.3 Momentos: . . . 34

4.4 Normal Padronizada . . . 34
4.4.1 O Modelo . . . 34
4.4.2 Padronização . . . 35
4.4.3 Função Distribuição Acumulada . . . 36

5 O Modelo Exponencial **45**
5.1 O Modelo Exponencial . . . 46
5.2 Momentos da Distribuição . . . 46
5.3 Graficamente: . . . 46
5.4 Função Distribuição Acumulada . . . 47

6 Aproximação da Binomial pela Normal **49**
6.1 Relembrando a Binomial . . . 49
6.1.1 Momentos: . . . 50
6.2 Aproximação Normal à Binomial . . . 50
6.2.1 Graficamente: . . . 51

7 Distribuição Gama **53**
7.1 O Modelo Gama . . . 53
7.2 Graficamente . . . 53
7.3 Momentos . . . 54

8 Distribuição Qui-Quadrado **55**
8.1 O Modelo Qui-Quadrado . . . 55
8.2 Graficamente . . . 55
8.3 Momentos . . . 56
8.4 Resultados importantes . . . 56

9 Distribuição t-student **57**
9.1 O Modelo t-student . . . 57
9.2 Graficamente . . . 57
9.3 Momentos . . . 58

10 Distribuição F **59**
10.1 O Modelo F . . . 59
10.2 Momentos . . . 59
10.3 Graficamente . . . 59

11 Introdução: Inferência **62**
11.1 Objetivo: . . . 62
11.2 Exemplos do príncipio no dia a dia . . . 63
11.3 Algumas definições importantes . . . 64
11.3.1 População e amostra . . . 64
11.3.2 Amostragem Aleatória Simples . . . 65

11.4 Estatística e Parâmetro . . . 68
11.5 Distribuições amostrais . . . 70
11.6 Distribuição Amostral da Média . . . 70
11.7 Distribuição Amostral da Variância . . . 76
11.8 Distribuição amostral da proporção . . . 76

12 Modos de Convergência **77**
12.1 Convergência de uma sequência numérica . . . 77
12.2 Convergência em Distribuição e o Teorema do Limite Central. . . . 78
12.2.1 Teorema do Limite Central (TLC): Aplicação da Convergência em Distribuição. . . . 78
12.3 Convergência em Probabilidade e a Lei dos Grandes Números . . . 80
12.3.1 A Lei dos Grandes Números (LGN): Aplicação da Convergência em Probabilidade . . . 80
12.4 Convergência em Média Quadrática . . . 82
12.5 Relação entre as convergências . . . 83

13 Determinação do tamanho da amostra **83**
13.1 Tamanho da amostra com σ conhecido . . . 83
13.2 Tamanho da amostra com população finita . . . 84
13.3 Tamanho da amostra com σ desconhecido: média amostral . . . 85
13.4 Proporção populacional . . . 86

14 Introdução: Estimação **88**

15 Estimadores e Estimação **90**

16 Propriedades dos Estimadores **92**
16.1 Tendenciosidade ou Viés . . . 92
16.1.1 Estimadores não viesados para Esperança e Variância populacional. . . 93
16.2 Eficiência . . . 96
16.3 Erro quadrático médio . . . 98
16.4 Consistência . . . 100

17 Métodos de Estimação **103**
17.1 Estimadores de Mínimos Quadrados . . . 106
17.2 Estimador de Máxima Verossimilhança . . . 109
17.2.1 Intuição: . . . 109
17.2.2 A Função de Verossimilhança . . . 112
17.2.3 Propriedades dos Estimadores de M.V.: . . . 115
17.2.4 Exemplos . . . 115
17.3 Máxima Verossimilhança e Minimos Quadrados . . . 116

18 Estimação de Intervalo **117**
18.1 Introdução . . . 117
18.2 Intervalo de confiança: Procedimento Geral . . . 118
18.3 Para dados com Distribuição Normal: a média . . . 118
18.3.1 Quando a variância é desconhecida . . . 125

19 Teste de Hipótese **126**
19.1 Introdução . . . 126
19.2 Construíndo a Hipótese Nula . . . 127
19.3 O Teste Estatístico . . . 128
19.4 Probabilidade da cauda e o p-valor . . . 130
19.5 Erro Tipo I (EI) e Erro Tipo II (EII) . . . 131
19.6 Procedimento Geral do Teste de Hipótese . . . 136
19.6.1 Teste para um parâmetro populacional . . . 136
19.6.2 Nível de significância . . . 136
19.6.3 Estabelencendo Valor Crítico e Região Crítica. . . . 137
19.6.4 O Teste de Hipótese . . . 138
19.6.5 Relação entre a Probabilidade de cauda, p-valor, e região crítica . . . 138
19.7 Os Cinco passos para a contrução do teste de hipótese . . . 139

20 Teste de Hipótese na prática **140**
20.1 Introdução . . . 140
20.2 Testes paramétricos para parâmetros locacional . . . 140
20.2.1 Testes sobre Esperança de uma população com variância conhecida . . . 140
20.2.2 Utilizando a Probabilidade de Cauda ou Probilidade de Significância ou p-valor . . . 145
20.2.3 Teste sobre a Esperança de uma população normal com variância desconhecida . . . 147
20.2.4 Comparação de duas populações normais: amostra independente . . . 151
20.3 Testes Paramétricos sobre Probabilidades . . . 159
20.3.1 Teste para proporção . . . 159

1 Variáveis Aleatórias Bidimensionais

1.1 Introdução

Até o momento nos interessou observar apenas uma característica de um experimento. Por exemplo, a altura média dos alunos do curso de estatística. Podemos também estar interessados em mais uma característica adicional, como o peso dos alunos do curso de estatística.

Portanto, queremos observar duas características de forma simultânea dos alunos: altura e peso. Ou seja, duas características simultaneamente do mesmo experimento ϵ.

Considere o experimento de jogar dois dados não viciados de forma simultânea. Define-se duas variáveis aleatórias: X o número que aparece no dado 1 e Y o número que aparece no dado 2. Assim, temos o seguinte espaço amostral com 36 elementos (6x6):

$$\Omega = \{(1,1),(1,2),(1,3),...,(6,6)\}$$

Como o dado é não viciado cada evento (x,y) tem a mesma probabilidade de ocorrência de 1/36. Assim, a função de **probabilidade bivariada** é:

$$p(x_i, y_j) = P(X = x_i, Y = y_j) = 1/36$$

para i=1,. . . ,6 e j=1,. . . 6.

Assim como no caso unidimensional pode-se construir um histograma. Com base no exemplo acima, podemos fazer o seguinte histograma tridimensional para o par de dados X e Y, ou seja, a distribuição conjunta de (X, Y):

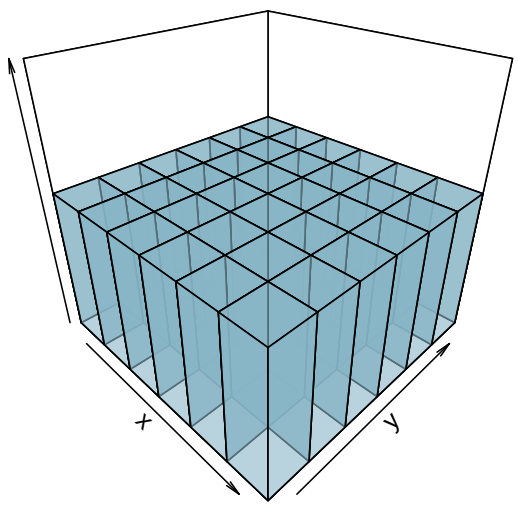

Figure 1: Distribuição conjunta uniforme discreta

Com base nessa ideia podemos fazer a seguinte definição:

Definição

Seja ϵ um experimento, Ω um espaço amostral, $X = X(\omega)$ e $Y = Y(\omega)$, para $\omega \in \Omega$, (X, Y) será uma variável aleatória bidimensional (ou vetor aleatório).

Agora possuímos não mais um espaço unidimensaional R_x como anteriormente visto, mas sim bidimensional, ou seja, o contradomínio da variável aleatória será R_{xy} e cada resultado $X = X(\omega)$ e $Y = Y(\omega)$ pode ser representado como um ponto (x, y) no plano euclidiano. Podemos dividir os resultado de um experimento em dois tipos, os discretos e os contínuos. Vejamos abaixo esses dois tipos de resultados.

1.2 Variáveis Aleatórias Discretas

São variáveis que conseguimos colocar em lista, seja ela finita ou infinita. Assim, o vetor (X,Y) será uma variável aleatória discreta bidimensional ou vetor aleatório bidimensional se os valores possíveis puderem ser representados por (x_i, y_i), $i = 1, ..., n, ...$; e $j = 1, 2, ..., m, ...$

Como no caso unidimensional tem-se, podemos definir a distribuição de probabilidade conjunta de (X, Y)

Definição

A cada valor possível da variável aleatória bidimensional (X, Y), (x_i, y_j), associamos uma probabilidade $p(x_i, y_j)$, $P(X = x_i, Y = y_i)$, e irá satisfazer:

i) $p(x_i, y_j) \geq 0$ para todo (x, y)

ii) $\sum_i \sum_j p(x_i, y_j) = 1$

Com base na definição anterior podemos definir agora o que seria a função distribuição conjunto, ou seja:

Definição

Função de probabilidade conjunta de (X,Y) (ou bivariada):
$p(x_i, y_j) = P(X = x_i, Y = y_j)$ para $-\infty < x_i < \infty$ e $-\infty < y_j < \infty$

Distribuição de probabilidade conjunta de (X,Y) (ou bivariada):
$[x_i, y_j, p(x_i, y_j)]$

Para fixarmos as definições apresentadas acimas, e colocarmos os conceitos em prática, vamos realizar dois exemplos.

Exemplo

Considere o experimento de jogar dois dados simultaneamente. Considere a função de distribuição conjunta e calcule a probabilidade conjunta de $P(5 \leq X \leq 6, 1 \leq Y \leq 2)$

Resposta:
$P(5 \leq X \leq 6, 1 \leq Y \leq 2) = p(5,1) + p(5,2) + p(6,1) + p(6,2) = 4 * 1/6 = 1/9$

Exemplo

Um supermercado possui três caixas operando. Dois consumidores chegam aos caixas, que estão vazios, em momentos distintos do tempo. Cada consumidor escolhe um caixa de forma aleatória e independente do outro. Seja X o número de consumidores que escolhem o caixa 1 e Y os que escolhem o caixa 2. Qual a distribuição conjunta de X e Y?

Resposta:
O espaço amostral do experimento será dado pelo par ordenado $\{i, j\}$, onde o primeiro consumidor escolhe o caixa i e o segundo escolhe j, tal que $i = 1, 2, 3$ e $j = 1, 2, 3$. Assim, cada ponto amostral tem a mesma probabilidade e o espaço amostral pode ser representado como :

$$\Omega = \{(1,1), (1,2), (1,3), ..., (3,3)\}$$

A distribuição conjunta de X e Y será conforme descrito na tabela abaixo. Para construir essa tabela note que, por exemplo, $P(X = 0, Y = 0) = P(\{(3,3)\}) = 1/9$ e que $P(X = 0, Y = 1) = P(\{(2,3), (3,2)\}) = 2/9$

y (cx2)	x=0 (cx1)	x=1 (cx1)	x= 2 (cx1)
y=0	1/9	2/9	1/9
y=1	2/9	2/9	0
y=2	1/9	0	0

1.2.1 Visualização gráfica

Vejamos agora alguns gráficos de variáveis aleaórias bidimensionais:

BINOMIAL:

Considere a variável aleatória (X, Y) com distribuição binomial e a probabilidade de sucesso de X é igual a 0.75 e de Y igual a 0.25 com 10 rodadas:

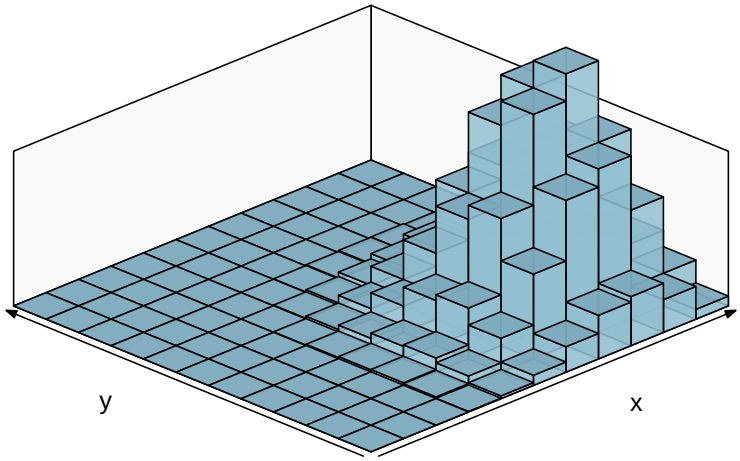

Figure 2: Distribuição conjunta Binomial

POISSON

Considere a variável aleatória (X, Y) com distribuição de poisson e o valor esperado de X igual a 7, de Y igual a 4 e a covariância é 3 (a frente veremos esse conceito):

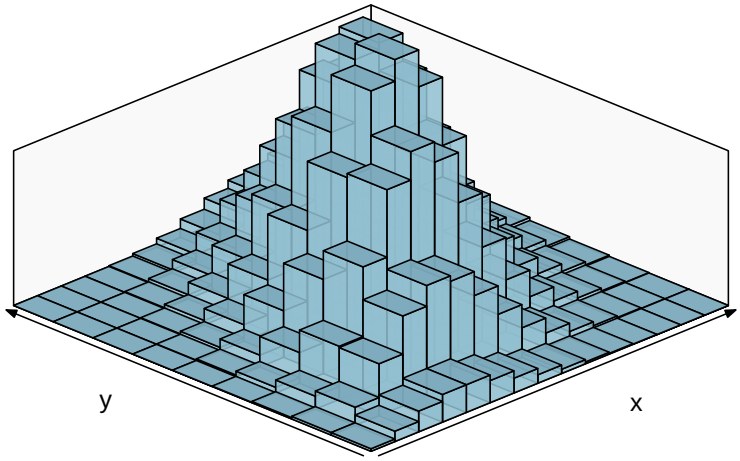

Figure 3: Distribuição conjunta de Poisson

1.3 Variáveis Aleatórias Contínuas

São variáveis que não conseguimos listar, pois existem infinitos valores entre dois pontos. Assim,o vetor (X, Y) será uma variável aleatória contínua se puder tomar todos os valores em algum conjunto não enumerável no plano eucledianо

Definição

Sendo (X, Y) variável aleatória contínua bidimensional. A função densidade de probabilidade conjunta, $f(x, y)$, irá satisfazer:

i) $f(x, y) \geq 0$

ii) $\int\int_R f(x, y)dxdy = 1$ se f(x,y)=0 para $(x, y) \notin R \rightarrow \int_{-\infty}^{\infty}\int_{-\infty}^{\infty} f(x, y) = 1$

Importante notar que $f(x, y)$ não representa a probabilidade. Assim para um evento B em R_{xy}:

$$P(B) = P\{[X(\omega), Y(\omega)] \in B\} = P\{\omega|[X(\omega), Y(\omega)] \in B\}$$

Para o caso discreto:

$$P(B) = \sum\sum_B p(x_i, y_j)$$

Para o caso contínuo:

$$P(B) = \iint_B f(x, y)dxdy$$

Reinterpretando o exposto acima sobre o evento B, como no caso unidimensional, onde a área sobre a função densidade de probabilidade representa a probabilidade, no caso bidimensional o **volume sob a função densidade de probabilidade conjunta representa a probabilidade**.

Assim, uma probabilidade $P(a \leq X \leq b, c \leq Y \leq d)$ é calculada como:

$$P(a \leq X \leq b, c \leq Y \leq d) = \int_c^d\int_a^b f(x, y)dxdy$$

Exemplo

Suponha que uma partícula é aleatoriamente alocada em um quadrado com lados iguais a 1. Assim, se duas áreas de mesma dimensão forem consideradas a partícula tem a mesma probabilidade de estar em qualquer uma das duas áreas. Seja X e Y as coordenadas da localização da partícula. A função de densidade conjunta de X e Y será:

$$f(x,y) = \begin{cases} 1, \ 0 \ \leq x \leq 1, \ 0 \ \leq y \leq 1 \\ \quad 0, \ \textit{caso contrário} \end{cases}$$

Assim:

a. Esboce a função densidade de probabilidade conjunta

b. Encontre $P(0 \leq X \leq 0.2, 0 \leq Y \leq 0.4)$

Resposta:

Ver figura abaixo.

$$P(0 \leq X \leq 0.2, 0 \leq Y \leq 0.4) = \int_0^{0.4} \int_0^{0.2} f(x,y)dxdy$$
$$= \int_0^{0.4} \int_0^{0.2} 1dxdy = \int_0^{0.4} (\int_0^{0.2} 1dx)dy$$
$$= \int_0^{0.4} (x\Big|_0^{0.2})dy = (0.2\text{-}0)\int_0^{0.4} dy = (0.2-0).(y\Big|_0^{0.4})$$
$$= (0.2-0)(0.4-0) = 0.08$$
$$P(0 \leq X \leq 0.2, 0 \leq Y \leq 0.4) = 0.08$$

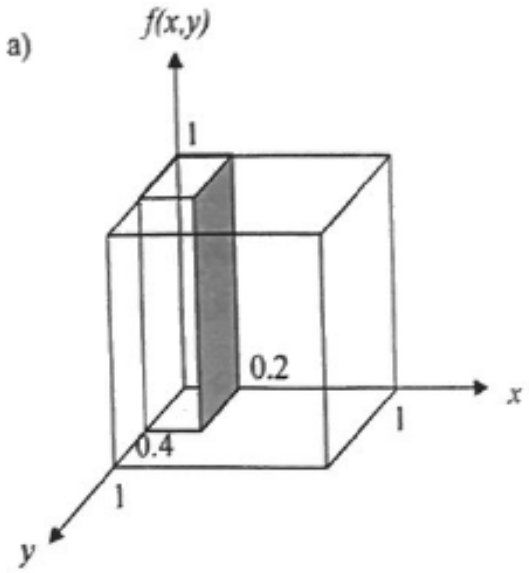

Figure 4: Função densidade de probabilidade conjunta

1.3.1 Visualização gráfica: Var. Contínuas

Vejamos agora alguns gráficos de variáveis aleaórias bidimensionais:

NORMAL BIVARIADA:

Considere a variável aleatória (X, Y) com distribuição normal bivariada com a esperança de X igual a 10, de Y igual a 4, o desvio-padrões iguais a 3 e 2 respectivamente. Aqui consideremaos a correlação de 0.7 (veremos mais a frente esse conceito).

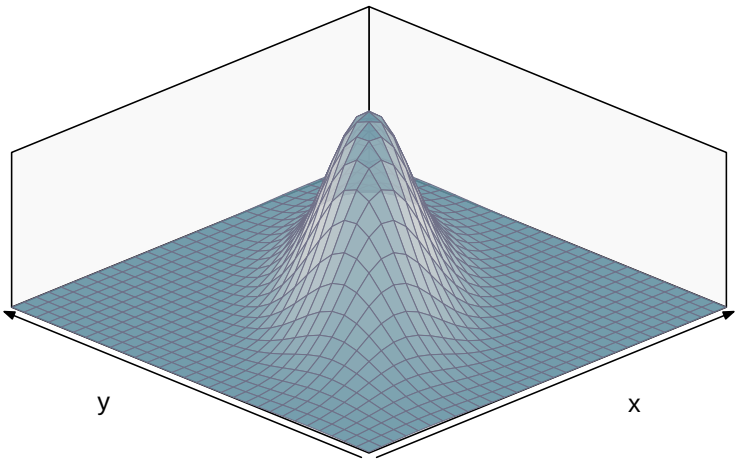

Figure 5: Distribuição conjunta normal bivariada

NORMAL BIVARIADA PADRÃO:

Considere a variável aleatória (X, Y) com distribuição normal bivariada padrão, ou seja, a esperança de X e Y igual a a 1, o desvio-padrões iguais a 1 e sem covariancia.

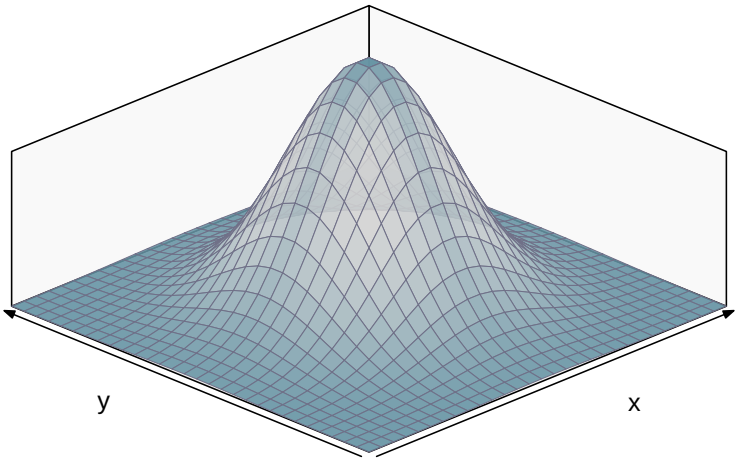

Figure 6: Distribuição conjunta normal padrão bivariada

1.4 Função Distribuição Acumulada

Como no caso univariado a distinção entre variável aleatória conjunta contínua e conjunta discreta pode ser feita em termos de sua função distribuição conjunta acumulada.

1.4.1 Caso discreto

Definição

A função distribuição conjunta acumulada, F, da variável aleatória bidimensional (X,Y) é definida por:

$$F(x,y) = P(X \leq x, Y \leq y) \; para \; -\infty < x_i < \infty \; e \; -\infty < y_i < \infty$$

Seja X e Y duas variáveis aleatórias discretas com função distribuição conjunta $F(x,y)$, a função distribuição conjunta acumulada de X e Y será:

$$F(x,y) = \sum_{f1=-\infty}^{x} \sum_{f2=-\infty}^{y} p(t_1, t_2)$$

Retomando os exemplos anteriores temos as seguintes funcÕes de distribuição conjunta acumuladas discretas:

Exemplo

Para o caso dos dois dados apresentados anteriormente temos que:

$$F(2,3) = P(X \leq 2, Y \leq 3) = p(1,1) + p(1,2) + p(1,3) + p(2,1) + p(2,2) + p(2,3)$$

$$F(2,3) = P(X \leq 2, Y \leq 3) = 6/36 = 1/6$$

O gráfico segue abaixo.

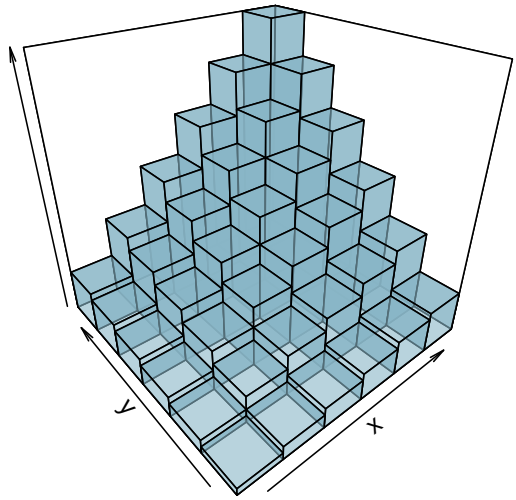

Figure 7: Distribuição acumulada conjunta uniforme discreta

Exemplo

Para o exemplo anterior (caixa do supermercado) encontre F(-1,2) e F(1.5,2)

$$F(-1,2) = P(X \leq -1, Y \leq 2) = P(\emptyset) = 0$$

*Note que é impossível no exemplo do caixa o valor assumir -1, portanto, temos a probabilidade de um conjunto vazio, que será zero.

$$\begin{aligned} F(1.5,2) &= P(X \leq 1.5, Y \leq 2) \\ &= p(0,0) + p(0,1) + p(0,2) + p(1,0) + p(1,1) + p(1,2) = 8/9 \end{aligned}$$

1.4.2 Visualização gráfica

BINOMIAL:

Considere a variável aleatória (X, Y) com distribuição binomial e a probabilidade de sucesso de X é igual a 0.75 e de Y igual a 0.25 com 10 rodadas, sua função distribuição acumulada será:

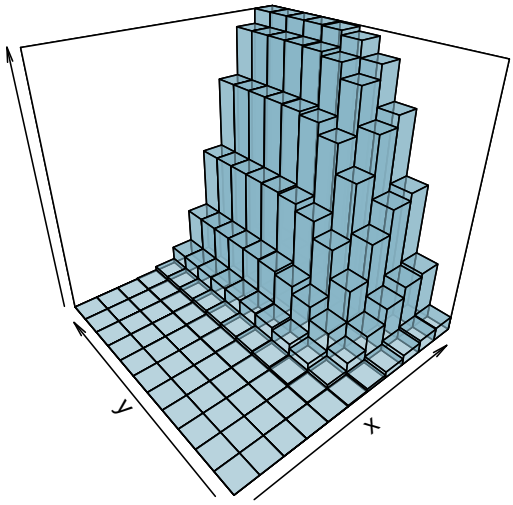

Figure 8: Distribuição conjunta Binomial

POISSON

Considere a variável aleatória (X, Y) com distribuição de poisson e o valor esperado de X igual a 7, de Y igual a 4 e a covariância é 3 (a frente veremos esse conceito). Assim a função distribuição acumulada será:

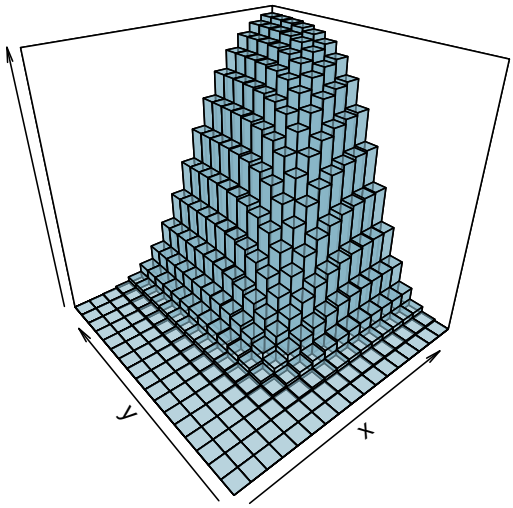

Figure 9: Distribuição conjunta de Poisson

1.4.3 Caso Contínuo

Seja X e Y duas variáveis aleatórias contínuas com função distribuição conjunta $F(x, y)$. Se existir uma função densidade de probabilidade conjunta $f(x, y)$ não negativa, assim a **função distribuição conjunta acumulada de X e Y** será:

$$F(x, y) = \int_{-\infty}^{x} \int_{-\infty}^{y} f(t_1, t_2) dt_1 dt_2 \; para \; -\infty < x_i < \infty \; e \; -\infty < y_i < \infty$$

Exemplo

Para o exemplo anterior da partícula, encontre F(0.4, 0.4):

Resposta:
Ver figura abaixo.

$$\begin{gathered} P(X \leq 0.4, Y \leq 0.4) = \int_0^{0.4} \int_0^{0.4} f(x, y) dx dy \\ = \int_0^{0.4} \int_0^{0.4} 1 dx dy = \int_0^{0.4} (\int_0^{0.4} 1 dx) dy = \int_0^{0.4} (x\Big|_0^{0.4}) dy \\ = (0.4 - 0) \int_0^{0.4} dy = (0.4 - 0).(y\Big|_0^{0.4}) \\ = (0.4 - 0)(0.4 - 0) = 0.016 \\ P(X \leq 0.4, Y \leq 0.4) = 0.016 \end{gathered}$$

Teorema

Seja X e Y duas variáveis aleatórias contínuas com função distribuição conjunta $F(x, y)$ então:

$$a) \; F(-\infty, -\infty) = F(-\infty, y) = F(x, -\infty) = 0$$

$$b) \; F(\infty, \infty) = 1$$

No caso univariado tem-se:

$$f(x, y) = \frac{\partial^2 F(x,y)}{\partial x \partial y}$$

1.4.4 Visualização gráfica

Vejamos agora alguns gráficos de variáveis aleaórias bidimensionais:

NORMAL BIVARIADA:

Considere a variável aleatória (X, Y) com distribuição normal bivariada com a esperança de X igual a 10, de Y igual a 4, o desvio-padrões iguais a 3 e 2 respectivamente. Aqui consideremaos a correlação de 0.7 (veremos mais a frente esse conceito). Assim a função distribuição acumulada conjunta terá o seguinte formato:

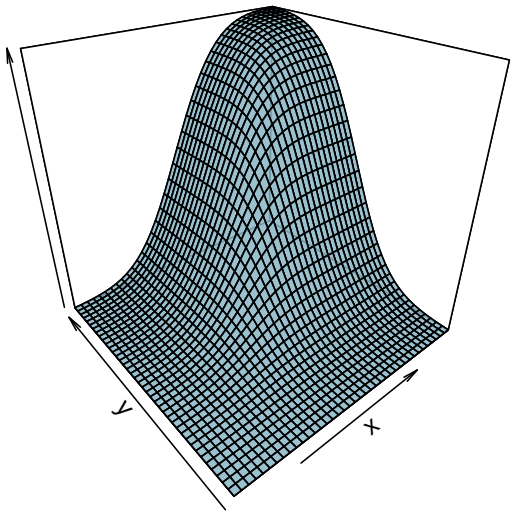

Figure 10: Distribuição acumulada conjunta normal

NORMAL BIVARIADA PADRÃO: Considere a variável aleatória (X, Y) com distribuição normal bivariada padrão, ou seja, a esperança de X e Y igual a a 1, o desvio-padrões iguais a 1 e sem covariância. Assim a função distribuição acumulada conjunta terá o seguinte formato:

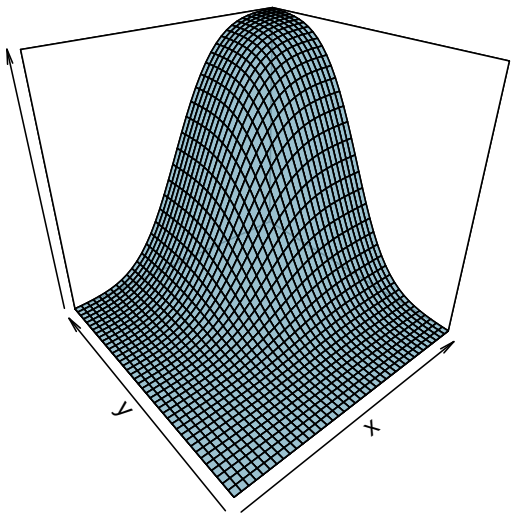

Figure 11: Distribuição acumulada conjunta normal padrão

2 Distribuição de Probabilidade Marginal e Condicional

2.1 Distribuição de Probabilidade Marginal

Dada a variável bidimensional (X, Y) podemos estar interessados em X ou Y individualmente. Agora não mais queremos entender como se distribui conjuntamente renda e consumo. Com base na distribuição conjunta, quero saber somente como a renda distribui, por exemplo.

2.1.1 Para o caso discreto

Para o caso discreto, temos a seguinte **distribuição marginal de X**:

$$p(x_i) = P(X = x_i) = P(X = x_i, Y = y_i \ ou \ X = x_i, Y = y_2....)$$
$$p(x_i) = \sum_j p(x_i, y_j)$$

Onde p é a função distribuição marginal de X. Podemos pensar em Y de forma análoga.

A intuição aqui é que se queremos a marginal de X temos que empilhar na direção de Y, assim o eixo y irá sumir. Vejamos graficamente.

2.1.1.1 Visualização gráfica

Vejamos um exemplo extraído de Inouye,D.I. et al.(2017)[1]:

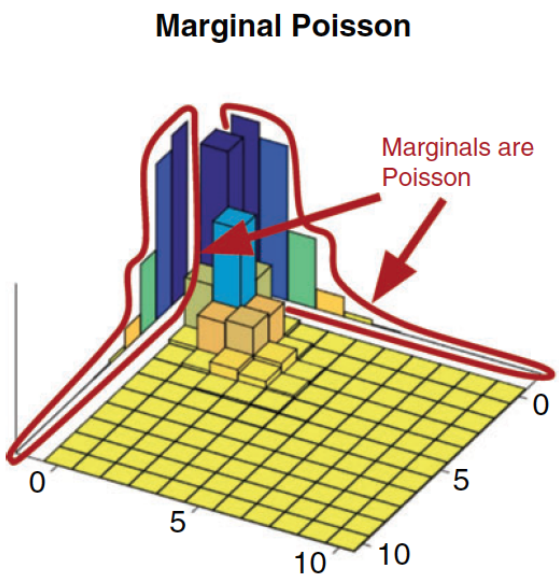

Veja que se quisermos a distribuiçao marginal de X, apresentada a esquerda, temos que somar as barras ou empilha-las na direção de Y.

2.1.2 Para o caso continuo

O caso contínuo é similar ao discreto. No contínuo, a **função densidade marginal de X** será:

$$g(x) = \int_{-\infty}^{\infty} f(x, y)dy$$

E a **função densidade marginal de y** será:

$$h(y) = \int_{-\infty}^{\infty} f(x, y)dx$$

Aqui temos que mostrar uma figura para ilustrar.

[1] A review of multivariate distributions for count data derived from the Poisson distribution

Exemplo

Suponha que (X, Y) seja uma variável aleatória bidimensional. Não estamos interessados em Y, gostariamos de saber somente qual a probabilidade de encontrarmos valores de x entre c e d. Assim:

$$P(c \leq x \leq d) = P[c \leq X \leq d, -\infty < Y < \infty]$$

$$P(c \leq x \leq d) = \int_c^d \int_{-\infty}^{\infty} f(x, y) dy dx$$

$$P(c \leq x \leq d) = \int_c^d g(x) dx$$

2.1.2.1 Visualização gráfica

Vejamos um exemplo extraído de Selvan, R.(2015) [2]:

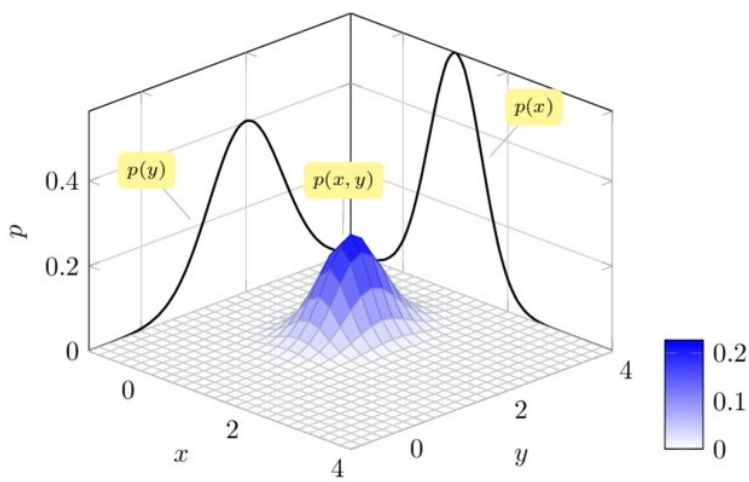

Veja que se quisermos a distribuiçao marginal de X, apresentada ao fundo, temos que somar as barras ou empilha-las na direção de Y.

[2] Selvan, R. 2015. Bayesian tracking of multiple point targets using Expectation Maximization

2.2 Distribuição de Probabilidade Condicional

Na distribuição maringao, tinhamos a distribuição conjunta entre renda e consumo e estavamos interessados somente na renda. Agora estamos querendo saber qual a distribuição da renda para certa faixa de consumo, ou o contrário, qual a distribuição do consumo para dada faixa de renda.

Para o caso discreto:

Para variáveis discretas temos o seguinte:

$$P(x_i|y_j) = P(X = x_i|Y = y_j)$$

$$P(x_i|y_j) = \frac{P(x_i,y_j)}{q(y_j)}$$

Note que $P(x_i|y_j) \geq 0$ e $\sum_i P(x_i|y_j) = 1$

2.2.0.1 Visualização gráfica

Vejamos um exemplo extraído de Inouye,D.I. et al.(2017)[3]:

[3] A review of multivariate distributions for count data derived from the Poisson distribution

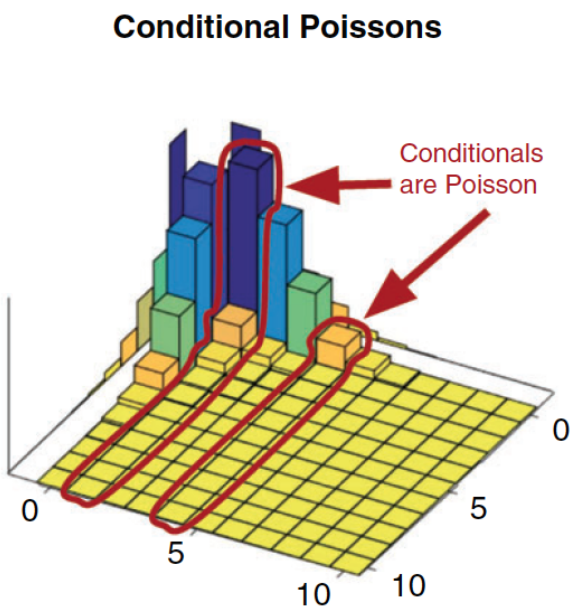

Veja que se quisermos a distribuição condicional de X dado um certo valor de Y, por exemplo, $Y = 2$.Temos que considerar as barras marcadas e repondera-las pela chance de $Y = 2$ acontecer. Ou seja, agora $Y = 2$ será o total.

2.2.1 Para o caso contínuo

Para o caso contínuo a f.d.p. de X condicionada a um dado $Y = y$ é:

$$g(x|y) = \frac{f(x,y)}{h(y)}$$

De forma análoga para Y:

$$h(y|x) = \frac{f(x,y)}{g(x)}$$

Note que $g(x|y) \geq 0$ e

$$\int_{-\infty}^{\infty} g(x|y)dx = \int_{-\infty}^{\infty} \frac{f(x,y)}{h(y)}dx = \frac{h(y)}{h(y)} = 1$$

Inserir um gráfico e falar da intuição.

2.2.1.1 Visualização gráfica

Vejamos um exemplo extraído de Neuper,M. e Ehret,U. (2019)[4]:

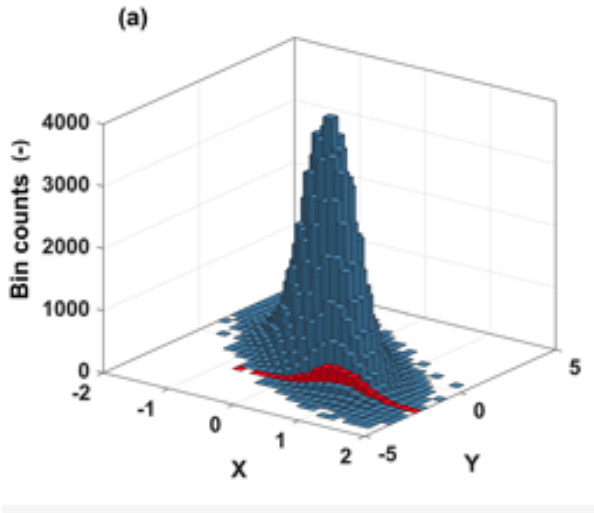

Veja que se quisermos a distribuição condicional de X dado um certo valor de Y, por exemplo, $Y = -2$.Temos que considerar a linha marcada e novamente reponder todos os elementos pela chance de $Y = -2$ acontecer. Ou seja, agora $Y = -2$ será o total.

2.3 Variáveis Aleatórias Independentes

Independencia está ligado ao conceito de informação e quanto essa informação recebida muda sua opinião do que irá acontecer com o caso sobre estudo. Podemos dar uma informação sobre renda e perguntarmos sobre o consumo desse parte da população. Quando os resultados de X influenciam o resultado de Y dizemos que as variáveis são dependentes. Caso a informação sobre X não afeta de meneira nenhuma os resultados de Y, dizemos que são independentes.

[4]Quantitative precipitation estimation with weather radar using a data- and information-based approach

2.3.1 Para o caso discreto

Definição

Para a variábel bidimensional discreta (X, Y), X e Y serão independentes se

$$p(x_i, y_j) = p(x_i)p(y_j)$$

Ou, de outra maneira:

$$P(x_i|y_j) = \frac{P(x_i, y_j)}{q(y_i)} = \frac{P(x_i)q(y_j)}{q(y_i)} = P(x_i)$$

2.3.2 Para caso Contínuo

Definição

Para a variábel bidimensional contínua (X, Y), X e Y serão independentes se:

$$f(x, y) = g(x)h(y)$$

Ou, de outra maneira:

$$g(x|y) = \frac{f(x, y)}{h(y)} = \frac{g(x)h(y)}{h(y)} = g(x)$$

Com base nessas definições podemos agora apresentar o seguinte teorema que conecta o que viram em probabilidade com variáveis aleatórias multidimesionais.

Teorema

Seja (X, Y) uma variável aleatória bidimensional e A e B dois eventos que dependem de X e Y, respectivamente. Então, se X e Y forem independentes:
$P(A \cap B) = P(A)P(B)$

Prova:
$P(A \cap B) = \int\int_{P(A\cap B)} f(x,y)dxdy = \int\int_{P(A\cap B)} g(x)h(y)dxdy$
$P(A \cap B) = \int_A g(x)dx \int_B h(y)dy = P(A)P(B)$

Exemplo

Suponha uma f.d.p. conjunta da variábel aleatória bidimensional (X, Y):

$$f(x,y) = \begin{cases} x^2 + \frac{xy}{3} \ para \ 0 < x < 1, 0 < y < 2 \\ 0, \ caso \ contrário \end{cases}$$

Calcule a $P(Y < X)$:

Resposta:

$$P(Y < X) = \int_0^1 \int_0^x x^2 + \frac{xy}{3} dydx$$

$$P(Y < X) = \int_0^1 [x^2 y + \frac{xy^2}{6}]_0^x dy$$

$$P(Y < X) = \int_0^1 [x^3 + \frac{x^3}{3}] dy$$

$$P(Y < X) = [\frac{x^4}{4} + \frac{x^4}{24}]_0^1$$

$$P(Y < X) = \frac{1}{4} + \frac{1}{24} = \frac{7}{24}$$

3 Coeficiente de Correlação

Até o momento medimos a $E(X)$ e a $Var(X)$, ou seja, uma medida de posição e de variabilidade em relação a R_x, Entretanto, quando temos um vetor bidimensional (X, Y) uma outra medida surge, a qual tenta media o "grau de associação" linear entre X e Y.

Definição

Seja (X, Y) uma variábel aleatória bidimensional. O **Coeficiente de Correlação** $\rho_{X,Y}$ entre X e Y será:

$$\rho_{X,Y} = \frac{E[(X-E(X))(Y-E(Y))]}{\sqrt{Var(X)Var(Y)}}$$

Um termo muito importante surge na expressão acima, a **Covariância**. Ela mede a variabilidade conjunta de uma variável aleátoria multidimensional. Como no caso da variância, ela sobre do efeito das escalas de medidas. Por isso que anteriormente dividimos pelos desvio-padrões. Lembre-se que já usamos esse artifício anteriormente para nos livrar da unidade de medida.

Definição

A **Covariância** entre X e Y, $Cov(X, Y)$, é dada por:

$$Cov(X, Y) = E[(X - E(X))(Y - E(Y))]$$

Novamente, a correlação mede o **GRAU DE ASSOCIAÇÃO LINEAR**. Vejamos algumas Propriedades da Correlação:

Teorema

O coeficiente de correlação $\rho_{X,Y}$ entre X e Y pode ser apresentado como:

$$\rho_{X,Y} = \frac{E(XY)-E(X)E(Y)}{\sqrt{Var(X)Var(Y)}}$$

Prova:

$$E[(X - E(X))(Y - E(Y))] = E[XY - XE(Y) - E(X)Y + E(X)E(Y)]$$
$$= E(XY) - E(X)E(Y) - E(X)E(Y) + E(X)E(Y) = E(XY) - E(X)E(Y)$$

Teorema

Se X e Y forem independentes então:

$$\rho_{X,Y} = 0$$

Prova: Da propriedade da independência, se X e Y forem independentes então:

$$E(X,Y) = E(X)E(Y)$$

Considerando o teorema acima, e sabendo que as variáveis são independentes, então $\rho_{X,Y} = 0$

IMPORTANTE: Note que Independência $\Rightarrow \rho_{X,Y} = 0$ mas não é verdade que $\rho_{X,Y} = 0 \Rightarrow$ *Independência*

Teorema

O Coeficiente de Correlação possui valores entre -1 e 1, ou seja:

$$-1 \leq \rho \leq 1$$

Prova:
Considere a seguinte desigualdade verdadeira:

$$(\frac{x-\mu_x}{\sigma_x} \mp \frac{Y-\mu_y}{\sigma_y})^2 \geq 0$$

A expressão continua verdadeira se aplicarmos o operador esperança:

$$E(\frac{x-\mu_x}{\sigma_x} \mp \frac{Y-\mu_y}{\sigma_y})^2 \geq 0$$

Desenvolvendo temos que:

$$E[(\frac{x-\mu_x}{\sigma_x})^2 + (\frac{Y-\mu_y}{\sigma_y})^2 \mp 2(\frac{x-\mu_x}{\sigma_x})(\frac{Y-\mu_y}{\sigma_y})] \geq 0$$

$$\frac{1}{\sigma_x^2}E(X-\mu_x)^2 + \frac{1}{\sigma_y^2}E(Y-\mu_y)^2 \mp 2\frac{1}{\sigma_x\sigma_y}E((X-\mu_x)(Y-\mu_y)) \geq 0$$

$$\frac{\sigma_x^2}{\sigma_x^2} + \frac{\sigma_y^2}{\sigma_y^2} \mp 2\rho \geq 0$$

$$\mp 2\rho \geq -2$$

$$\therefore \rho \geq -1 \ e \ \rho \leq 1$$

Teorema

Se X e Y forem duas variáveis aleatórias, onde $Y = AX + B$, onde A e B são constantes. Então $\rho^2 = 1$. Se $A > 0$, $\rho = 1$. Se $A < 0$, $\rho = -1$

Prova:

$$Y = AX + B$$
$$E(Y) = AE(X) + B \ e \ VAR(Y) = A^2VAR(X)$$
$$E(XY) = E(AX^2 + BX) \ \rightarrow AE(X^2) + BE(X)$$

Então:

$$\rho^2 = \frac{A^2Var(X)}{A^2Var(X)} = 1$$

Assim, com base no exposto, temos que o coeficiente de correlação é uma medida do grau de linearidade entre X e Y. Dessa forma, ρ próximo a 1 e -1 indicam alto grau de linearidade e ρ próximo a zero indica ausência de relação linear - mas não diz nada sobre relações não-lineares.

3.1 Visualização gráfica

Aqui apresnsemtamos um correlograma com base em variáveis simuladas:

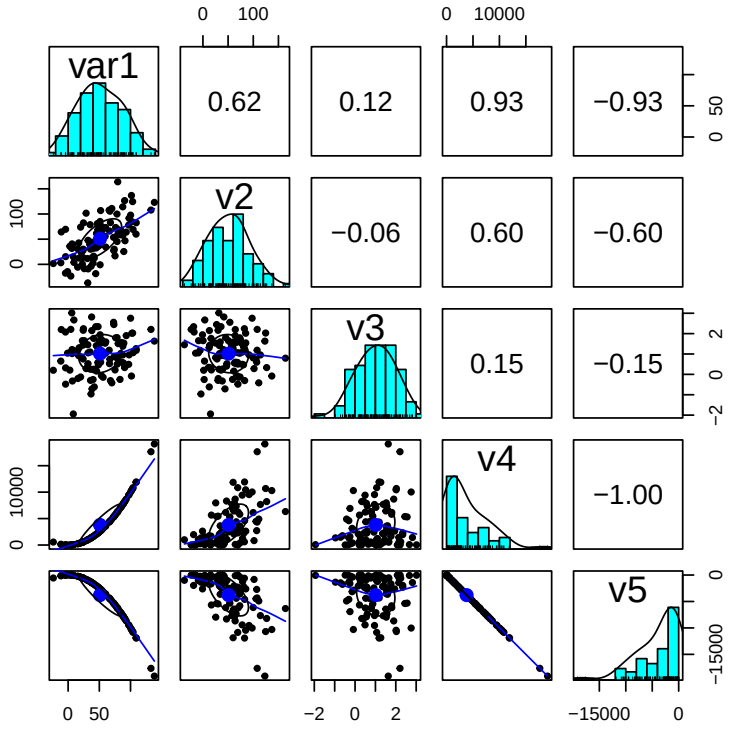

Figure 12: Gráfico de correlação para variáveis simuladas v1 a v5

Vamos começar pelas variáveis v5 e v4, elas tem um comportantamento conjunto totalmente linear, ou seja, saber de v4 te informa corretmente o que acontecerá com v5. Aqui quando v5 sobe, v4 desce. Vejamos agora as variáveis v3 e v2, observe como os dados estão disperso, sem nenhum padrão de comportamento linear. Nesse caso a correlação é próxima a zero (-0.0135). Perceba que a relação não-linear entre v1 e v4 e v1 e v5, faz com que a correlação seja menor que 1 e não perfeita. Já as variáveis v1 e v2 mostram comportamento conjunto positivo, mas não perfeito, reativamente disperso. Quando v1 sobe, v2 também sobe, entretanto não cosneguimos prever esse comportamento perfeitamente.

4 O Modelo Normal

4.1 A Distribuição Normal

Um dos principais modelos de probabilidade. É essencial para inferência estatística (distribuição Gaussiana).

Definição

A variável aleatória X tem distribuição normal com Média μ e Variância σ^2, onde $-\infty < \mu < +\infty$ e $0 < \sigma^2 < \infty$. Sua densidade é dada por:

$$f(x;\mu,\sigma^2) = \frac{1}{\sigma\sqrt{2\pi}} e^{\frac{-(x-\mu)^2}{2\sigma^2}}$$

Onde $-\infty < x < +\infty$

4.2 Representação Gráfica:

Uma Distribuição Normal com parâmetros μ e σ^2 pode ser representada graficamente como:

```
rm(list = ls(all.names = TRUE)) #will clear all objects includes hidden objects.
x<-seq(-3,3,0.1)
fdnorm<-dnorm(x = x, mean = 0, sd=1)
fdanorm<-pnorm(q = x, mean = 0, sd=1)
curve(dnorm(x,0,1),xlim=c(-3,3),main='',xaxt="n",xlab="z", ylab="f(x)",
      col="darkblue",cex.axis=0.65, cex.lab=0.8)
axis(1,at=c(-1, 0, 1),labels =
       c("-DP(X)","E(x)","DP(x)"),cex.axis=0.65, cex.lab=0.8)
lines(x=c(0,0),y=c(0,fdnorm[x==0]),lty=2, col="black")
lines(x=c(1,1),y=c(0,fdnorm[x==1]),lty=2, col="black")
lines(x=c(-1,-1),y=c(0,fdnorm[x==-1]),lty=2, col="black")
```

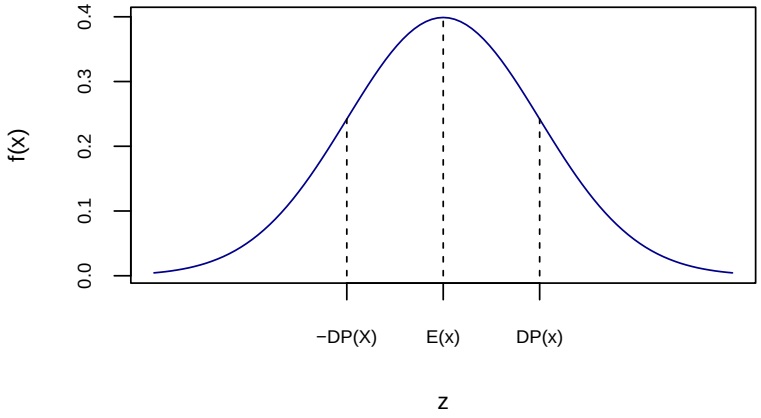

Figure 13: Distribuição Normal

Para entender melhor a distribuição Normal e a relação entre a média e o desvio padrão σ (- lembrando que $\sigma = \sqrt{variância}$) é interessante notar a proporção nos intervalos de desvio-padrão.

Ou seja, a fração da área abaixo da curva $f(x)$ quando temos as seguintes amplitudes,tabela 1, da variável x na distribuição:

Tabela 1: Intervalos de desvios e probabilidade

Amplitude	Proporção
$\mu \pm \sigma$	$68,3\%$
$\mu \pm 2\sigma$	$95,5\%$
$\mu \pm 3\sigma$	$99,7\%$

A figura 2 abaixo representa graficamente o que está colocado na tabela[5]. Observa-se que a probabilidade de estra entre +1 e -1 desvio padrão é de 68,3%. Isso é válido para qualquer distribuição normal INDEPENDENTE da média e desvio padrão.

[5]http://www.portalaction.com.br/probabilidades/62-distribuicao-normal

Vejamos um exemplo de 3 distribuições normais, $X\ N(10,9)$, $Y\ N(200,100)$ e $Z\ N(0,1)$. Dessa forma a chance de estar entre a esperança μ e um desvio padrão, σ, ou seja, entre 10 e 13 para X, entre 200 e 210 para Y e entre 0 e 1 para Z, é de 34,15%. Isso vale para qualquer intervalo de desvio (-1,+1); (-1.3,+1.3); (-3,+3) !!!!

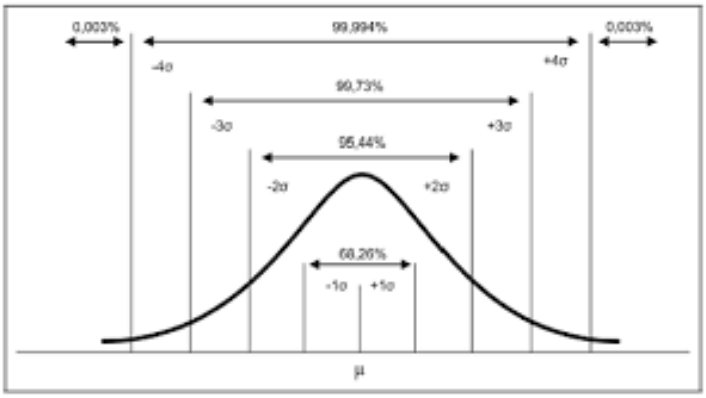

Figure 14: Relação entre o desvio padrão e amplitude da Normal

4.3 Momentos:

Os primeiros dois momentos da distribuição normal são:

Definição

Esperança:

$$E(X) = \mu$$

Variância:

$$Var(X) = \sigma^2$$

Dessa forma para a distribuição normal as seguintes características são verdadeiras:

- Se X é normalmente distribuída então $X \sim N(\mu, \sigma^2)$
- Como pode ser visto na figura 1, a densidade da distribuição é simétrica. Ou seja, para todo x real é verdade que:

$$f(\mu + x; \mu, \sigma^2) = f(\mu - x; \mu, \sigma^2)$$

4.4 Normal Padronizada

4.4.1 O Modelo

Um caso especial da distribuição normal é aquela que possui média 0 e desvio padrão igual a 1. Recebe até um nome diferenciado, distribuição normal padrão.

Definição

Uma variável Z normal padrão (ou reduzida) é uma distribuição Normal com parâmetros $\mu = 0$ e $\sigma = 1$, tal que $Z \sim N(0, 1)$.
Assim, essa variável aleatória Z, possui a seguinte f.d.p.:
$\phi(Z) = \frac{1}{\sqrt{2\pi}} e^{\frac{-z^2}{2}}$
$-\infty < Z < \infty$

4.4.2 Padronização

Teorema

Seja X uma variável distribuída normalmente, tal que $X \sim N(\mu, \sigma^2)$ então temos uma variável Z padronizada a partir de X tal que:

$$Z = \frac{X-\mu}{\sigma}$$

A variável Z terá os seguintes momentos: $E(Z) = 0$ e $Var(Z) = 1$

Prova:

I. Média:

$$\begin{aligned} E(Z) &= E(\tfrac{X-\mu}{\sigma}) \\ &= \tfrac{1}{\sigma}E(X-\mu) \\ &= \tfrac{1}{\sigma}[E(X) - E(\mu)] \\ &= \tfrac{1}{\sigma}[E(\mu) - E(\mu)] = 0 \end{aligned}$$

II. Variância:

$$Var(Z) = E(Z^2) - E(Z)^2$$

Note que:

$$\begin{aligned} E(Z^2) &= \tfrac{1}{\sigma^2}[E(x-\mu)]^2 \\ &= \tfrac{\sigma^2}{\sigma^2} \\ &= 1 \end{aligned}$$

E encontramos acima que $E(Z) = 0$. Portanto:

$$\begin{aligned} Var(Z) &= E(Z^2) - E(Z)^2 \\ &= 1 - 0 \\ &= 1 \end{aligned}$$

4.4.3 Função Distribuição Acumulada

Definição

A f.d.a. $F(y)$ de uma v.a. normalmente distribuída X com média μ e variância σ^2 é:

$$F(y) = \int_{-\infty}^{y} f(x; \mu, \sigma^2)dx \qquad y \in \mathbb{R}$$

Onde $f()$ é a função de densidade de probabilidade.
Para a normal padrão temos a seguinte f.d.a:

$$\Phi(y) = \int_{-\infty}^{y} \phi(Z) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{y} e^{\frac{-z^2}{2}} dz$$

Onde $\phi(Z)$ é a função de densidade de probabilidade.

As integrais acima correspondem à Área sob $f(x)$ ou $\phi(Z)$ no intervalo de $-\infty$ e y. A figura abaixo representa a área entre $-\infty$ e 1 (figura à esquerda) de uma normal padrão com função de densidade $\phi()$. Já a figura à direita representa a distribuição acumulada $\Phi()$.

```
x<-seq(-3,3,0.1)
fdnorm<-dnorm(x = x, mean = 0, sd=1)
fdanorm<-pnorm(q = x, mean = 0, sd=1)
par(mfrow=c(1,2))
regiao=seq(-3,1.5,0.01)
cord.x <- c(min(regiao),regiao,max(regiao))
cord.y <- c(0,dnorm(regiao),0)
curve(dnorm(x,0,1),xlim=c(-3,3),main='f.d.p',xlab="z",type="l",
      col="darkblue",lwd=2, ylab="f(z)",xaxt="n",cex.axis=0.65, cex.lab=0.8 )
axis(1,at=c(-3,-2,-1, 0, 1, 1.5,2, 3),labels =
       c(-3,-2,-1,0,1,"y",2, 3),cex.axis=0.65, cex.lab=0.8)
polygon(cord.x,cord.y,col='lightgray')

regiao=seq(-3,1.5,0.01)
cord.x <- c(min(regiao),regiao,max(regiao))
cord.y <- c(0,pnorm(regiao),0)
curve(pnorm(x,0,1),xlim=c(-3,3),main='f.d.a.',xlab="z",type="l",
      col="darkblue",lwd=2, ylab="F(z)",xaxt="n",cex.axis=0.65, cex.lab=0.8 )
axis(1,at=c(-3,-2,-1, 0, 1, 1.5,2, 3),labels =
       c(-3,-2,-1,0,1,"y",2, 3),cex.axis=0.65, cex.lab=0.8)
polygon(cord.x,cord.y,col='lightgray')
```

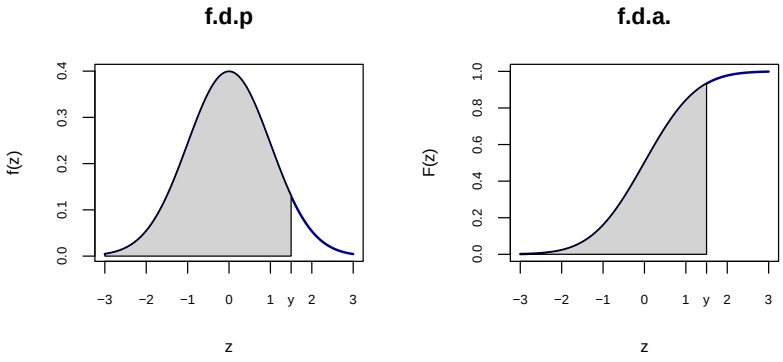

Figure 15: Função Distribuição de Probabilidade Normal e Função Distribuição Acumulada Normal

Suponha que $X \sim N(\mu, \sigma^2)$ e queremos calcular:

$$P(a < X < b) = \int_a^b f(x)dx$$

Tal que $f(x)$ é a f.d.p. da distribuição Normal. A Figura 5 contém a representação do que queremos calcular.

```
x<-seq(0,20,0.1)
fdnorm<-dnorm(x = x, mean = 10, sd=3)
regiao=seq(12,15,0.1)
cord.x <- c(min(regiao),regiao,max(regiao))
cord.y <- c(0,dnorm(regiao, mean=10, sd=3),0)
curve(dnorm(x,10,3),xlim=c(0,20),xlab="x",type="l",
      col="darkblue",lwd=2, ylab="f(x)",xaxt="n",main="P(a<X<b)",
      cex.axis=0.65, cex.lab=0.8, cex.main=0.7 )
axis(1,at=c(0,7, 10, 12,13, 15,20),labels =
       c(0, 7, 10, "a",13,"b",20),cex.axis=0.65, cex.lab=0.8)
polygon(cord.x, cord.y, col='lightgray')
```

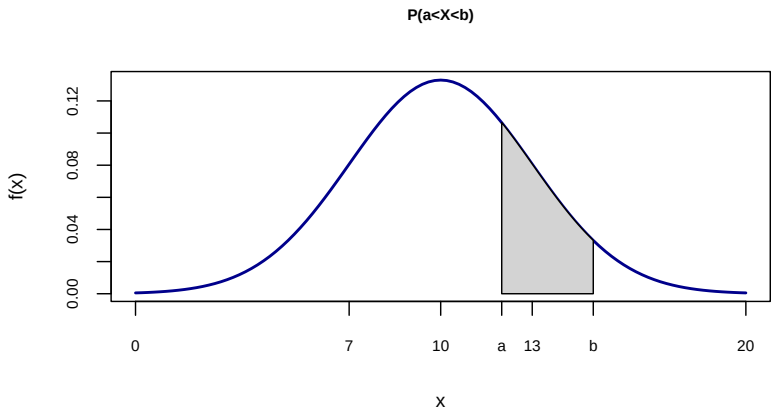

Figure 16: Calculando a probabilidade para a Distribuição Normal

É importante ressaltar que o cálculo da área, entre a e b, só pode ser obtido por integração numérica. Para cada distribuição, com seu μ e σ próprios, teríamos que (re)calcular qual a $P(a < X < b)$.

Então, para simplificar o problema, tentamos fazer a medida em termos de desvio padrão. Quanto que desvimos da média em desvio padrões. Para isso, padronizamos os valores, ouseja, achamos seus equivalentes na distribuição normal padrão. Essa já possui as probabilidades calculadas e disponibilizadas na tabela da Normal Padrão.

Assim, após a transformação em Normal padrão, passamos do cálculo da $P(a < X < b)$ para a $P(a* < Z < b*)$, onde $Z \sim N(0, 1)$

Podemos consultar o valor da $P(a* < Z < b*)$ já calculado e reportado na tabela da Normal Padrão. A figura 6 abaixo mostra graficamente tal transformação:

```
par(mfrow=c(2,1))
x<-seq(0,20,0.1)
fdnorm<-dnorm(x = x, mean = 10, sd=3)
regiao=seq(12,15,0.1)
cord.x <- c(min(regiao),regiao,max(regiao))
cord.y <- c(0,dnorm(regiao, mean=10, sd=3),0)
curve(dnorm(x,10,3),xlim=c(0,20),xlab="x",type="l",
      col="darkblue",lwd=2, ylab="f(x)",xaxt="n",main="P(a<X<b)",
      cex.axis=0.65, cex.lab=0.8, cex.main=0.7 )
axis(1,at=c(0,7, 10, 12,13, 15,20),labels =
       c(0, 7, 10, "a",13,"b",20),cex.axis=0.65, cex.lab=0.8)
```

```r
polygon(cord.x, cord.y, col='lightgray')

z<-seq(-3,3,0.1)
fdnorm<-dnorm(x = x, mean = 0, sd=1)
regiao=seq(0.66,1.66,0.1)
cord.x <- c(min(regiao),regiao,max(regiao))
cord.y <- c(0,dnorm(regiao, mean=0, sd=1),0)
curve(dnorm(x,0,1),xlim=c(-3,3),xlab="z",type="l",
      col="darkblue",lwd=2, ylab="f(z)",xaxt="n",main="P(a'<Z<b')",
      cex.axis=0.65, cex.lab=0.8, cex.main=0.7 )
axis(1,at=c(-3,1, 0, 0.66 ,1, 1.66, 3),labels =
       c(-3, 1, 0, "a'",1,"b'",3),cex.axis=0.65, cex.lab=0.8)
polygon(cord.x, cord.y, col='lightgray')
```

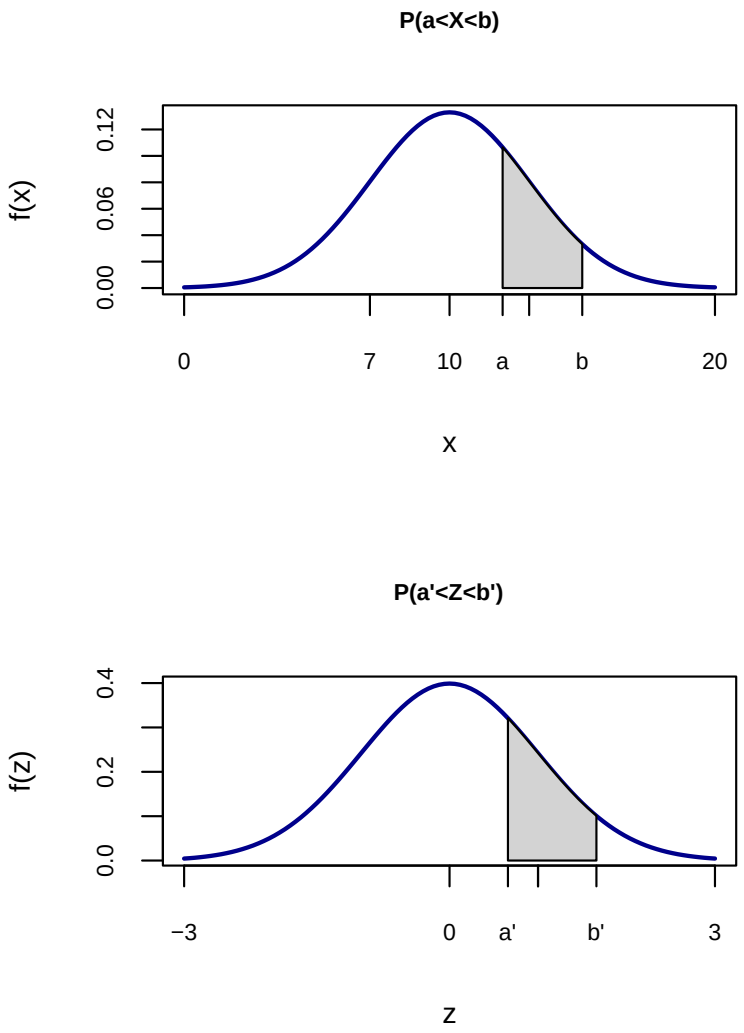

Figure 17: Relação entre as Distribuições Normais e a Normal Padrão

Exemplo

Calcule a $P(0 \leq Z \leq Z_c)$ para $Z_c = 1,73$

Resposta:
Consultando a tabela da Normal Padrão:
$P(0 \leq Z \leq 1,73) = 0,45818$
A Figura abaixo mostra como consultamos tal valor na tabela Normal Padrão extraída do livro de Morettin e Bussab (2010).

Tabela III — Distribuição Normal Padrão

$Z \sim N(0, 1)$

Corpo da tabela dá a probabilidade p, tal que $p = P(0 < Z < Z_c)$

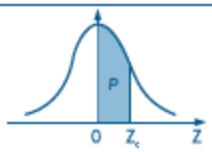

parte inteira e primeira decimal de Z_c	Segunda decimal de Z_c										parte inteira e primeira decimal de Z_c
	0	1	2	3	4	5	6	7	8	9	
	p = 0										
0,0	00000	00399	00798	01197	01595	01994	02392	02790	03188	03586	0,0
0,1	03983	04380	04776	05172	05567	05962	06356	06749	07142	07535	0,1
0,2	07926	08317	08706	09095	09483	09871	10257	10642	11026	11409	0,2
0,3	11791	12172	12552	12930	13307	13683	14058	14431	14803	15173	0,3
0,4	15542	15910	16276	16640	17003	17364	17724	18082	18439	18793	0,4
0,5	19146	19497	19847	20194	20540	20884	21226	21566	21904	22240	0,5
0,6	22575	22907	23237	23565	23891	24215	24537	24857	25175	25490	0,6
0,7	25804	26115	26424	26730	27035	27337	27637	27935	28230	28524	0,7
0,8	28814	29103	29389	29673	29955	30234	30511	30785	31057	31327	0,8
0,9	31594	31859	32121	32381	32639	32894	33147	33398	33646	33891	0,9
1,0	34134	34375	34614	34850	35083	35314	35543	35769	35993	36214	1,0
1,1	36433	36650	36864	37076	37286	37493	37698	37900	38100	38298	1,1
1,2	38493	38686	38877	39065	39251	39435	39617	39796	39973	40147	1,2
1,3	40320	40490	40658	40824	40988	41149	41309	41466	41621	41774	1,3
1,4	41924	42073	42220	42364	42507	42647	42786	42922	43056	43189	1,4
1,5	43319	43448	43574	43699	43822	43943	44062	44179	44295	44408	1,5
1,6	[illegible]	[illegible]	[illegible]	[illegible]	44950	45053	45154	45254	45352	45449	1,6
1,7	45543	45637	45728	45818	45907	45994	46080	46164	46246	46327	1,7
1,8	[illegible]	[illegible]	[illegible]	[illegible]	46712	46784	46856	46926	46995	47062	1,8
1,9	47128	47193	47257	47320	47381	47441	47500	47558	47615	47670	1,9
2,0	47725	47778	47831	47882	47932	47982	48030	48077	48124	48169	2,0
2,1	48214	48257	48300	48341	48382	48422	48461	48500	48537	48574	2,1
2,2	48610	48645	48679	48713	48745	48778	48809	48840	48870	48899	2,2
2,3	48928	48956	48983	49010	49036	49061	49086	49111	49134	49158	2,3
2,4	49180	49202	49224	49245	49266	49286	49305	49324	49343	49361	2,4
2,5	49379	49396	49413	49430	49446	49461	49477	49492	49506	49520	2,5
2,6	49534	49547	49560	49573	49585	49598	49609	49621	49632	49643	2,6
2,7	49653	49664	49674	49683	49693	49702	49711	49720	49728	49736	2,7
2,8	49744	49752	49760	49767	49774	49781	49788	49795	49801	49807	2,8
2,9	49813	49819	49825	49831	49836	49841	49846	49851	49856	49861	2,9
3,0	49865	49869	49874	49878	49882	49886	49889	49893	49897	49900	3,0
3,1	49903	49906	49910	49913	49916	49918	49921	49924	49926	49929	3,1
3,2	49931	49934	49936	49938	49940	49942	49944	49946	49948	49950	3,2
3,3	49952	49953	49955	49957	49958	49960	49961	49962	49964	49965	3,3
3,4	49966	49968	49969	49970	49971	49972	49973	49974	49975	49976	3,4
3,5	49977	49978	49978	49979	49980	49981	49981	49982	49983	49983	3,5
3,6	49984	49985	49985	49986	49986	49987	49987	49988	49988	49989	3,6
3,7	49989	49990	49990	49990	49991	49991	49992	49992	49992	49992	3,7
3,8	49993	49993	49993	49994	49994	49994	49994	49995	49995	49995	3,8
3,9	49995	49995	49996	49996	49996	49996	49996	49996	49997	49997	3,9
4,0	49997	49997	49997	49997	49997	49997	49998	49998	49998	49998	4,0
4,5	49999	50000	50000	50000	50000	50000	50000	50000	50000	50000	4,5

Figure 18: Consulta à tabela Normal Padrão para o exemplo apresentado

Exemplo

Depósitos no Banco Ribeirão em janeiro (x) são distribuídos normalmente com média 10000,00 e d.p. 1500,00
Seleciona-se um depósito ao acaso, qual a probabilidade de o depósito ser de:

a. 10 000 ou menos

b. Um valor entre 12 000 e 15 000

c. Maior que 20 000

Resposta:

a.

$$P(X < 10000) = P(Z \leq \frac{10000-10000}{15000}) = P(Z \leq 0) = 0,5$$

Portanto, a probabilidade é de 50%

b.

$$\begin{aligned} P(12000 < X < 15000) &= P(\frac{12000-10000}{15000} < Z < \frac{10000-10000}{15000}) \\ &= P(\frac{4}{3} < Z < \frac{10}{3}) \\ &= P(1,33 < Z < 3,333) \\ &= 0,49957 - 0,40824 = 0,09133 \end{aligned}$$

Portanto, a probabilidade é de $9,1\%$

c.

$$\begin{aligned} P(X > 20000) &= P(Z > \frac{20000-10000}{15000}) \\ &= P(Z > 6,67) \\ &\cong 0 \end{aligned}$$

Portanto, a probabilidade é praticamente zero.

O exemplo no R:

```r
pnorm(10000,mean=10000,sd=1500)
```

```
[1] 0.5
```

```r
pnorm(15000,mean=10000,sd=1500)-pnorm(12000,mean=10000,sd=1500)
```

```
[1] 0.09078216
```

```r
1-pnorm(20000,mean=10000,sd=1500)
```

```
[1] 1.308398e-11
```

Exemplo

A altura de 10000 alunos tem distribuição normal com $\mu = 170$ cm e $\sigma = 5$ cm.

a) Qual o número esperado de alunos com altura superior a 165 cm?

b) Qual é o intervalo simétrico ao redor da média que contém 75% dos alunos?

Resposta:

a)

$$\begin{aligned} P(X > 165) &= P(Z > \tfrac{165-170}{5}) \\ &= P(Z > -1) \\ &= P(Z < 1) = 0,34134 + 0,5 = 0,84134 \end{aligned}$$

Portanto, o número espero de alunos é de 8413 (84,13% de 10000)

b)

$$\begin{aligned} P(-a < Z < a) &= 0,75 \\ P(Z < a) &= 0,375 \\ a &= 1,15 \end{aligned}$$

Disto segue que:

$$\begin{aligned} 1,15 &= \tfrac{X-170}{5} \\ X_1 = 175,75 \ e \ X_2 &= 164,25 \end{aligned}$$

5 O Modelo Exponencial

Útil nas aplicações de contabilidade de sistemas.

5.1 O Modelo Exponencial

Definição

A v.a T tem distribuição exponencial com parâmetros $\beta > 0$ se sua f.d.p. tem a seguinte forma

$$f(t,\beta) = \begin{cases} \frac{1}{\beta} e^{\frac{-t}{\beta}}, & se\ t \geq 0 \\ 0, & se\ t < 0 \end{cases}$$

Tal que $T \sim Exp(\beta)$

5.2 Momentos da Distribuição

A distribuição T possui os seguintes Momentos :

Definição

Esperança:

$$E(T) = \beta$$

Variância:

$$Var(T) = \beta^2$$

5.3 Graficamente:

Considere a distribuição Exponencial para $\beta = 1$ e $\beta = 4$, ou seja, as esperanças.

```
par(mfrow=c(1,2))
curve(dexp(x,1),xlim=c(0,5),main="f.d.p para X~exponencial(1)",
      xlab="x",type="l", col="darkblue",lwd=2, ylab="f(x)",
      cex.axis=0.65, cex.lab=0.8, cex.main=0.7)
curve(dexp(x,4),xlim=c(0,5),main="f.d.p para X~exponencial(4)",
      xlab="x",type="l", col="darkblue",lwd=2, ylab="f(x)",
      cex.axis=0.65, cex.lab=0.8, cex.main=0.7)
```

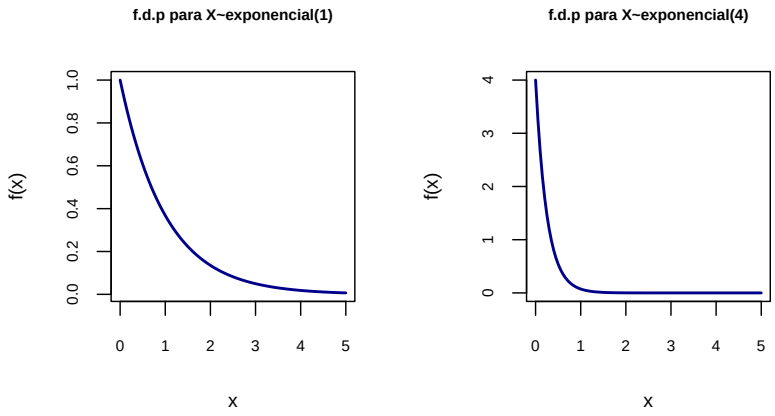

Figure 19: Distribuição de probabilidade exponecial e Distribuição exponencial acumulada

5.4 Função Distribuição Acumulada

Definição

A Distribuição Exponencial possui a seguinte F.d.a.

$$F(t) = \begin{cases} 1 - e^{\frac{-t}{\beta}}, \ se \ t \geq 0 \\ 0, \ se \ t < 0 \end{cases}$$

Exemplo

O tempo de vida de uma bactéria é uma v.a. com distribuição exponecial com parâmetro $\beta = 500$, portanto, E(T)=500. Qual a probabilidade de que uma bactéria viva acima da média?

Resposta:

$P(T > 500) = \int_{500}^{\infty} f(t).dt$

$= \frac{1}{500} \int_{500}^{\infty} e^{\frac{-t}{500}}.dt$

$= \frac{1}{500}[-500e^{\frac{-t}{500}}]_{500}^{\infty}$

$= e^{-1} = 0,3678$

Portanto, a probabilidade é de 36,7%

Fazendo o exemplo no R:

```
1-pexp(500,rate=1/500)
```

```
[1] 0.3678794
```

6 Aproximação da Binomial pela Normal

6.1 Relembrando a Binomial

Exemplo

Considere uma moeda honesta tal que sair cara indica sucesso e coroa indica fracasso. Lançando a moeda 3 vezes, qual a probabilidade de 2 sucessos?

Resposta:
Temos as seguintes possibilidades:

$$A = \{SSF, SFS, FSS\}$$

Então segue que:

$$\begin{aligned} P(SSF) &= \tfrac{1}{2}.\tfrac{1}{2}.\tfrac{1}{2} = \tfrac{1}{8} \\ &= pp.q = p^2.q \end{aligned}$$

Logo $P(A) = \frac{3}{8} = 3p^2.q$

A tabela abaixo contém o cálculo da probabilidade do problema acima:

Sucessos	Prob	p=1/2
0	q^3	1/8
1	$3pq^2$	3/8
2	$3p^2q$	3/8
3	p^3	1/8

6.1.1 Momentos:

Definição

A distribuição binomial possui os seguintes Momentos:
$E(x) = n.p$
$Var(x) = n.p.q$
E temos que:

$$P(x = k) = \binom{n}{k} p^k q^{n-k}$$

6.2 Aproximação Normal à Binomial

Suponha uma variável Y distribuída pela binomial com parâmetros $n = 10$ e $p = \frac{1}{2}$. Suponha que queremos calcular $P(Y \geq 7)$. Isso equivale a calcular:

Sucessos	Prob	p=1/2
7	$\binom{10}{7}p^7q^3$	0,11718
8	$\binom{10}{8}p^8q^2$	
9	$\binom{10}{9}p^9q^1$	
10	$\binom{10}{7}p^{10}$	

- Note que :

$$\binom{10}{7} = \frac{10!}{7!3!} = \frac{10.9.8}{6} = 120$$

$$P(X = 7) = 120.\frac{1}{2}^7\frac{1}{2}^3 = 0,117$$

- Aproximando pela normal temos que:

$$n = 10$$

$$\mu = n.p = 10.\frac{1}{2} = 5$$

$$\sigma^2 = n.p(1-p) = 10\frac{1}{2}\frac{1}{2} = 2,5$$

6.2.1 Graficamente:

```
barplot(height = dbinom(0:10,size=10,prob = 1/2),col = "white",ylim=c(0,0.3),
        ylab="f(x), p(x)", cex.lab=0.8,cex.main=0.7)
par(new=T)
barplot(height = c(rep(0,7),dbinom(7:10,size=10,prob = 1/2)),ylim=c(0,0.3),
        border=c(rep(NA,7),rep("black",4)), col = c(rep(NA,7),rep("gray",4)))
par(new=T)
curve(dnorm(x,mean=5, sd=sqrt(2.5)),xlim=c(-0.8,10.8),ylim=c(0.0,0.3),
      xaxs="i",yaxs="i",ylab="")
```

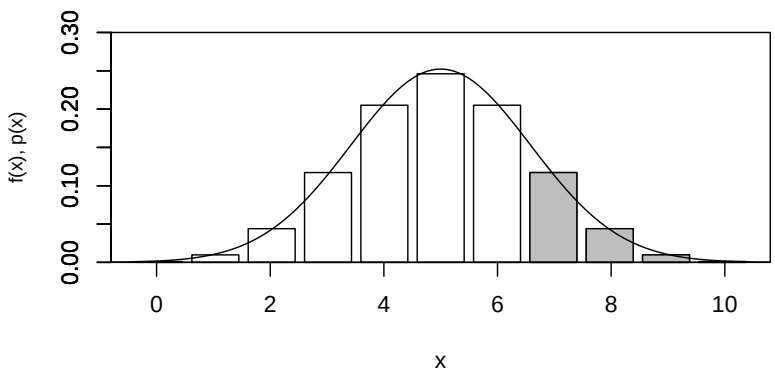

Figure 20: Aproximação da Binomial pela Normal

- Sendo X uma v.a. com distribuição normal então:

$$P(Y \geq 7) \cong P(X \geq 6,5) = P(\tfrac{x-\mu}{\sigma} \geq \tfrac{6,5-\mu}{\sigma})$$

$$P(Z \geq \tfrac{6,5-\mu}{\sigma}) = P(Z \geq 0,94) = 0,1714$$

onde $Z \sim N(0,1)$

- A probabilidade encontrada pela Normal é de 0,1718 enquanto pela aproximação encontramos que é de 0,1714.
- Formalmente, justifica-se tal aproximação pelo Teorema do Limite Central.

Fazendo o exemplo no R:

$P(Y \geq 7)$

```
1-pbinom(6,size=10,prob=1/2)
```

```
[1] 0.171875
```

$P(X \geq 6.5)$

```
1-pnorm(6.5,mean=5,sd=sqrt(2.5))
```

```
[1] 0.1713909
```

Exemplo

De um lote de produtos manufaturados, sorteamos 100 itens ao acaso. Sabemos que 10% dos itens produzidos possuem defeitos. Qual a chance que dos 100 sorteados 12 sejam defeituosos? Use a aproximação pela normal.

Resposta:
$X \sim b(100; 0,)$
Considere p= número de defeituosos. Pela aproximação pela Normal temos que $E(x) = 100.0,1 = 10$ e $Var(x) = 100.0,1.0,9 = 9$. Disto segue que:

$$P(x-12) = \binom{100}{12}.(0,1)^{12}(0,9)^{88} = \frac{100!}{12!88!}(0,1)^{12}(0,9)^{88} = 0,0987$$

Portanto, aproximando pela Normal temos a distribuição:
$Y \sim N(10; 9)$

$$\begin{aligned} P(Y=12) &= P(11,5 \leq X \leq 12,5) \\ &= P(\tfrac{11,5-10}{9} \leq Z \leq \tfrac{12,5-10}{9}) \\ &= P(0,5 \leq Z \leq 0,83) \\ &= 0,29673 - 0,19146 = 0,1052 \end{aligned}$$

Portanto, a probabilidade é de 10,5%

7 Distribuição Gama

7.1 O Modelo Gama

Uma variável aleatória contínua X que assume valores positivos tem distribuição Gama, com parâmetros $\alpha \geq 1$ e $\beta > 0$, com f.d.p. dada por:

Definição

$$f(x;\beta,\alpha) = \begin{cases} \frac{1}{\Gamma(\alpha)\beta^{\alpha}} x^{\alpha-1} e^{\frac{-x}{\beta}}, & x > 0 \\ 0, & x \leq 0 \end{cases}$$

Sendo $\Gamma(\alpha)$ a Função Gama:

$$\Gamma(\alpha) = \int_0^{\infty} e^{-x} x^{\alpha-1} dx \quad , \quad \alpha > 0$$

7.2 Graficamente

O gráfico abaixo mostra como a distribuição muda com a alteração dos parâmetros α e para $\beta = 1$:

```
col <- rainbow(3)
a <- c(1,2,5)
plot(0,0,xlab="x",ylab="Dist. de Prob. Gamma",
     xlim = c(0,8),ylim = c(0,1),
      cex.axis=0.65, cex.lab=0.8, cex.main=0.7)
for (i in 1:3)
{
  lines(seq(0,8,by=0.01),dgamma(seq(0,8,by=0.01),a[i],1),col = col[i])
}
legend(1, 1, legend=c("alfa=1", "alfa=2", "alfa=5"),
       col=c("red", "green", "blue"), lty=1:1, cex=0.8)
```

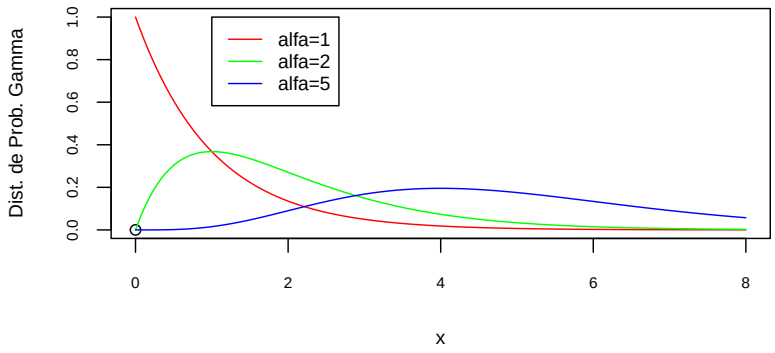

Figure 21: Distribuição Gamma, para Beta=1 e Alfa variando

7.3 Momentos

Definição

Se $X \sim Gama(\alpha, \beta)$ então possui os seguintes momentos:
Esperança:

$$E(X) = \alpha\beta$$

Variância:

$$Var(X) = \alpha\beta^2$$

8 Distribuição Qui-Quadrado

8.1 O Modelo Qui-Quadrado

Definição

Uma variável aleatória contínua Y que assume valores positivos tem distribuição Qui-Quadrado com v graus de liberdade - $\chi^2(v)$ - e possui a seguinte f.d.p.:

$$f(x;\beta, alpha) = \begin{cases} \frac{1}{\Gamma(v/2)2^{v/2}} y^{(v/2)-1} e^{\frac{-y}{2}} & , \ y > 0 \\ \\ 0 & , \ y \leq 0 \end{cases}$$

8.2 Graficamente

Abaixo temos a representação gráfica da Qui-Quadrado com diversos graus de liberdade (d.f.):

```
par(mfrow=c(1,3))
curve(dchisq(x,df=1),xlim=c(0,20),xlab="x", ylab="Dist. Prob. Qui-Quadrado",
      main="(a) df=2", col="darkblue",lwd=3,
      cex.axis=0.65, cex.lab=0.8, cex.main=0.7)
curve(dchisq(x,df=4),xlim=c(0,20),xlab="x", ylab="",
      main="(a) df=4", col="darkblue",lwd=3,
      cex.axis=0.65, cex.lab=0.8, cex.main=0.7)
curve(dchisq(x,df=6),xlim=c(0,20),xlab="x", ylab="",
      main="(a) df=6", col="darkblue",lwd=3,
      cex.axis=0.65, cex.lab=0.8, cex.main=0.7)
```

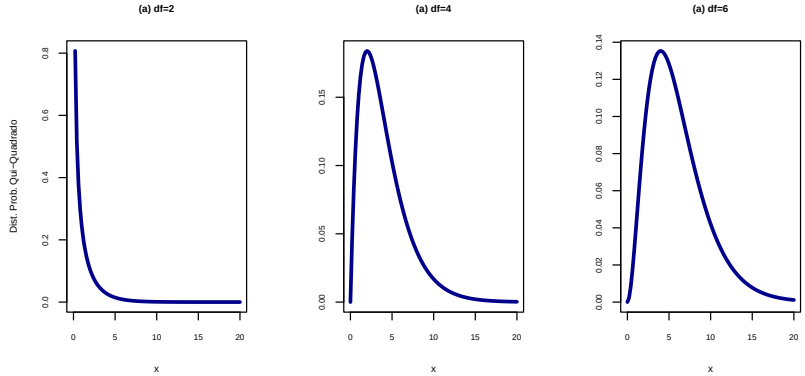

Figure 22: Distribuição Qui-Quadrado para diferentes graus de liberdade (gl)

8.3 Momentos

Definição

A distribuição Qui-Quadrado com v graus de liberdade possui os seguintes momentos:
Esperança: $E(Y) = v$

Variância: $Var(Y) = 2v$

Existem tabelas para obter uma probabilidade $P(Y > y_0)$ quando Y é uma variável com distribuição Qui-Quadrado. Além disso, quando $v > 30$ podemos utilizar a aproximação normal para a distribuição Qui-Quadrado.

8.4 Resultados importantes

Temos dois resultados importantes:

Definição

(1) O quadrado de uma v.a. com distribuição normal padrão é uma v.a. com distribuição $\chi^2(1)$

---

(2) Uma variável aleatória $\chi^2(V)$ é equivalente à soma de V normais padrões ao quadrado

9 Distribuição t-student

9.1 O Modelo t-student

Definição

Sejam as v.a. independentes $X \sim N(0,1)$ e $Y \sim \chi^2(v)$. Considere T:

$$T = \frac{X}{\sqrt{\frac{Y}{v}}}$$

Então T tem distribuição t-student com V graus de liberdade. Então, uma variável aleatória contínua com distribuição T tem a seguinte f.d.p.:
$f(t,;v) = \frac{\Gamma((v+1)/2)}{\Gamma(v/2)\sqrt{\pi v}}(1+t^2/v)^{\frac{-(v+1)}{2}}$
$\infty < t < \infty$

9.2 Graficamente

Para v suficientemente grande, a densidade de t aproxima-se da $N(0,1)$. Vejamos:

```
curve(dnorm(x),ylim=c(0,0.4),xlim=c(-3,3),xlab="x",col="darkred",
      ylab="Dist. Prob. t-student",lwd=3)
par(new=TRUE)
curve(dt(x,df=1),ylim=c(0,0.4),xlim=c(-3,3),xlab="",col="orange",
      lty=1,ylab="")
par(new=TRUE)
curve(dt(x,df=3),ylim=c(0,0.4),xlim=c(-3,3),xlab="",col="darkgreen",
      lty=1,ylab="")
par(new=TRUE)
curve(dt(x,df=15),ylim=c(0,0.4),xlim=c(-3,3),xlab="",col="blue",
      lty=1,ylab="")
legend(-3,0.4,lty=c(1,1,1,1), col=c("darkred","orange","darkgreen","blue"),
       legend=c("normal padrão", "t-gl=1","t-gl=3", "t-gl=15"),
       bty="n",lwd=c(2,2,2,2),cex=0.75)
```

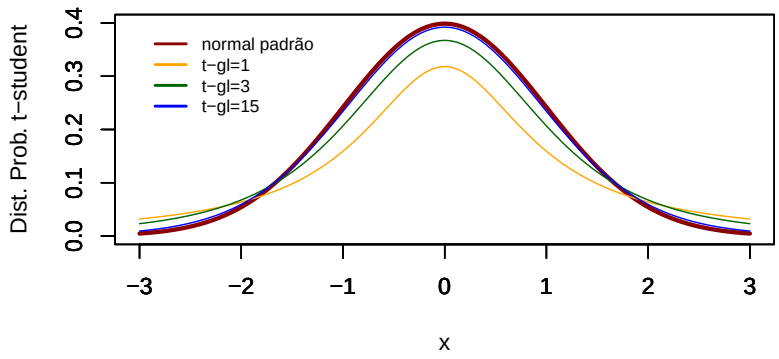

Figure 23: Distribuição t-student para diferentes graus de liberdade (gl)

Observe que quanto maior o grau de liberdade, gl, mais próximo à normal padrão a distribuição de t-student se encontra.

9.3 Momentos

Definição

A distribuição t-student com v graus de liberdade possui os seguintes momentos:
Esperança: $E(t) = 0$

Variância: $Var(t) = \frac{v}{v-2}$

10 Distribuição F

10.1 O Modelo F

Definição

Sejam U e V duas v.a. independentes, cada uma com distribuição qui-quadrado com v_1 e v_2 graus de liberdade. Então a v.a.

$$W = \frac{U/v_1}{V/v_2}$$

possui distribuição F com v_1 e v_2 graus de liberdade, tal que $W \sim F(v_1, v_2)$. Dessa forma, uma variável aleatória contínua com distribuição F tem a seguinte f.d.p.:

$$f(t,;v) = \frac{\Gamma((v_1+v_2)/2)}{\Gamma(v_1/2)\Gamma(v_2/2)}(\frac{v_1}{v_2})^{v1/2}\frac{w^{(v_1-2)/2}}{(1+v_1w/v_2)^{(v_1+v_2)/2}}$$

Para $w > 0$

10.2 Momentos

Definição

A distribuição F possui os seguites momentos: Esperança:
$E(W) = \frac{v_1}{v_1-v_2}$

Variância:
$Var(W) = \frac{2v_2^2(v_1+v_2-2)}{v_1(v_2-2)^2(v_2-4)}$

10.3 Graficamente

Gráficos da distribuição para diferentes combinações de v_1 e v_2.

```
x<-seq(0,10,0.1)
curve(df(x,df1=2, df2=2),ylim=c(0,1),xlim=c(0,4),xlab="x",
      col="orange",lty=1,ylab="Distribuição de Prob. F")
par(new=TRUE)
curve(df(x,df1=5, df2=7),ylim=c(0,1),xlim=c(0,4),xlab="",
```

```
      col="darkblue",lty=1,ylab="")
par(new=TRUE)
curve(df(x,df1=20, df2=20),ylim=c(0,1),xlim=c(0,4),xlab="",
      col="darkgreen",lty=1,ylab="")
legend(2,1,lty=c(1,1,1,1), col=c("orange","darkblue","darkgreen"),
       legend=c("gl1=2; gl2=2", "gl1=5; gl2=7","gl1=20; gl2=20")
       ,bty="n",lwd=c(2,2,2,2),cex=0.75)
```

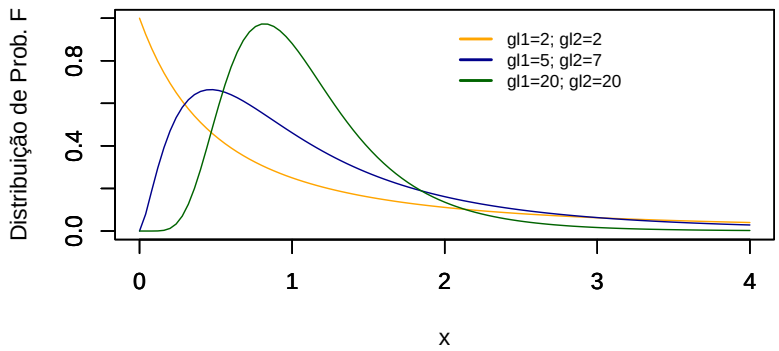

Figure 24: Distribuição de Probabilidade F

Um exemplo

Suponha que desejamos encontrar $P(F(v_1, v_2) > F_\alpha)$. Isso é equivalente à encontrar a área α da figura abaixo, tal que $P(F(v_1, v_2) > F_{alpha}) = \alpha$.

Graficamente:

```
x<-seq(0,10,0.1)
regiao=seq(2.5,4,0.01)
cord.x <- c(min(regiao),regiao,max(regiao))
cord.y <- c(0,df(regiao,df1=5, df2=7),0)
curve(df(x,df1=5, df2=7),xlim=c(0,4),ylim=c(0,1),xaxt='n', xlab="x",
      ylab="Dist. Prob. F",xaxs="i",yaxs="i",col="darkblue",lwd=2,
      cex.axis=0.65, cex.lab=0.8)
axis(1,at=c(0,1, 2, 2.5,3, 4),labels =
       c(0,1, 2, "a" ,3, 4),cex.axis=0.65, cex.lab=0.8)
polygon(cord.x,cord.y,col='lightgray')
```

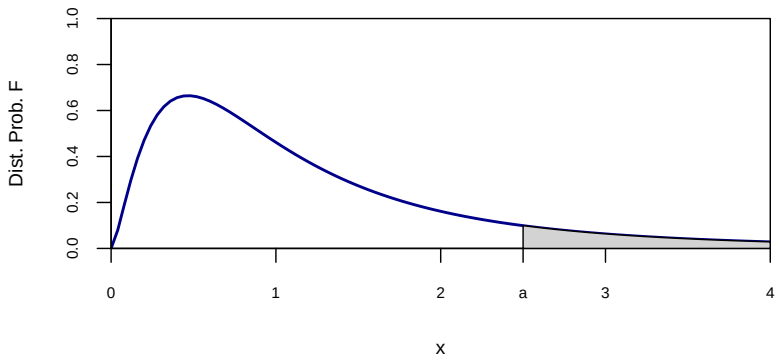

Figure 25: Encontrando a Probabilidade para Distribuição de Probabilidade F

Para valores inferiores temos que:

$$F(v_1, v_2) = \frac{1}{F(v_2, v_1)}$$

Exemplo

Seja $W \sim F(5, 7)$.Calcule o valor de F_α tal que:
$P(F > F_\alpha) = 0,05$ e $P(F \leq F_\alpha) = 0,95$

Resposta:
Consultando a tabela para a distribuição F retirada de Morettin e Bussab (2010) e representada abaixo temos que:
$P(F > F_\alpha) = 0,05$ e $P(F \leq F_\alpha) = 0,95$ para $F_\alpha = 3,97$

Tabela VI — Distribuição F

Corpo da tabela dá os valores f_c tais que $P(F > f_c) = 0{,}05$.

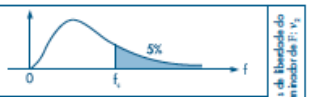

Graus de liberdade do denominador de F: ν_2	Grau de liberdade do numerador de F: ν_1 = 1	2	3	4	5	6	7	8	9	10	12	14	15	16	18	20	24	30	40	60	120	∞	Graus de liberdade do denominador de F: ν_2
1	161,4	199,5	215,7	224,6	30,2	34,0	236,8	238,9	240,5	241,9	243,9	245,4	245,9	246,5	247,3	248,0	249,1	250,1	251,1	252,2	253,3	254,3	1
2	18,51	19,00	19,16	19,25	19,30	19,33	19,35	19,37	19,38	19,40	19,41	19,42	19,43	19,43	19,44	19,45	19,45	19,46	19,47	19,48	19,49	19,50	2
3	10,13	9,55	9,28	9,12	9,01	8,94	8,89	8,85	8,81	8,79	8,74	8,72	8,70	8,69	8,67	8,66	8,64	8,62	8,59	8,57	8,55	8,53	3
4	7,71	6,94	6,59	6,39	6,26	6,16	6,09	6,04	6,00	5,96	5,91	5,87	5,86	5,84	5,82	5,80	5,77	5,75	5,72	5,69	5,66	5,63	4
5	6,61	5,79	5,41	5,19	5,05	4,95	4,88	4,82	4,77	4,74	4,68	4,64	4,62	4,60	4,58	4,56	4,53	4,50	4,46	4,43	4,40	4,36	5
6	[illegible]	[illegible]	[illegible]	[illegible]	[illegible]	4,28	4,21	4,15	4,10	4,06	4,00	3,96	3,94	3,92	3,90	3,87	3,84	3,81	3,77	3,74	3,70	3,67	6
7	5,59	4,74	4,35	4,12	3,97	3,87	3,79	3,73	3,68	3,64	3,57	3,53	3,51	3,49	3,47	3,44	3,41	3,38	3,34	3,30	3,27	3,23	7
8	[illegible]	[illegible]	[illegible]	[illegible]	[illegible]	3,58	3,50	3,44	3,39	3,35	3,28	3,24	3,22	3,20	3,17	3,15	3,12	3,08	3,04	3,01	2,97	2,93	8
9	5,12	4,26	3,86	3,63	3,48	3,37	3,29	3,23	3,18	3,14	3,07	3,03	3,01	2,99	2,96	2,94	2,90	2,86	2,83	2,79	2,75	2,71	9
10	4,96	4,10	3,71	3,48	3,33	3,22	3,14	3,07	3,02	2,98	2,91	2,87	2,85	2,83	2,80	2,77	2,74	2,70	2,66	2,62	2,58	2,54	10
11	4,84	3,98	3,59	3,36	3,20	3,09	3,01	2,95	2,90	2,85	2,79	2,74	2,72	2,70	2,67	2,65	2,61	2,57	2,53	2,49	2,45	2,40	11
12	4,75	3,89	3,49	3,26	3,11	3,00	2,91	2,85	2,80	2,75	2,69	2,64	2,62	2,60	2,57	2,54	2,51	2,47	2,43	2,38	2,34	2,30	12
13	4,67	3,81	3,41	3,18	3,03	2,92	2,83	2,77	2,71	2,67	2,60	2,55	2,53	2,52	2,48	2,46	2,42	2,38	2,34	2,30	2,25	2,21	13
14	4,60	3,74	3,34	3,11	2,96	2,85	2,76	2,70	2,65	2,60	2,53	2,48	2,46	2,44	2,41	2,39	2,35	2,31	2,27	2,22	2,18	2,13	14
15	4,54	3,68	3,29	3,06	2,90	2,79	2,71	2,64	2,59	2,54	2,48	2,42	2,40	2,39	2,35	2,33	2,29	2,25	2,20	2,16	2,11	2,07	15
16	4,49	3,63	3,24	3,01	2,85	2,74	2,66	2,59	2,54	2,49	2,42	2,37	2,35	2,33	2,30	2,28	2,24	2,19	2,15	2,11	2,06	2,01	16
17	4,45	3,59	3,20	2,96	2,81	2,70	2,61	2,55	2,49	2,45	2,38	2,34	2,31	2,29	2,26	2,23	2,19	2,15	2,10	2,06	2,01	1,96	17
18	4,41	3,55	3,16	2,93	2,77	2,66	2,58	2,51	2,46	2,41	2,34	2,29	2,27	2,25	2,22	2,19	2,15	2,11	2,06	2,02	1,97	1,92	18
19	4,38	3,52	3,13	2,90	2,74	2,63	2,54	2,48	2,42	2,38	2,31	2,26	2,23	2,22	2,18	2,16	2,11	2,07	2,03	1,98	1,93	1,88	19
20	4,35	3,49	3,10	2,87	2,71	2,60	2,51	2,45	2,39	2,35	2,28	2,22	2,20	2,18	2,15	2,12	2,08	2,04	1,99	1,95	1,90	1,84	20
21	4,32	3,47	3,07	2,84	2,68	2,57	2,49	2,42	2,37	2,32	2,25	2,20	2,18	2,16	2,12	2,10	2,05	2,01	1,96	1,92	1,87	1,81	21
22	4,30	3,44	3,05	2,82	2,66	2,55	2,46	2,40	2,34	2,30	2,23	2,17	2,15	2,13	2,10	2,07	2,03	1,98	1,94	1,89	1,84	1,78	22
23	4,28	3,42	3,03	2,80	2,64	2,53	2,44	2,37	2,32	2,27	2,20	2,15	2,13	2,11	2,08	2,05	2,01	1,96	1,91	1,86	1,81	1,76	23
24	4,26	3,40	3,01	2,78	2,62	2,51	2,42	2,36	2,30	2,25	2,18	2,13	2,11	2,09	2,05	2,03	1,98	1,94	1,89	1,84	1,79	1,73	24
25	4,24	3,39	2,99	2,76	2,60	2,49	2,40	2,34	2,28	2,24	2,16	2,11	2,09	2,07	2,04	2,01	1,96	1,92	1,87	1,82	1,77	1,71	25
26	4,23	3,37	2,98	2,74	2,59	2,47	2,39	2,32	2,27	2,22	2,15	2,09	2,07	2,05	2,02	1,99	1,95	1,90	1,85	1,80	1,75	1,69	26
27	4,21	3,35	2,96	2,73	2,57	2,46	2,37	2,31	2,25	2,20	2,13	2,08	2,06	2,04	2,00	1,97	1,93	1,88	1,84	1,79	1,73	1,67	27
28	4,20	3,34	2,95	2,71	2,56	2,45	2,36	2,29	2,24	2,19	2,12	2,06	2,04	2,02	1,99	1,96	1,91	1,87	1,82	1,77	1,71	1,65	28
29	4,18	3,33	2,93	2,70	2,55	2,43	2,35	2,28	2,22	2,18	2,10	2,05	2,03	2,01	1,97	1,94	1,90	1,85	1,81	1,75	1,70	1,64	29
30	4,17	3,32	2,92	2,69	2,53	2,42	2,33	2,27	2,21	2,16	2,09	2,04	2,01	1,99	1,96	1,93	1,89	1,84	1,79	1,74	1,68	1,62	30
40	4,08	3,23	2,84	2,61	2,45	2,34	2,25	2,18	2,12	2,08	2,00	1,95	1,92	1,90	1,87	1,84	1,79	1,74	1,69	1,64	1,58	1,51	40
60	4,00	3,15	2,76	2,53	2,37	2,25	2,17	2,10	2,04	1,99	1,92	1,86	1,84	1,81	1,78	1,75	1,70	1,65	1,59	1,53	1,47	1,39	60
120	3,92	3,07	2,68	2,45	2,29	2,17	2,09	2,02	1,96	1,91	1,83	1,77	1,75	1,72	1,69	1,66	1,61	1,55	1,50	1,43	1,35	1,25	120
∞	3,84	3,00	2,60	2,37	2,21	2,10	2,01	1,94	1,88	1,83	1,75	1,69	1,67	1,63	1,60	1,57	1,52	1,46	1,39	1,32	1,22	1,00	∞
	1	2	3	4	5	6	7	8	9	10	12	14	15	16	18	20	24	30	40	60	120	∞	

Figure 26: Tabela da Distribuição F

Exemplo

Seja $W \sim F(5,7)$. Calcule $P(F < F_\alpha) = 0,05$

Resposta:

$$P(F(5,7) < F_\alpha) = P(\tfrac{1}{F(7,5)} < F_\alpha) = P(F(7,5) > \tfrac{1}{F_\alpha})$$

Pela tabela:

$$\tfrac{1}{F_\alpha} = 4,8 \rightarrow F_\alpha = 0,205$$

11 Introdução: Inferência

11.1 Objetivo:

Um processo de levantamento de informações é em geral caro e em muitas situações é destrutivo. Os processos destrutivos são em geral associadosa equipamento eletrônicos, para

saber quanto uma lâmpada dura tenho que ligar e esperar queimar!! Em ciências sociais estamos interessados em características de pessoas, empresas, municípios, estados, países etc. Não é destrutivo mas é uma coleta cara. Por exemplo, o Censo demográfico de 2010 custou R$ 1,3 bilhões, ou aproximadamente R$ 2,2 bi em reais de 2020. O valor é de aproximadamente R$ 35,00 por domicílio. Vejamos outro caso. A figura abaixo mostra a nota de pesquisa eleitoral realizada para eleição ao governo de São Paulo. Vejam que os questionários variam de R$40 a R$67 por questionário, uma média de R$ 53 reais o questionário. Logo uma pesquisa eleitoral para saber as intenções de votos de 2500 pessoas custa aproximadamente R$135 mil[6].

PRESTADOR DE SERVIÇOS

IBOPE inteligência

CPF/CNPJ: **68.802.370/0001-86** Inscrição Municipal: **2.610.381-8**
Nome/Razão Social: **IBOPE INTELIGENCIA PESQUISA E CONSULTORIA LTDA**
Endereço: **AV FRANCISCO MATARAZZO 01350, ANDAR 8; CGD CORPORAT - Água Branca - CEP: 05001-100**
Município: **São Paulo** UF: **SP**

TOMADOR DE SERVIÇOS

Nome/Razão Social: **S/A O ESTADO DE S.PAULO**
CPF/CNPJ: **61.533.949/0001-41** Inscrição Municipal: **1.055.203-0**
Endereço: **AV ENGENHEIRO CAETANO ALVARES 00055, AV PROF C BOURROUL 100 - LIMAO - CEP: 02546-000**
Município: **São Paulo** UF: **SP** E-mail: **estado.nfe-servicos@estadao.com**

INTERMEDIÁRIO DE SERVIÇOS

CPF/CNPJ: **----** Nome/Razão Social: **----**

DISCRIMINAÇÃO DOS SERVIÇOS

JOB 180011 - PAG DAS PESQ REALIZ NO 2° TURNO DAS ELEIÇÕES PRES 2018 E ELEIÇÕES P/ GOV NO EST DE SÃO PAULO. O VALOR PAGO PELO TOMADOR SE REF A PARCELA 01 DE 03 E CORRESP À 50% DAS RODADAS NACIONAIS E 50% DAS RODADAS EM SÃO PAULO. O RESTANTE SERÁ PAGO POR OUTRO CONTR, CONF CONTRATO CELEB ENTRE AS PARTES, DISCRIM EM SUA RESPEC NF. ABRANGÊNCIA NACIONAL: DUAS PESQUISAS DE 2.506 ENTREVISTAS CADA NO VALOR DE R$ 336.960,47 E UMA PESQUISA DE 3.010 ENTREVISTAS NO VALOR DE R$ 202.364,53/ SÃO PAULO: DUAS PEPESQUISAS DE 1.506 ENTREVISTAS NO VALOR DE 121.269,94 E UMA PESQUISA DE 2.002 ENTREVISTAS NO VALOR DE R$ 80.605,06. VENCIMENTO: 15/10/2018.

ATENCAO! RETER R$ 3706 REF A 1.5% IR - LEI 9064 DE 20/06/1995
ATENCAO RETER R$ 1605.93 REF A 0.65% PIS - LEI 10.833 DE 29/12/2003
ATENCAO RETER R$ 7412 REF A 3% COFINS - LEI 10.833 DE 29/12/2003
ATENCAO RETER R$ 2470.67 REF A 1% CSLL LEI - 10.833 DE 29/12/2003

ESTAO ISENTAS DESSAS RETENCOES AS EMPRESAS
OPTANTES PELO SIMPLES OU QUE ESTEJAM ENQUADRADAS
NAS DEMAIS EXCEÇÕES DO ART 32, LEI 10.833 DE
29/12/2003 OU NO ART. 5 LEI 10.925 DE 23/07/2004

Figure 27: Valor de pesquisa eleitoral em 2018

Espero que tenha ficado claro que olhar todo mundo, na grande maioria das vezes, é fisicamente, temporalmente e financeiramente impossível.

Dessa forma nosso objetivo aqui é:

> **A partir de uma amostra da população realizar inferência sobre toda a população**.

11.2 Exemplos do príncipio no dia a dia

Pense nessas situações:

[6]Fonte: TSE- http://www.tse.jus.br/eleicoes/pesquisa-eleitorais/consulta-as-pesquisas-registradas

- Para medir a glicose muitos pacientes usam uma gota de sangue e um pequeno aparelho. A partir dele sabem quanto tem no corpo todo, basta uma gota para termos boa certeza de quanto é taxa de glicose!
- Para saber se a quantidade de sal está adequada em uma grande panela de arroz, basta uma pequena colher de chá para termios uma boa certeza!
- Abacaxis às vezes são vendidos em caminhões na rua. Quando paramos provamos e são doces. Compramos 4 por 10. Qual a certeza que esses que vc está levando estejam também doces? É diferente das situações anteriores?

Com certeza vc deve ter pensado que sim é diferente. A certeza é muito menor na segunda. A diferença está em quão homogênea é a característica na população, o sal no arroz e a glicose no sangue devem ser muito bem distribuidas, ou seja, bem homogêneas. Já a doçura no abacaxi deve ter distribuição pior e provar apenas um abacaxi não nos dá uma ideia do todo.

Esse é um erro muito comum, a partir de uma ou poucas observações dizer que o todo se comporta da mesma maneira, esse erro se agrava quando maior é a heterogeneidade!!!

11.3 Algumas definições importantes

11.3.1 População e amostra

Definição

População: Totalidade das observações sob Investigação

Amostra: Subconjunto da população observado

A definição da população depende da pergunta de pesquisa ou análise. Se queremos saber qual o salário médio dos empregados do setor industrial no estado de São Paulo para determinado ano, nossa população são todos os funcionários das indústrias instaladas no estado de São Paulo para esse ano. Se queremos os determinantes do desempenho escolar dos alunos do ensino fundamental no Brasil em 2019, nossa população será esse grupo de aluno nesse ano. Se quisermos avaliar o gasto municipal no ano anterior as eleições no Brasil, temos nossa população formada pelos municípios para o ano de análise.

Quem define a população é o objetivo do seu trabalho

11.3.2 Amostragem Aleatória Simples

Existem várias maneiras de fazer uma análise aleatória, uma delas é a simples. Vejamos primeiro um processo de amostragem não aleatório e que possui tendenciosidade. A figura abaixo mostra esse processo[7]:

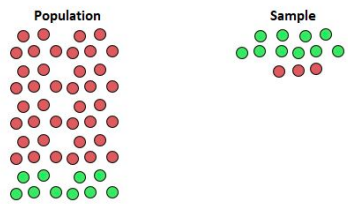

Figure 28: Amostragem tendenciosa

Observa-se que existe uma supervalorização do verde e uma subvalorização do vermelho. Chegariamos a conclusão, caso isso fosse uma pesquisa eleitoral, que o candidato verde, segunda amostra teria mais chance de ganhar e o vermelho menor chance. O que não condiz com a população. Dizemos que temos uma amostra viesada ou tendenciosa.

Um processo de amostragem aleatório requer que as características presentes na população estejam presentes na amostras e estejam balanceadas, ou seja, que a sua leitura represente bem o todo. a figura abaixo mostra alguns tipos de amostragem, a simples, sistemática, estratificada e em cluster[8].

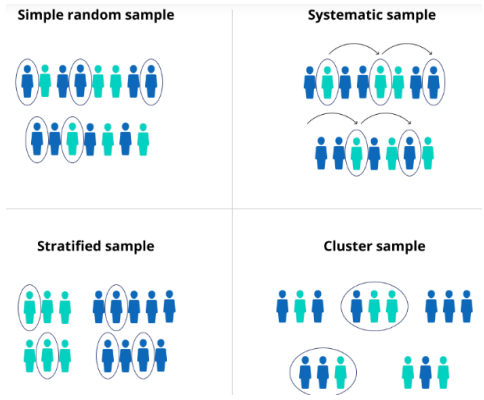

Figure 29: Tipos de amostragem aleatórias

Aqui podemos pensar sempre na amostragem aleatória simples e que será explicada nesse curso. Outros porcessos de amostragem requerem estudos específicos na área! Vejamos então a

[7]Fonte: https://www.statology.org/undercoverage-bias/
[8]https://www.scribbr.com/methodology/sampling-methods/

definição de amostragem aleatória simples.

Definição

Considere uma amostra de tamanho n de uma população $f(X)$,tal que $i = 1, ..., n$, onde X_i é a i-ésima medição de X.

Assim, chamamos de **Amostra Aleatória Simples** o conjunto de n variáveis aleatóridas independentes $X_i, ..., X_n$, cada uma com a mesma distribuição de probabilidade de X, ou seja, $f(X)$.

Precisa-se garantir que cada medida X_i seja feita da mesma maneira ou da mesma forma de mensuração. Dessa forma, garante-se que a Amostra Aleatória Simples $X_i, ..., X_n$ é independemente e identicamente distribuída (iid). Portanto, X_i são variáveis aleatórias e $(x_i, ..., x_n)$ os valores correspondentes.

Graficamente:

```
# Mostrando que Xi tem a mesma distribuição de X
 # Simulamos a distribuição de alturas, X, E(X)=167 e DP(X)=5
 x_alt<-rnorm(100000,mean=167, sd= 5)

 # Vamos fazer a primeira medição de X, ou seja, sortear somente o
 # primeiro elemento Xi.
   # Iremos repetir a primeira medição 100.000, ou seja, repetimos o
   # sorteio de Xi 100 mil vezes

# 1 - Criamos uma vetor numérico
xi<-numeric()

# 2 - Sorteamos de X os valores com reposição e criamos o vetor Xi
for ( i in 1:100000){
  xi[i]<-sample(x_alt,size = 1, replace=TRUE)
}

# 3 - Agora plotamos X e Xi para ver se há diferença na distribuição
par(mfrow=c(1,2))
hist(x_alt, col="steelblue3", border="white",freq = FALSE, ylab="Densidade",
     xlab="x",main="", xlim=c(150, 190), breaks=20)
hist(xi, col="wheat4", border="white",freq = FALSE, ylab="Densidade",
```

```
xlab="xi",main="", xlim=c(150, 190),breaks=20)
```

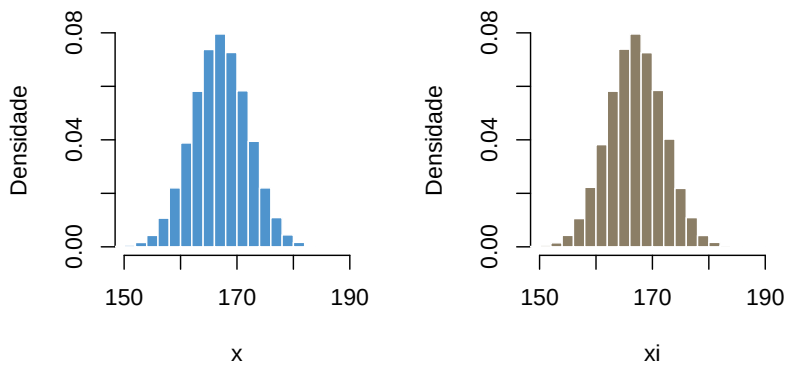

Figure 30: Distribuição de probabilidade de X e da primeira medição de X, ou seja, Xi

Exemplo

Seja X a altura média dos alunos da FEA. Temos uma amostra de tamanho n=30 que é representada por:

As medições são $(X_1, X_2, ..., X_{30})$ com as respectivas alturas observadas de $(x_1, x_2, ..., x_{30})$

Se a altura X for uma v.a. com fdp $f(x)$ então cada mensuração X_i terá a mesma distribuição $f(x)$ e a função de densidade conjunta de $(X_1, X_2, ..., X_{30})$ será:

$$g(x_1, ..., x_{30}) = f(x_1)f(x_2)...f(x_{30})$$

ou

$$q(x_1, ..., x_{30}) = p(x_1)p(x_2)...p(x_{30})$$

Pois são *iid*

Exemplo

Temos uma amostra n=8 de baterias de notebooks, sendo a vida útil dessas representada por X. A primeira medição é X_1 e observa-se o valor x_1 entre todos os possíveis valores. Analogamente:

Tem-se os valores observados $(x_1, x_2, ..., x_8)$ das medições $(X_1, X_2, ..., X_8)$

Se a população de notebooks possuem baterias com vida útil normalmente distribuídas (X), então as medições da vida útil $(X_1, X_2, ..., X_{30})$ também possuem a mesma distribuição da população original.

11.4 Estatística e Parâmetro

Definição

Parâmetro: Medida que descreve uma característica da população.

Os parâmetros definem as características de uma população. Qual a renda média da população, qual o desemprego médio da população, qual o desempenho médio educacional, qual a expectativa de vida média na população etc. São características que em geral não observamos.

Uma pergunta, qual a nota média da sua turma (aqueles que entraram com você na faculdade)? Perceba que mesmo características da sua população, são de difíceis conhecimento. Temos que nos valer de uma parte e tentar estimar o que seriam os valores dessas características.

Definição

Estatística é uma característica de uma amostra, ou seja, é uma função de seus elementos $X_1, X_2, ..., X_n)$.

Definição

Seja $X_1, X_2, ..., X_n$ uma A.A.S. de X. Sejam $x_1, x_2, ..., x_n$ os valores medidos a cada para cada medição de X. Seja H uma função real, cujo argumento é um vetor n-dimensional de números reais. Podemos definir uma estatística como:

$$T = H(X_1, X_2, ..., X_n)$$

Para a amostra e toma o valor particular:

$$t = H(x_1, x_2, ..., x_n)$$

Onde T é uma variável aleatória e, portanto, possuirá uma distribuição de probabilidade, chamada de distribuição amostral de T. Alguns exemplos de T:

$$Média: \ \overline{X} = \frac{\sum_{i=1}^{n} X_i}{n}$$

$$Variância: \ S^2 = \frac{1}{n-1} \sum_{i=1}^{n} (X_i - \overline{X})^2$$

$$X_{(1)} : Min\{X_1, ..., X_n\}$$

Vejamos a tabela abaixo que já faz uma primeira associação entre estatística e parâmetro:

Parâmetro		Estatística	
Esperança	$E(X) = \mu$	$\bar{X}$	Média
Variância Pop.	$Var(X) = \sigma^2$	$S^2; \sigma^2$	Variância Amostral
Mediana Pop.	Md	md	Mediana Amostral
Proporção Pop.	p	$\hat{p}$	Proporção Amostral

Tabela 1 - Parâmetros populacionais e as Estatísticas associadas

Como regra geral, temos que parâmetros são representados por letras gregas e estatística como letra do nosso alfabeto (latino), ou se utilizamos nosso alfabeto para representar o parâmetro, utilizamos a mesma letra mas com chapéu para indicar que é uma estatística.

11.5 Distribuições amostrais

Nosso objetivo agora é ser mais específico que o colocado anteriormente. Nosso objetivo específico é:

> Fazer uma afirmativa sobre o parâmetro, característica da população, por meio de um estatística, característica da amostra.

Ou seja, utilizamos uma estatística amostral T para inferir o parâmetro populacional Θ.

Como T é uma variável aleatória e possui distribuição de probabilidade, precisamos saber:

→ Qual a distribuição de T?

→ Quais as propriedades ou característica das distribuições amostrais?

11.6 Distribuição Amostral da Média

Suponha uma variável aleatória X que possui distribuição de probabilidade f(x) e tem os seguintes parâmetros:

$$E(x) = \mu$$

$$Var(x) = \sigma^2$$

Não sabemos qual a distribuição de X, mas sabemos que $\overline{X}$ é uma uma variável aleatória que é função da amostra e gostariamos de saber sobre algumas características da sua distribuição. Vejamos primeiro os seus momentos. A intuição é:

→ Extraímos todas as possíveis amostras de tamanho n da população

→ Então calculamos $\overline{X}$ para cada uma das amostras

Assim:

$$E(\overline{X}) = X$$

$$Var(\overline{X}) = S^2_{\overline{X}} = \frac{Var(X)}{n}$$

Teorema

Seja X uma v.a. com parâmetros μ e σ^2. Seja $(X_1, X_2, ..., X_n)$ uma A.A.S. de X. Então:

$E(\overline{X}) = \mu$

$Var(\overline{X}) = \frac{\sigma^2}{n}$

Demonstração:
Para $(X_1, X_2, ..., X_n)$ independentes temos que:

$$E(\overline{X}) = \frac{1}{n}\{E(X_1) + ... + E(X_n)\} = \frac{n\mu}{n} = \mu$$

$$Var(\overline{X}) = \frac{1}{n^2}\{Var(X_1) + ... + Var(X_n)\} = \frac{1}{n^2}n\sigma^2 = \frac{\sigma^2}{n}$$

Conforme veremos logo a frente pelo Teorema do Limite Central, que a distribuição de $\overline{X}$ ser uma $N(\mu; \frac{\sigma^2}{n})$. Dessa forma, quanto maior o n da amostragem, menor será a $Var(\overline{X})$. Vejamos a figura abaixo adaptada de Bussab e Morettin:

```
#Exemplo extraído de Bussab e Morettin

# Simulando uma variável com distribuição normal.
x_normal<-rnorm(10000,mean=167, sd= 5)

# Criando os vetores numéricos
# Media e variancia para amostras de tam 15, 50 E 150
xbar15<-numeric()
var_amostral15<-numeric()
xbar50<-numeric()
var_amostral50<-numeric()
xbar150<-numeric()
var_amostral150<-numeric()

# Extraindo duas mil amostras de 15, 50 e 150 elementos e fazendo a média e
  # variância para cada uma das amostras. Teremos 2000 médias e 2000 variâncias
  #para cada tamanho de amostra (15, 50 3 150)
```

```r
for ( i in 1:2000){
  smp<-sample(x_normal,size = 15)
  xbar15[i]<-mean(x_normal[smp])
  var_amostral15[i]<-var(x_normal[smp])

  smp<-sample(x_normal,size = 50)
  xbar50[i]<-mean(x_normal[smp])
  var_amostral50[i]<-var(x_normal[smp])

  smp<-sample(x_normal,size = 150)
  xbar150[i]<-mean(x_normal[smp])
  var_amostral150[i]<-var(x_normal[smp])
}

par(mfrow=c(2,3))
hist(xbar15, col="steelblue3",freq = FALSE, breaks = 25,main="",
     xlim=c(164, 170), ylab="Densidade", xlab="Média para n=15",
     border="steelblue3")
hist(xbar50, col="wheat4", freq = FALSE, breaks = 25, main="",
     xlim=c(164, 170), ylab="Densidade", xlab="Média para n=50",
     border="wheat4")
hist(xbar150, col="palegreen3",freq = FALSE, breaks = 25, main="",
     xlim=c(164, 170), ylab="Densidade", xlab="Média para n=150",
     border="palegreen3")
hist(var_amostral15, col="steelblue3", freq = FALSE, breaks = 25, main="",
     xlim=c(0, 50), ylab="Densidade", xlab="Variância para n=15",
     border="steelblue3")
hist(var_amostral50, col="wheat4", freq = FALSE, breaks = 25, main="",
     xlim=c(0, 50), ylab="Densidade", xlab="Variância para n=50",
     border="wheat4")
hist(var_amostral150, col="palegreen3", freq = FALSE, breaks = 25, main="",
     xlim=c(0, 50), ylab="Densidade", xlab="Variância para n=150",
     border="palegreen3")
```

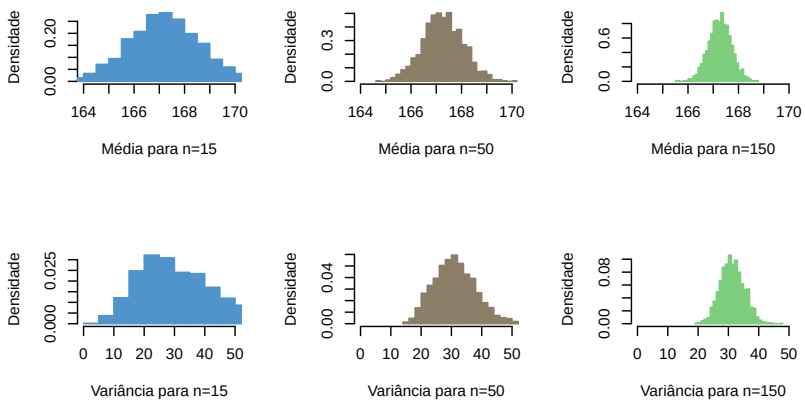

Figure 31: Distribuição amostral da média para diferentes tamanos amostrais

Vamos agora calcular as médias para cada uma das variáveis que criamos. Ou seja, vamos fazer a $E(\overline{X})$

```
# Vamos fazer a media das medias calculadas para 15, 50 e 150 com
  # 2 mil rodadas de amostragem
mean(xbar15)
```

```
[1] 167.2225
```

```
mean(xbar50)
```

```
[1] 167.2655
```

```
mean(xbar150)
```

```
[1] 167.2655
```

Observe que todas ficaram muito próximas da verdadeira esperança da população, mostrando empiricamente o teorema apresentado. Pode-se verificar também a variância amostral $Var(\overline{X}) = \frac{\sigma^2}{n}$. Vejamos:

```r
# Vamos fazer a variância das médias calculadas para 15, 50 e 150 com
  # 2 mil rodadas de amostragem
var(xbar15)
```

```
[1] 2.109824
```

```r
var(xbar50)
```

```
[1] 0.6291623
```

```r
var(xbar150)
```

```
[1] 0.2030213
```

Percebemos que a partir que o tamanho amostral vai aumentando o resultado vai convergindo para $Var(\overline{X}) = \frac{\sigma^2}{n}$, lembre-se que $\sigma^2 = 25$ para a simulação feita.

Importante ressaltar que esse resultado para a distribuição da média, ou seja $\overline{X}$ é valido para qualquer distribuição de X. Veja o caso abaixo onde temos X que possui uma distribuiçõ χ^2 com 3 graus de liberdade.

```r
# Distribuição amostral da média quando X tem dist Chi-Quadrado.
# Simulando uma distribuição chiquadrado
x_chisq<-rchisq(100000,df=3)

#Inicializando as variaveis como vetores numericos
## Media e variancia para amostras de tam 15
x_chi4<-numeric()
## Media e variancia para amostras de tam 300
x_chi30<-numeric()
## Media e variancia para amostras de tam 1000
x_chi1000<-numeric()

for ( i in 1:2000){
  smp<-sample(x_chisq,size = 4)
  x_chi4[i]<-mean(x_chisq[smp])

  smp<-sample(x_chisq,size = 30)
  x_chi30[i]<-mean(x_chisq[smp])
```

```r
  smp<-sample(x_chisq,size = 1000)
  x_chi1000[i]<-mean(x_chisq[smp])

}

##  Figura
par(mfrow=c(1,4))
hist(x_chisq, col="gray", border="gray",freq = FALSE, main="",
     ylab="Densidade de X", xlab="x")
hist(x_chi4, col="steelblue3", freq = FALSE, breaks = 20, main="",
      ylab="Densidade Média", xlab="Média para n=4",
     border="steelblue3")
hist(x_chi30, col="wheat4", freq = FALSE, breaks = 20, main="",
      ylab="Densidade Média", xlab="Média para n=30",
     border="wheat4")
hist(x_chi1000, col="palegreen3", freq = FALSE, breaks = 20, main="",
      ylab="Densidade Média", xlab="Média para n=300",
     border="palegreen3")
```

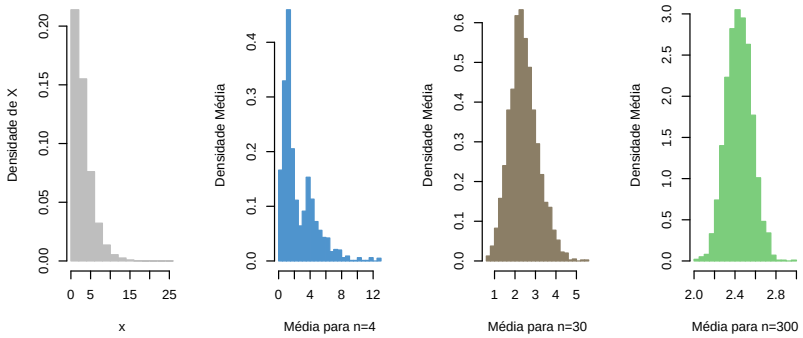

Figure 32: Distribuição amostral da média para diferentes tamanos amostrais

Podemos observar na figura acima que X é bastante assimétrico. Para o primeiro gráfico tiramos amostra de tamanho 4 e perceba que ainda é assimétrica, mas a partir do momento que vamos aumentando o tamanho da amostra, a distribuição de $\overline{X}$ vai ficando mais próxima de uma normal.

11.7 Distribuição Amostral da Variância

A Variância Amostral também é uma variável aleatória. Os gráficos anteriores mostram a distribuição de $Var(X_i)$ para diferentes tamanhos amostrais. Importante notar que calculamos na seção anterior também $Var(\overline{X})$ com base nos valores de média obtidos na simulação. A $Var(X_i)$ é uma candidata a ser uma boa aproximação para σ^2, ou seja, variância populacional. Assim:

Definição

A variância amostral:

$$Variância: \ S^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \overline{X})^2$$

possui distribuição χ^2 se X possui distribuição normal.

Para n grande podemos aproximar a χ^2 por uma distribuição normal. Olhe os gráficos de variância amostrais acima. Observe que para n=15 a distribuição de $Var(X_i)$ é assimétrica e parece uma χ^2, com o aumento da amostra vamos caminhando para uma distribuição normal.

11.8 Distribuição amostral da proporção

Considere uma amostra $X_1, X_2, ..., X_n$ que assume os valores:

$x_i = 1$: sucesso

$x_i = 0$: fracasso

para $i = 1, 2..., n$.

Seja p a probabilidade de sucesso. Então a proporção amostral pode ser calculada como:

$$\hat{p} = \frac{\sum_{i=1}^{n} X_i}{n}$$

Seja $Y = \sum_{i=1}^{n} X_i$. Então Y possui distribuição Binomial com parâmetros $E(Y) = n.p$ e $Var(Y) = np(1-p)$.

Então, as caracteriticas da proporção, $\hat{p}$, será :

$$E(\hat{p}) = \frac{np}{n} = p$$

$$Var(\hat{p}) = \frac{1}{n^2}np(1-p) = \frac{p(1-p)}{n}$$

Para n grande a distribuição de $\hat{p}$ é aproximadamente Normal (pela aproximação da binomial pela Normal).

12 Modos de Convergência

Gostariamos de saber se uma sequência de variáveis aleatórias $X_1, X_2, ..., X_n$ caminha ou converge na direção de X. Assim, suponha que queiramos saber o valor de X, fazemos uma medida via X_1, podemos aumentar o número de medidas para X_2 e observamos se chega mais próximo de X, e constinuamos até X_n e vemos se essa sequencia de medidas vai convergindo para X.Veremos aqui 3 tipos de convergência.

1. Convergência em probabilidade
2. Convergência em Média Quadratica
3. Convergência em Distribuição

12.1 Convergência de uma sequência numérica

Definição

Convergência:
Uma sequência de números reais $\{\alpha_i\}$ $i = 1, 2, .., n$ converge para um número real α se para qualquer $\varepsilon > 0$ existe um inteiro N onde para todo $n > N$ tem-se:

$$|\alpha_n - \alpha| < \varepsilon$$

Assim:

$\alpha_n \to \alpha$ quando $n \to \infty$ ou

$lim_{n\to\infty}\alpha_n = \alpha$

No caso de variáveis aleatórias, como só podemos falar de probabilidade, a definição anterior de convergência não é válida.

12.2 Convergência em Distribuição e o Teorema do Limite Central.

É forma mais fraca de convergência, dizemos que a fda de X_n converge para a fda de X. Formalmente:

Definição

Convergência em Distribuição
Uma sequência de v.a. $\{X_i\}$ $i = 1, 2, .., n$ converge para X em distribuição se a função de distribuição acumulada F_{X_n} de X_i converge para a f.d.a. F_X de X em cada ponto da F. Em outras palavras:

$X_n \xrightarrow{d} X$ ou

$\lim_{n\to\infty} F_{X_n}(x) = F_X(x)$ é a distribuição limite de X_n.

12.2.1 Teorema do Limite Central (TLC): Aplicação da Convergência em Distribuição.

12.2.1.1 Teorema do Limite Central

Um dos resultados mais importantes em estatística e que afirma que a soma de um grande número de variáveis aleatórias possui distribuição normal. Suponha uma sequência $X_1, X_2, ..., X_n$ a qual possui a mesma distribuição de X. A média $\overline{X}$, que é uma soma de variáveis aleatórias, possui $E(\overline{X}) = \mu$ e a variância $Var(\overline{X}) = \frac{\sigma^2}{n}$. Podemos normalizar a variável aleatória $\overline{X}$, ou seja Z_n:

$$Z_n = \frac{\overline{X}_n - E(\overline{X}_n)}{\sqrt{Var(\overline{X}_n)}}$$

Dessa forma podemos fazer a seguinte definição:

Definição

Teorema do Limite Central
Seja $X_1, X_2, ..., X_n$ uma sequência de variáveis aleatórias com $E(X_i) = \mu$ e $Var(X_i) = \sigma^2$. A variável $\overline{X}$ normalizada:

$$Z_n = \frac{\overline{X}_n - E(\overline{X}_n)}{\sqrt{Var(\overline{X}_n)}} = \frac{X_1 + X_2 +, ... + X_n - n\mu}{\frac{\sigma}{\sqrt{n}}}$$

converge em distribuição para uma normal padrão quando n vai para o infinito, assim: $\lim_{n\to\infty} P(Z_n \leq x) = \Phi(x)$ para to $x \in \mathbb{R}$
Portanto,

$$Z_n \xrightarrow{d} N(0,1)$$

Assim, temos a distribuição assintótica de Z_n (a qual se aproxima quando n é grande), será:

$$Z_n \overset{a}{\sim} N(0,1)$$

Isso implica que a distribuição assintótica da sequência $\overline{X}_n$ é:

$$\overline{X}_n \overset{a}{\sim} N(E(\overline{X_n}), Var(\overline{X_n}))$$

12.2.1.2 Aproximação Normal da Binomial

Recordando, uma variável com distribuição Binomial X é a soma de v.a. Bernoulli iid $\{Y_i\}$ tal que $X = \sum Y_i$. Sendo que $Y_i = 1$ com probabilidade p e $Y_i = 0$ com probabilidade $(1-p)$.

$\hat{p} = \frac{X}{n}$

Assim, se as condições do TLC são satisfeitas, com $E(Y_i) = p$, $Var(Y_i) = (1-p)p$ e $\hat{p} = \frac{X}{n}$ então:

$$\frac{\frac{X}{n} - p}{\sqrt{(1-p)p/n}} \xrightarrow{d} N(0,1)$$

Assim:

$$\frac{X}{n} \overset{a}{\sim} N(p, pq/n)$$

Ou:

$$X \overset{a}{\sim} N(np, npq)$$

12.3 Convergência em Probabilidade e a Lei dos Grandes Números

É um modo de convergência mais forte do que a convergência em distribuição, muitas vezes chamada de convergência estocástica. Vejamos a definição:

Definição

Convergência em Probabilidade:
Uma sequência de v.a. $X_1, X_2, , ..., X_n$ converge em probabilidade para uma v.a. X, ou seja,

$X_n \xrightarrow{p} X$ quando $n \to \infty$, se:

$lim_{n\to\infty} P(|X_n - X| \geq \varepsilon) = 0$ ou

$plim_{n\to\infty} X_n = X$

12.3.1 A Lei dos Grandes Números (LGN): Aplicação da Convergência em Probabilidade

12.3.1.1 Lei Fraca dos Grandes Números

A Lei dos Grandes Números é o Teorema que descreve o resultado de um experimento realizado um grande número de vezes. A Lei Fraca será nosso foco, pois é bem menos restritiva em termos de convergência, ou seja, exige uma convergência mais fraca e é suficiente para os problemas econométricos que veremos a frente.

Definição

Lei Fraca dos Grandes Números
Dada uma sequência da v.a. X_i e $\overline{X}_n = \frac{1}{n}\sum X_i$, a Lei Fraca Dos Grandes Números coloca que $\overline{X}_n - E(\overline{X}_n)$ converge para 0 em probabilidade. Portanto:

$\overline{X}_n - E(\overline{X}_n) \xrightarrow{p} 0$
ou
$\overline{X}_n \xrightarrow{p} E(\overline{X}_n) = \mu$

Assim temos o seguinte teorema

Teorema

Seja uma sequência $X_1, X_2, ..., X_n$ iid com $E(X_i) = \mu$ e $Var(X_i) = \sigma^2$. Então:
$\overline{X_n} \xrightarrow{p} \mu$ quando \$n $\to \infty$\$.

Prova:
Utilizando a desigualdade de Tchebycheff:

$P(|\overline{X} - \mu| < \varepsilon) \geq 1 - \frac{\sigma^2}{\varepsilon^2 n}$

$lim_{n\to\infty} P(|\overline{X} - \mu| < \varepsilon) = 1$
ou

$lim_{n\to\infty} P(|\overline{X} - \mu| \geq \varepsilon) = 0$

Portanto:

$\overline{X} \xrightarrow{P} \mu$
ou
$plim\overline{X} = \mu$

Em palavras:

O significado de X_n convirgir para μ, é que com uma amostra cada vez maior existe uma probabilidade muito alta de que a média ds observações esteja próxima do verdadeiro par6ametro populacional, ou seja, a esperança.

12.3.1.2 Lei Forte dos Grandes Números

Uma maneira mais forte de convergência é dada pela convergência "quase certa". Não veremos ela aqui e daremos uma ideia apenas da existência da Lei Forte dos Grande Números. Podemos representar essa convergência por:

$\overline{X_n} \overset{a.s.}{\to} \mu$ quando $n \to \infty$

Podemos definir a convergência quase certa da seguinte maneira:

Definição

Lei Forte dos Grandes Números
$P(lim_{n\to\infty}\overline{X_n} = \mu) = 1$

Ou seja, a Lei forte coloca que X_n converge para μ com probabilidade igual a 1. Aqui é a probabilidade do limite e antes o limite da probabilidade! Assim, a média da amostra converge quase certamente para o valor esperado.

É um tipo de convergência pouco utilizado na Econometria. Vejamos em palavras a diferença entre as duas para um n grande

1. **Lei Fraca:** $\overline{X}_n$ está próximo de μ e portanto $|\overline{X}_n - \mu| > \varepsilon$ pode existir mas não é frequente
2. **Lei Forte:** $|\overline{X}_n - \mu| < \varepsilon$ para todo n

12.4 Convergência em Média Quadrática

É um tipo de convergência mais forte que a de probabilidade e de distribuição.

Definição

Convergência em Média Quadrática
Uma sequência de v.a. $X_1, X2, ..., X_n$ converge para X em média quadrática se:

$$lim_{n\to\infty}E(X_n - X)^2 = 0$$

Tal que:
$X_n \overset{M}{\to} X$

12.5 Relação entre as convergências

Existe uma relação de implicação ou relacionamento entre os diversos tipos de convergência. Esse relacionamento é apresentado no teorema abaixo.

Teorema

$X_n \xrightarrow{M} X \Rightarrow X_n \xrightarrow{P} X$
$X_n \xrightarrow{p} X \Rightarrow X_n \xrightarrow{d} X$
O que implica:
$X_n \xrightarrow{M} X \Rightarrow X_n \xrightarrow{p} X \Rightarrow X_n \xrightarrow{d} X$

Teorema

Seja X_n um vetor de v.a. com númerp finito de elementos. Seja g uma função contínua e α um vetor constante. Então:
$X_n \xrightarrow{P} \alpha \Rightarrow g(X_n) \xrightarrow{P} g(\alpha)$

13 Determinação do tamanho da amostra

Iremos considerar aqui apenas a técnica de amostrage alatatória simples. Nosso objetivo é dar a intuição do processo de amostragem e não ensinar a fazer design de pesquisa de campo. Existem disciplinas específicas para isso.

Duas medidas importantes a serem consideradas.

1. Distância Máxima tolerável entre a estimativa e o parâmetro real: d
2. A probabilidade de que d seja maior que o tolerável: α

13.1 Tamanho da amostra com σ conhecido

Considere a desigualdade de Tchebycheff:

$$P(|\overline{X} - \mu| \leq \varepsilon) \geq 1 - \frac{\sigma^2}{\varepsilon^2 n}$$

Considerando $\varepsilon = d$, $\frac{\sigma^2}{\varepsilon^2 n} = \alpha$ e trabalhando no limite inferior tolerável (na igualdade):

$$P(|\overline{X} - \mu| \leq d) = 1 - \alpha$$

$$P(-d \leq \overline{X} - \mu \leq d) = 1 - \alpha$$

$$P(-\frac{d}{\sigma/\sqrt{n}} \leq Z \leq \frac{d}{\sigma/\sqrt{n}}) = 1 - \alpha$$

$$P(-\frac{d\sqrt{n}}{\sigma} \leq Z \leq \frac{d\sqrt{n}}{\sigma}) = 1 - \alpha$$

$$P(-Z_c \leq Z \leq Z_c) = 1 - \alpha$$

$$Z_c = \frac{\sqrt{n}d}{\sigma} \rightarrow n = \frac{\sigma^2 Z_c^2}{d^2}$$

onde n é o tamanho da amostra. Logo observa-se que o tamanho da amostra não tem relação com o tamanho da população. Se a população for altamente homogênea, a variância será pequena e o tamanho da amostra pequeno. Também depende do erro e da probabilidade de ficar acima do tolerável.

Exemplo

Uma pesquisa de satisfação foi feita com os funcionários de uma empresa. O índice vai de 0 a 100 e sabe-se que o desvio padrão é 30.
Qual o tamanho da amostra de entrevistados, considerando um nível de tolerância $d = 1,5$ unidades, com probabilidade $1 - \alpha = 92,81\%$?

Resposta: Na tabela da distribuição normal padrão:

$$1 - \alpha = 0,9281 \rightarrow Z_c = 1,8$$

Como d=1,5 então:

$$n = (\frac{1{,}8.30}{1{,}5})^2 \cong 1.296$$

13.2 Tamanho da amostra com população finita

Se a população for finita a independência entre os elementos X_i não é válida. Disto segue que:

$$Var(\overline{X}) = \frac{\sigma^2}{n}$$

é caso particular de:

$$Var(\overline{X}) = \sigma^2(\frac{1}{n} - \frac{1}{N})$$

Onde N é o tamanho populacional. Assim, para N finito e conhecido basta utilizar:

$$n' = \frac{n}{1+n/N}$$

Note que se n for muito menor que N então $n' \to n$ e

$$Var(\overline{X}) = \sigma^2(\frac{1}{n} - \frac{1}{N}) \to \frac{\sigma^2}{n}$$

Ou seja, converge para a amostragem anterior para população infinita.

13.3 Tamanho da amostra com σ desconhecido: média amostral

Como não temos σ temos que fazer uma amostra piloto com n_1 elementos e estimar o desvio padrão da seguinte maneira:

$$S_1 = \sqrt{\frac{\sum(X_i - \overline{X})^2}{n-1}}$$

Assim pode-se calcular:

$$n = \frac{S_1^2 Zc^2}{d^2}$$

Assim como temos já n_1 elementos agora podemos complementar até chegar a a n

13.4 Proporção populacional

Agora queremos garantir que:

$$P(|\hat{p} - p| \leq d) = 1 - \alpha$$

O tamanho da amostra será tal que:

$$n = \frac{Z_c^2}{d^2} p(1-p)$$

se não sabemos nada considerar $p = 0,5$, esse irá gerar a maior amostra para dado α e d

O exemplo no R:

Vejamos como ficaria o tamanho amostral para uma pesquisa eleitoral onde consideramos que $p = 0.4$, $1 - p = 0.6$, $1 - \alpha = 0,95$ e iremos considerar varios d, margem de erro. Ou seja, a primeira é dois pontos percentuais para mais ou menos, o segundo 1,5 pontos percentuais, o terceiro, 1 ponto e por fim 0,5 pontos percentuais. Vejamos o que essa mudança no que estamos ropensos a aceitar como margem de erro afeta o custo da pesquisa. Vimos que o valor por questionário era de R$53,00.

```
# Utilizando a tabela normal vimos que para alpha de 5% o
  #valor de Zc é 1,96, sendo p=0.4 e q=0.6

# para uma margem de erro de 2 pontos para cima e para
#baixo,tem-se
1.96^2*0.4*0.6/(0.02^2)  # Tamanho amostral
```

```
[1] 2304.96
```

```
(1.96^2*0.4*0.6/(0.02^2))*53 # Custo da pesquisa
```

```
[1] 122162.9
```

```
# para uma margem de erro de 1.5 pontos para cima e para
#baixo,tem-se
1.96^2*0.4*0.6/(0.015^2)  # Tamanho amostral
```

```
[1] 4097.707
```

```r
(1.96^2*0.4*0.6/(0.015^2))*53 # Custo da pesquisa
```

```
[1] 217178.5
```

```r
# para uma margem de erro de 1 pontos para cima e para
#baixo,tem-se
1.96^2*0.4*0.6/(0.01^2)  # Tamanho amostral
```

```
[1] 9219.84
```

```r
(1.96^2*0.4*0.6/(0.01^2))*53 # Custo da pesquisa
```

```
[1] 488651.5
```

```r
# para uma margem de erro de 1 pontos para cima e para
#baixo,tem-se
1.96^2*0.4*0.6/(0.005^2)  # Tamanho amostral
```

```
[1] 36879.36
```

```r
(1.96^2*0.4*0.6/(0.005^2))*53 # Custo da pesquisa
```

```
[1] 1954606
```

Notamos que para sairmos de uma margem de erro de 2 pontos para uma margem de erro de 0.5 pontos percentuais o custo sai de R$122 mil para quase R$ 2 milhões. O custo cresce de forma exponencial com o aumento da precisão.

14 Introdução: Estimação

Um dos esforços da estatística é propor técnicas para estimar caracaterísticas populacionais que auxiliem os tomadores de decisão a fazerem melhores escolhas. Se vamos fazer um programa para treinamento para mulheres desempregadas de baixa renda, precisamos saber qual a taxa de desemprego daquela população e assim propor um número de vagas adequado. Se queremos melhorar o sistema de logística de um entreposto, precisamos entender qual a intensidade de chegada de caminhões nesse entreposto. Se vamos fazer um programa de auxílio para pessoas em situaçao de extrema pobreza, precisamos saber quantas pessoas vivem nessa situação nessa localidade.

Notamos que para a maior parte das questões que temos sobre o mundo, raramente sabemos o que acontece na população. Temos que tentar construir um modelo que nos ajude nessa tarefa e nos de a segurança que as nossas estimativas da realidade sejam boas. Na inferência estatística existem dois objetivos principais.

- Estimação de parâmetros: valores populacionais
- Testes de hipótese sobre os parâmetros

Nosso objetivo aqui é estudar técnicas que nos permita avaliar se uma proposta de estimativa de uma caractaristica da população é “boa” e aprender técnicas para encontrar “boas” estimativas. Assim temos duas questões básicas surgem:

- Quais as características que um "bom" estimador possui?
- Como decidiremos que uma boa estimativa é "melhor" que outras?

Para saber se uma estimativa é boa ou não vamos introduzir duas ideias aqui, exatidão e precisão.

Dois conceitos importantes:

- **Exatidão**: proximidade de cada observação do valor do centro do alvo (nosso caso: parâmetro)
- **Precisão**: proximidade de cada observação em relação ao ponto médio de todas, variância.

A figura abaixo traz esses dois conceitos[9]:

[9] https://portalfisica.wordpress.com/2018/08/24/acuracia-precisao-e-exatidao/

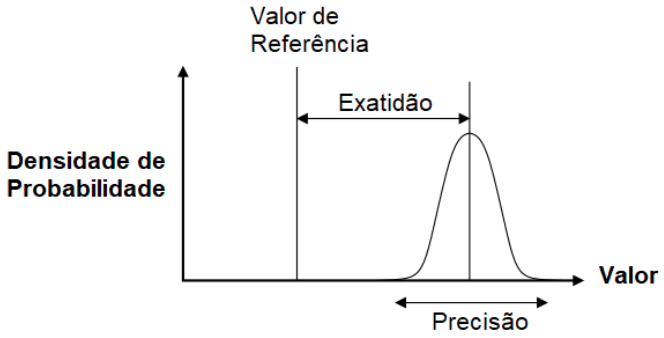

Figure 33: Exatidão e precisão

Uma outra forma de vermos o mesmo conceito é pelo exmplo clássico dos alvos. Vejamos a figura abaixo:

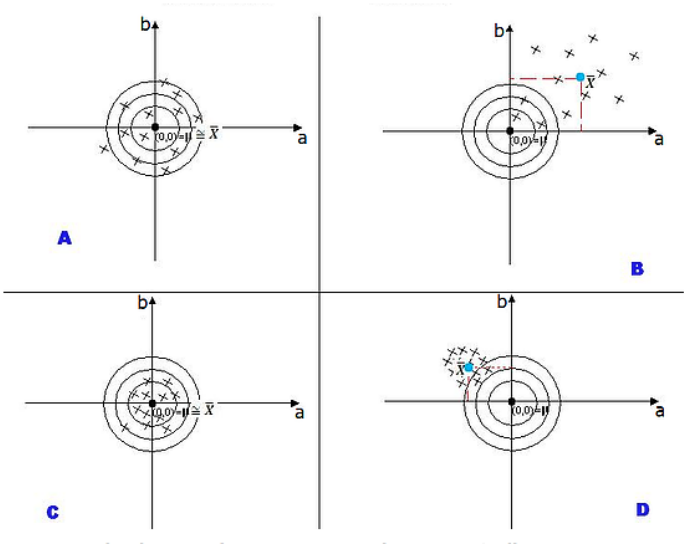

Figure 34: Alvo e os conceitos de Exatidão e precisão

Cada x no alvo representa uma tentativa sua de estimar o parâmetro de uma população que é o centro do alvo. A ideia seria que uma boa "arma" (arma aqui é a sua equação matemática) é aquela que acerta ao redor do centro do alvo e menos espelhado possível. Vejamos cada um desses alvos:

- **A**: Exato (média das tentativas está no centro do alvo.) Pouco Preciso (observações muito dispersas)
- **B**: Pouco Exato e Pouco Preciso
- **C**: Exato e Preciso
- **D**: Pouco Exato e Muito Preciso

Portanto, notamos que a melhor arma, ou seja, a melhor forma de estimar é pela "arma" C.

15 Estimadores e Estimação

Considere uma amostra $(X_1, ..., X_n)$ de uma variável aleatória X, sendo X_i variáveis aleatíras com a mesma distribuição de X e x_i os valores observados. Considere Θ um parâmetro populacional, podendo ser por exemplo: μ ou σ.

Definição

Um estimador T do parâmetro Θ é qualquer função das observações da amostra, tal que:

$$T = h(X_1, ..., X_n).$$

Portanto, cada estimador é uma estatística a qual associamos a um parâmetro. Assim temos uma segunda definição:

Definição

Uma Estimativa é o valor t que somente depende da amostra observada $x_1, x_2, ..., x_n$. OU seja, é uma função somento do banco de dados coletado:

$$**t = h(x_1, x_2, ..., x_n).**$$

Veja a situação apresentada abaixo. Sabe-se que temos o retorno de uma carteira dada por X que é uma variável aleatória. Sabe-se que a esperança do rerotno dessa carteira $(\mathbb{E}(X))$ que chamaremos de Θ é de 0. Encontramos duas maneiras de estimar esse retorno. Abaixo temos a distribuição de dois estimadores T_1 e T_2 do parâmetro Θ.

```r
#Distribuição de dois estimadores, T1 e T2,  para o parâmetro populacional
x<-seq(-5,7,0.1)
T1<-dnorm(x = x, mean = 3, sd=1)
T2<-dnorm(x = x, mean = 0, sd=1)

plot(x,T1,xlab="ti",type="l",main=NULL, col="steelblue3",lwd=2, ylab="f(ti)",
     xaxt="n",cex.axis=0.65, cex.lab=0.8 )
abline(v=0, col="black", lty=2)
par(new=TRUE)
plot(x,T2,xlab="", ylab="",type="l",col="wheat4",lwd=2,xaxt="n",
     cex.axis=0.65, cex.lab=0.8 )
axis(1,at=c(0),labels =c(expression(Theta)),cex.axis=0.65, cex.lab=0.8)
legend("topleft", legend=c("T1", "T2"),col=c("steelblue3", "wheat4"),
       lty=1:1, box.lty=0,cex=0.8)
```

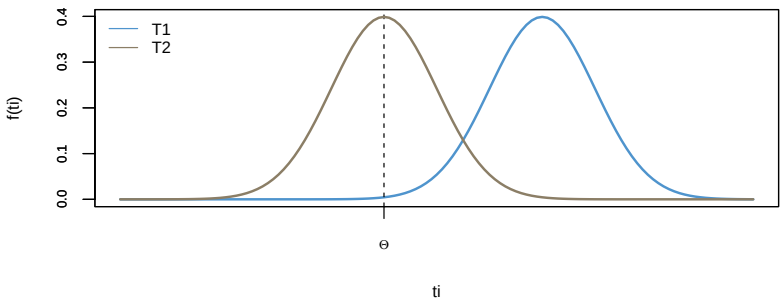

Figure 35: Função Distribuição de Probabilidade Normal e Função Distribuição Acumulada Normal

Questão

Definir uma função $T_i = h(X_1, ..., X_n)$ que seja próxima de Θ segundo algum critério. Ou seja, que acerte em média o parâmetro e que não seja muito dispersa!

16 Propriedades dos Estimadores

16.1 Tendenciosidade ou Viés

Suponha que estamos querendo estudar o desempenho dos alunos na Prova do ENEM, X, que vamos assumir que tenha distribuição normal com $\mathbb{E}(X) = 2000$ e $\sigma = 400$. Vamos observar 50 alunos que fizeram a prova em 2019 e estimar a esperança da nota utilizando a fórmula $\bar{X}$. Iremos repetir o processo de amostragem 100.000 vezes. Assim, vamos coletar 50 pessoas e fazer a média para essa amostragem, $\bar{X}_{50}$ e repetimos esse processo 100 mil vezes. Teremos portanto 100 mil médias. Vejamos a distribuição dessas médias feitas no R:

```
# Distribuição da nota dos alunos que fizeram ENEM, X.
x_normal<-rnorm(10000,mean=2000, sd= 400)

#Amostragem:
# Criando os vetores numéricos
xbar50<-numeric()
var_amostral50<-numeric()
# Extraindo 100 mil amostras de 50 alunos e fazendo a média para cada uma.
# Teremos 100.000 médias
for ( i in 1:100000){
  smp<-sample(x_normal,replace = TRUE,size = 50)
  xbar50[i]<-mean(x_normal[smp])
}

# Plotando as médias obtidas
hist(xbar50, col="steelblue3",freq = FALSE, breaks = 25,main="",
     xlim=c(1800, 2200), ylab="Dist. da média", xlab="médias para n=50",
     xaxt="n",border="steelblue3")
abline(v=2000, col="black", lty=2)
text(2000, 0.0003, expression(Theta))
axis(1,at=c(1800, mean(xbar50), 2200),labels =c(1800, round(mean(xbar50)),
    2200),cex.axis=0.65, cex.lab=0.8)
```

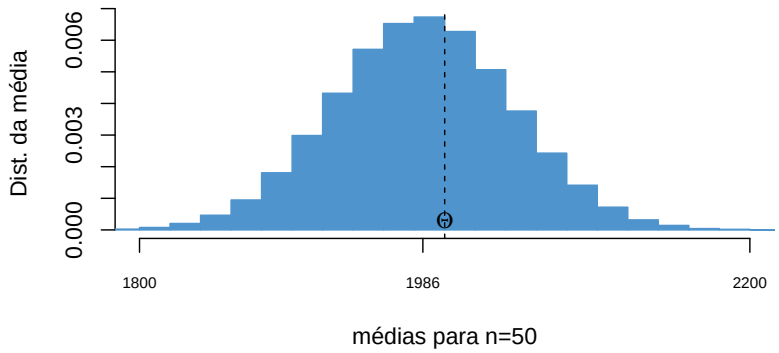

Figure 36: Distribuição do estimador da Esperança da Nota do ENEM

Observa-se que neste caso o valor númerico central representa $\mathbb{E}(\bar{X})$ e a linha pontilhada mostra $\mathbb{E}(X) = 2000 = \Theta$. Ainda pode-se observar que encontramos diversos valores para $\bar{X}$, variando de 1800 a 2200, mas com grande concentração ao redor de 2000.

Com base na figura 3 que apresenta dois estimadores e na figura 4 que mostra o resultado para uma estimativa da Esperança, temos a seguinte definição:

Definição

O estimador T é chamado de estimador **não-viesado**, ou não-tendencioso, para o parâmetro Θ se:

$$**\mathbb{E}(T) = \Theta** \text{ para todo } **\Theta** \backslash$$

Independente do valor de Θ, sendo a diferença $\mathbb{E}(T) - \Theta$ chamada de viés de T. Se a diferença é diferente de 0, T é viesado.

16.1.1 Estimadores não viesados para Esperança e Variância populacional.

Considere uma população com N elementos e com a esperança populacional de uma população de tamanho N:

$$\mu = \frac{1}{N} \sum_{j=1}^{N} X_j$$

Um bom estimador para a Esperança populacional seria a média, "copiando" a formulação populacional e consierando n o tamanho da amostra, ou seja:

$$\bar{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$$

Observe que ele é um estimador não visesado pois

$$\mathbb{E}(\bar{X}) = \frac{1}{n}\mathbb{E}[X_1 + X_2 + ... + X_n]$$

$$\mathbb{E}(\bar{X}) = \frac{1}{n}[\mathbb{E}(X_1) + \mathbb{E}(X_2) + ... + \mathbb{E}(X_n)]$$

$$\mathbb{E}(\bar{X}) = \frac{1}{n}[\mu + \mu + ... + \mu] = \frac{1}{n}n\mu = \mu$$

Da mesma forma podemos utilizar o princípio de "copiar" para achar um estimador ($\hat{\sigma}^2$) para a variância populacional σ^2, assim:

$$\sigma^2 = \frac{1}{N}\sum_{i=1}^{N}(X_i - \mu)^2$$

E um possível estimador para σ^2 (observe que colocamos um chapéu sobre *sigma*) será:

$$\hat{\sigma}^2 = \frac{1}{n}\sum_{i=1}^{n}(X_i - \overline{X})^2$$

Entretanto, tal estimador é viesado pois:

$$\sum_{i=1}^{N}(X_i - \overline{X})^2 = \sum_{i=1}^{N}(X_i - \mu + \mu - \overline{X})^2 = \sum_{i=1}^{N}((X_i - \mu) - (\overline{X} - \mu))^2$$

$$= \sum_{i=1}^{N}(X_i - \mu)^2 - 2\sum_{i=1}^{N}(X_i - \mu)(\overline{X} - \mu) + \sum_{i=1}^{N}(\overline{X} - \mu)^2$$

Note que $(\overline{X} - \mu)$ é constante. Então dado que:

$$\sum_{i=1}^{N}(X_i - \mu) = \sum_{i=1}^{N} X_i - n\mu$$

$$\overline{X} = \frac{1}{n}\sum_{i=1}^{N} X_i$$

Temos que:

$$n\overline{X} = \sum_{i=1}^{n} X_i \rightarrow \sum_{i=1}^{n}(X_i - \mu) = n(\overline{X} - \mu)$$

Logo:

$$
\begin{aligned}
\sum_{i=1}^{n}(X_i - \overline{X})^2 &= \sum_{i=1}^{n}(X_i - \mu + \mu - \overline{X})^2 \\
&= \sum_{i=1}^{N}(X_i - \mu)^2 - 2n(\overline{X} - \mu)^2 + n(\overline{X} - \mu)^2 \qquad (1) \\
&= \sum_{i=1}^{N}(X_i - \mu)^2 - n(\overline{X} - \mu)^2
\end{aligned}
$$

Assim:

$$
\begin{aligned}
\mathbb{E}(\hat{\sigma}^2) \quad &= E[\tfrac{1}{n}\{\textstyle\sum_{i=1}^{n}(X_i - \mu)^2 - n(\overline{X} - \mu)^2\}] \\
&= \tfrac{1}{n}\{\textstyle\sum_{i=1}^{n} E(X_i - \mu)^2 - nE(\overline{X} - \mu)^2\} \\
&= \tfrac{1}{n}\{\textstyle\sum_{i=1}^{n} Var(X_i) - nVar(\overline{X})\}
\end{aligned}
$$

Como $Var(X_i) = \sigma^2$ e $Var(\overline{X}) = \sigma^2/n$:

$$
\begin{aligned}
\mathbb{E}(\hat{\sigma}^2) &= \tfrac{1}{n}\{\textstyle\sum_{i=1}^{n} \sigma^2 - n\frac{\sigma^2}{n}\} \\
&= \sigma^2 - \tfrac{\sigma^2}{n} \\
&= \sigma^2 \tfrac{n-1}{n}
\end{aligned}
$$

Assim $\hat{\sigma^2}$ é um estimador viesado para o parâmetro σ^2 e o viés é dado por:

$$V = V(\hat{\sigma^2}) = E(\hat{\sigma^2}) - E(\sigma) = -\tfrac{\sigma^2}{n}$$

Como V é negativo estamos subestimando o verdadeiro valor do parâmetro. Entretanto, o viés diminui com n:

Quando $n \to \infty$ temos que $V \to 0$

Para obter o melhor estimador não-viesado do parâmetro σ^2 basta considerar

$$S^2 = \tfrac{n}{n-1}\hat{\sigma}^2$$

$$\therefore \mathbb{E}(\tfrac{n}{n-1}\hat{\sigma}^2) = \tfrac{n}{n-1}\mathbb{E}(\hat{\sigma}^2) = \tfrac{n}{n-1}\tfrac{n-1}{n}\sigma^2 = \sigma^2$$

Definimos:

$$S^2 = \frac{n}{n-1}\hat{\sigma}^2 = \frac{n}{n-1}\frac{1}{n}\sum_{i=1}^{n}(X_i - \overline{X})^2$$

$$S^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \overline{X})^2$$

Onde:

$$E(S^2) = \sigma^2$$

S^2 é um estimador não-viesado

16.2 Eficiência

Agora temos a seguinte situação, dado dois estimadores não viesados, como escolher qual dos dois seria melhor? Vejamos a situação abaixo:

```
# Vamos estudar a nota do ENEM.
x_normal<-rnorm(10000,mean=2000, sd= 400)

# Criando os vetores numéricos
xbar50<-numeric()
med50<-numeric()
# Extraindo duas mil amostras de 15 e fazendo a média e
# variância. Teremos 2000 médias e 2000 variâncias
for ( i in 1:100000){
  smp<-sample(x_normal,replace = TRUE, size = 50)
  xbar50[i]<-mean(x_normal[smp])
  med50[i]<-median(x_normal[smp])
}
par(mfrow=c(1,2))
hist(xbar50, col="steelblue3",freq = FALSE, breaks = 25,main="",
     xlim=c(1800, 2200), ylab="Densidade", xlab="Média para n=50",xaxt="n",
     border="steelblue3")
abline(v=2000, col="black", lty=2)
axis(1,at=c(1800, mean(xbar50), 2200),labels =c(1800, round(mean(xbar50)),
    2200),cex.axis=0.65)
text(2000, 0.0003, expression(Theta))
hist(med50, col="steelblue3",freq = FALSE, breaks = 25,main="",
     xlim=c(1800, 2200), ylab="Densidade", xlab="Mediana para n=50",xaxt="n",
     border="steelblue3")
abline(v=2000, col="black", lty=2)
axis(1,at=c(1800, mean(xbar50), 2200),labels =c(1800, round(mean(xbar50)),
```

```
    2200),cex.axis=0.65)
text(2000, 0.0003, expression(Theta))
```

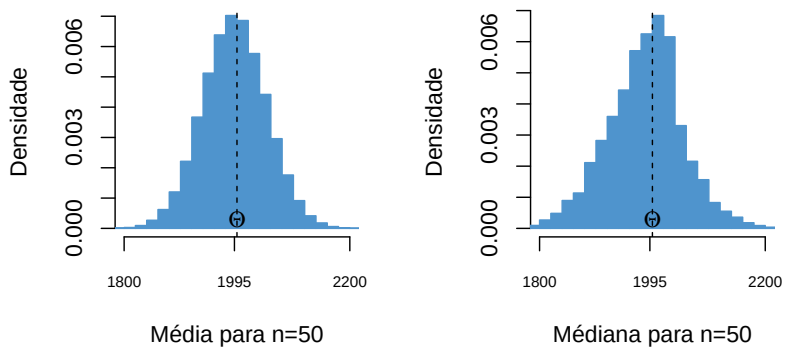

Figure 37: Distribuição de dois estimadores não viesádos para a Esperança da População , média e mediana

A figura 5 mostra a distribuição de dois estimadores da esperança populacional das notas do ENEN, a média e a mediana. Observa-se que elas não são viesadas. Qual das duas seria a melhor? Poderia utilizar as duas?

Visualmente notamos que a precisão do gráfico do estimador que utiliza a mediana amostral é maior do que a do gráfico do estimador que uriliza a méia amostral. Matematicamente temos o seguinte:

$$Var(\hat{md}) = \pi\frac{\sigma^2}{n} > \frac{\sigma^2}{n} = Var(\bar{X})$$

$\bar{X}$ tem menor variância e é melhor a partir deste critério. Assim, a média acerta o alvo como a mediana, entretanto a dispersão é menor para média, ou seja, maior precisão. O estimador da esperança que utiliza a média é exato e mais preciso do que o estimador que utiliza a mediana e portanto é preferível!

Em termos práticos, estimadores mais precisos ou eficientes, geram estimativas que tem maior chance de estarem perto do verdadeiro parâmetro. Veja o gráfico que para a média a chance de obtermos valores ao redor de 2.200 é muito baixo e apresenta-se maior na mediana.

Definição

Sejam T_1 e T_2 são dois estimadores não-viesados de um mesmo parâmetro Θ. Dizemos que T_1 é mais eficiente do que o estimador T_2 se

$$Var(T_1) < Var(T_2)$$

16.3 Erro quadrático médio

A performance de um estimador deve ser avaliada principalmente pela maneira que se dispersa ao redor do parâmetro Θ a ser estimado. Considere o erro amostral:

$$e = T - \Theta$$

Esse é o erro que cometemos ao estimar o parâmetro Θ da distribuição da v.a. X pelo estimador T baseado em uma amostra

Definição

Sendo T o estimador do parâmetro populacional $Theta$, então o Erro Quadrático Médio (EQM) do estimador T será:

$$EQM(T;\Theta) = E(e^2) = E(T-\Theta)^2$$

Desenvolvendo:

$$\begin{aligned} EQM(T;\Theta) &= E(e^2) = E(T-\Theta)^2 \\ &= E(T-E(T))^2 + E(E(T)-\Theta)^2 \\ &= Var(T) + V^2 \end{aligned}$$

Sendo $Var(T)$ a variância do estimador e V^2 o viés ao quadrado. Dessa forma, se conseguirmos encontrar o estimador que possui o menor EQM, esse será o estimador que reduz viés e variância. Muitas vezes buscamos em uma família de estimadores consistentes aqueles que possuem o menor EQM.

O gráfico apresenta o EQM da média e da mediana ao estimar a esperança da nota do ENEM. Observe que o EQM da mediana é maior, distribuição com mais peso a direita, ou seja, a chance de erros maiores é maior ao utilizar a mediana como estimador. Por isso preferimos a média.

```
# Vamos estudar a nota do ENEM.
x_normal<-rnorm(10000,mean=2000, sd= 400)

# Criando os vetores numéricos
xbar50<-numeric()
med50<-numeric()
e50<-numeric()
e50md<-numeric()
# Extraindo duas mil amostras de 15 e fazendo a média e
# variância. Teremos 2000 médias e 2000 variâncias
for ( i in 1:100000){
  smp<-sample(x_normal,replace = TRUE,size = 50)
  xbar50[i]<-mean(x_normal[smp])
  e50[i]<-(xbar50[i]-2000)^2
  med50[i]<-median(x_normal[smp])
  e50md[i]<-(med50[i]-2000)^2
}

hist(e50md, col="wheat4",freq = FALSE, breaks = 120,main="",
     xlim=c(0, 15000), ylab="Densidade do EQM", xlab="EQM",
     border="wheat4")

par(new=TRUE)
hist(e50, col="steelblue3",freq = FALSE, breaks = 120,main="",xaxt="n",
     yaxt="n", xlim=c(0, 15000), ylab="Densidade do EQM", xlab="EQM",
     border="steelblue3")
legend("topright", legend=c("EQM- mediana", "EQM - média"),col=c("wheat4",
      "steelblue3"), lty=1:1, box.lty=0,cex=0.8)
```

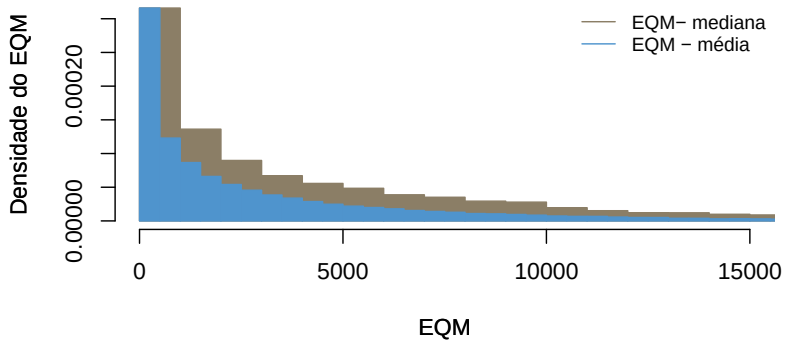

Figure 38: Erro Quadrático Médio de dois estimadores não viesádos para a Esperança da População , média e mediana

16.4 Consistência

A consistência é uma propriedade que surge quando o tamanho amostral cresce, ou seja, quando $n \to \infty$. Essa é uma propriedade importante para um estimador, pois deve convergir para o verdadeiro parâmetro quando a quantidade de informação aumenta, ou seja, maior tamanho amostral.

Podemos calcular $\overline{X}$ para diversos tamanho de amostra, obtemos uma sequência de estimadores $\overline{X}_n$ para n=1,2,.... Quando n cresce e a distribuição de $\overline{X}_n$ torna-se mais concentrada ao redor da média real μ. Dessa forma, $\overline{X}_n$ é uma sequência consistende de estimadores de μ.

Veja o gráfico abaixo para amostra de tamanho 50, 500 e 1500.

```
# Voltamos a nota do ENEM.
x_normal<-rnorm(10000,mean=2000, sd= 400)
# Criando os vetores numéricos
xbar50<-numeric()
xbar500<-numeric()
xbar1500<-numeric()
# Extraindo duas mil amostras de 15 e fazendo a média e
# variância. Teremos 2000 médias e 2000 variâncias
for ( i in 1:50000){
  smp<-sample(x_normal,replace = TRUE, size = 50)
  xbar50[i]<-mean(x_normal[smp])
  smp1<-sample(x_normal,replace = TRUE,size = 500)
```

```
  xbar500[i]<-mean(x_normal[smp1])
  smp2<-sample(x_normal,replace = TRUE,size = 1500)
  xbar1500[i]<-mean(x_normal[smp2])
}
hist(xbar50, col="wheat4",freq = FALSE, breaks = 25,main="",
     xlim=c(1800, 2200), ylab="Densidade da Média", xlab="Média de X",
     border="wheat4")
par(new=TRUE)
hist(xbar500, col="steelblue3",freq = FALSE, breaks = 25,main="",xaxt="n",
     yaxt="n", xlim=c(1800, 2200), ylab="", xlab="", border="steelblue3")
par(new=TRUE)
hist(xbar1500, col="gray",freq = FALSE, breaks = 25,main="",xaxt="n",
     yaxt="n", xlim=c(1800, 2200), ylab="", xlab="",border="gray")
text(2000, 0.0008, expression(mu))
legend("topright", legend=c("Amostra","n=50","n=500","n=1500"),col=c("white",
      "wheat4","steelblue3","gray"), lty=1:1, box.lty=0,cex=0.8)
```

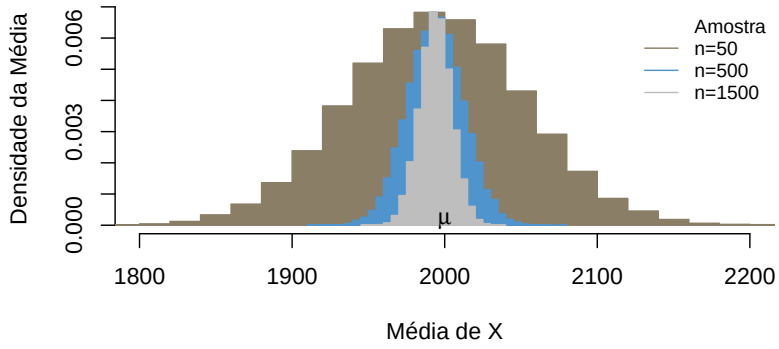

Figure 39: Consistência do estimador não viesados para a Esperança da População , média

Observe que ao aumentar o tamanho amostral a distribuição vai se concentrando ao redor do parâmetro populacional. Ou seja, $\bar{X}$ é consistente. Assim tem-se a seguinte definição:

Definição

Uma sequência $\{T_n\}$ de estimadores de um parâmetro Θ é consistente se para todo $\varepsilon > 0$:

$$P\{|T_n - \Theta| > \varepsilon\} \to 0, n \to \infty$$

Para o caso específico da média $\bar{X}$, tem-se:

$$P\{|\bar{X} - \mu| > \varepsilon\} \to 0, n \to \infty$$

Dessa forma temos o seguinte Teorema:

Teorema

Considerando a desigualdade de Tchebycheff, tem-se:

$$P\{|T_n - \Theta| < \varepsilon\} \geq 1 - \frac{\sigma^2}{\varepsilon^2 n}$$

Dessa forma sequência $\{T_n\}$ de estimadores de um parâmetro Θ é consistente se:

$$lim_{n\to\infty} P\{|T_n - \Theta| < \varepsilon\} = 1$$

Podemos ainda escrever:

$$\text{plim} T_n = \Theta$$

$$T_n \xrightarrow{p} \Theta$$

A prova desse teorema foi vista na seção anterior quando apresentamos a Lei dos Grandes Números. Uma maneira mais direta para testar a consistência do estimador pode-se utilizar o seguinte resultado:

Proposição

Uma sequência $\{T_n\}$ de estimadores de um parâmetro Θ é consistente se:

$$lim_{n\to\infty} E(T_n) = \Theta$$

$$lim_{n\to\infty} Var(T_n) = 0$$

Exemplo

Seja S^2 um estimador não viesado, sendo, $E(S^2) = \sigma^2$. Se X tiver uma distribuição Normal $\sim N(\mu, \sigma^2)$ e $X_1, ..., X_n$ as n medições de X, então:

$$Var(S^2) = \frac{2\sigma^4}{n-1}$$

e

$$lim_{n\to\infty} Var(S^2) = 0$$

Portanto, S^2 é um estimador consistente pois:

Exemplo

Para o caso do estimador incosistente $\hat{\sigma^2}$ da variância populacional onde $\mathbb{E}(\hat{\sigma^2}) = \sigma^2 - \frac{\sigma^2}{n}$, tem-se:

$$\mathbb{E}(\hat{\sigma^2}) = \hat{\sigma^2} - \frac{\hat{\sigma^2}}{n} \Rightarrow lim_{n\to\infty}\mathbb{E}(\hat{\sigma^2}) = \sigma^2$$

$$Var(\hat{\sigma^2}) = (\frac{n-1}{n})^2.Var(S^2) = \frac{(n-1)^2}{n^2}\frac{2\sigma^4}{n-1} = \frac{n-1}{n^2}2\sigma^4 \Rightarrow lim_{n\to\infty}Var(\hat{\sigma^2}) = 0$$

Portanto, $\hat{\sigma^2}$ é um estimador **consistente**

Esse resultado mostra o porque muitas vezes utilizamos os dois estimadores para estimar a variância populacional, pois para um n grande ambos são consistentes. Além disso, a variância de $\hat{\sigma}^2$ é menor.

17 Métodos de Estimação

Até agora "imitamos" o que acontece na população para a amostra com os estimadores $\overline{X}$ e S^2. Entretanto podemos ter modelos mais complexos e parâmetros populacionais que não conseguimos imitar o que acontece na população.

Vamos considerar que gostariamos de compreender os determinantes da renda de uma pessoa. Afinal, renda significa consumo e bem estar e gostariamos de saber porque tem pessoas que ganham mais e pessoas que ganham menos. Assim poderemos propor políticas públicas que sejam mais efetivas.

Com o passar do tempo e vários estudos os economistas perceberam que a educação é um fator importante para compreender a renda das pessoas.

Renda=h(Educação)

Ou seja, o salário é uma função da educação que recebemos. Veja o gráfico 1 abaixo entre o ln do PIB per capita e os anos médios de educação em diversos países do mundo[10].

```
#Pib per capita em ln e anos de estudos de diversos países em 2010
ln_salario<- c(9.16, 9.44, 9.67, 10.71, 10.61, 7.79, 9.55, 10.55, 8.87, 7.56,
               8.48, 9.51, 9.61, 7.75, 7.90, 10.60, 9.80, 9.14, 9.27, 9.40,
               7.80, 10.24, 10.17, 6.45, 10.68, 9.35, 9.12, 9.12, 8.72, 8.84,
               9.93, 10.54, 8.38, 8.90, 9.76, 9.14, 10.78, 10.46, 8.81, 10.51,
               9.14, 7.82,  7.80, 6.67, 10.97, 6.88, 9.79, 7.54, 10.04, 9.63,
               9.58, 8.77, 6.88, 8.14, 7.60, 10.69, 10.34, 8.29, 6.74, 11.20,
               8.34, 9.62, 8.83, 9.13, 8.59, 9.95, 10.16, 9.73, 9.99, 7.92,
               9.43, 7.06, 9.34, 10.36, 10.36, 9.03, 8.19, 8.86, 10.61, 10.93,
               8.65, 10.52, 9.43, 7.11, 10.22, 9.27, 9.79, 7.45, 10.46, 10.81,
               9.67, 9.70, 8.42, 7.96, 7.30)

educa<- c(10.44, 7, 9.71, 11.69, 10.13, 6.22, 9.57, 11.29, 9.63, 4.57, 8.57,
          8.17, 11.07, 4.94, 6.41, 12.74, 10.35, 8.25, 9.35, 8.43, 4.93, 11.76,
          12.8, 3.79, 11.97, 8.12, 8.02, 7.44, 8.06, 10.35, 10.71, 11.34, 3.92,
          12.58, 7.66, 11.36, 5.21, 5.17, 6.6, 12.2, 11.98, 11.48, 6.59, 8.02,
          9.15, 7.43, 12.45, 10.71, 10.33, 12.44, 10, 6.47, 6.08, 4.35, 11.33,
          5.01, 10.89, 2.14, 11.06, 9.44, 9.18, 5.27, 2.03, 5.11, 4.44, 11.71,
          11.12, 6.82, 1.95, 11.65, 5.19, 9.72, 7.99, 9.28, 8.65, 11.62, 8.71,
          11.08, 12.02, 3.11, 11.52, 4.28, 9.89, 12.96, 10.75, 10.67, 3.49,
          5.33, 11.95, 12.92, 7.07, 11.96, 8.47, 6.09, 10.96, 8, 7.44, 5.87,
          12.46, 13.24, 8.61, 8.78, 3.84, 7.4, 7.86)

bd = data.frame(ln_salario, educa)

plot(bd$educa, bd$ln_salario, xlab="Anos de Estudo",
     ylab="ln PIB pc ", pch=20, col="wheat4",ylim=c(5,12))
abline(lm(bd$ln_salario~bd$educa), col="steelblue3", lwd = 2)
```

[10]Extraídos de: Our World in Data

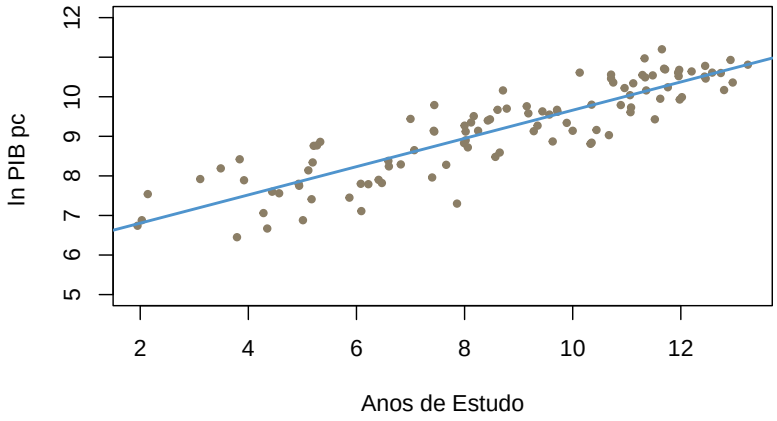

Figure 40: Anos de estudos e ln do PIB pc de diversos países em 2010

Observe que existe uma relação ascendente, ou seja, quanto maior a educação maior renda per capita. Entretanto, observa-se também uma imprecisão, ou algum componente aleatório que não nos permite determinar precisamente a renda dada a escolaridade. Para países com 10 anos de estudos as rendas variam mais ou menos entre 8,5 e 10,5. Dessa forma um possível modelo para tratarmos essa problema seria:

$$Renda = h(Educação) + flutuação\ aleatória$$

A questão é qual a função que descreveria essa relação entre escolaridade de rend? O que podemos assumir é que h é uma função crescente e parece razoável que possamos assumir uma função linear como representada pela linha vermelha. Podemos dizer que existe uma correlação entre renda e educação, ou seja, uma dependência linear. Um possível e mais comum modelo seria uma função linear que relaciona renda e educação e que considere as flutuações, ou seja:

$$Renda = \alpha + \beta.Educação + u_i$$

Essa é a linha de regressão sendo que α e β parâmetros populacionais. O parâmetro β representa a influência de um ano a mais de educação sobre a renda per capita e sendo $\mathbb{E}(u_i) = 0$ para $i = 1, ...n$

O que precisamos estimar é o parâmetro populacional β. Assim, deve existir uma estimador $\hat{\beta} = h(Y_i, X_j)$ que nos permitir estimar quanto que cada a ano a mais de educação poderia nos trazer a mais de renda. Diferentemente do que fizemos para Esperança, agora temos pouco ou nenhuma intuição do que seria a formulação de h.

Existem algumas maneiras para fazermos isso:

- Estimadores de Momentos
- Estimadores de Máxima Verossimilhança
- Mínimos Quadrados

Veremos duas delas Minimos Quadrados e Máxmia Verossimilhança.

17.1 Estimadores de Mínimos Quadrados

Iremos continuar como nosso exemplo anterior onde gostariamos de saber como cada ano a mais de educação poderia afetar a renda per capita. Primeiramente vamos considerar o gráfico anterior mas de uma forma mais didática. Considere a figura 2[11]:

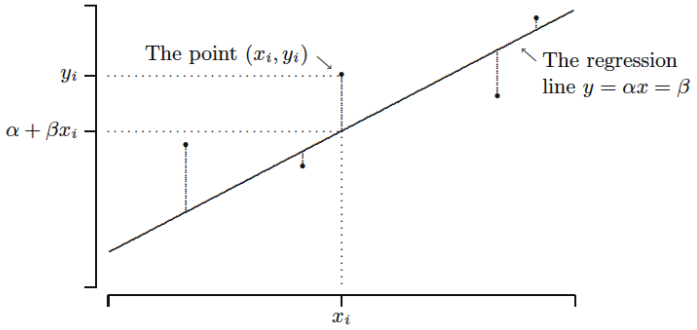

Figure 41: Valores observados e estimados para y

Temos que observar dois pontos importantes, o primeiro é que os pontos representam valores do par ordenado (x_i, y_i). A linha representa os valores estimados ou projetados de Y para dado valor de X, ou seja, $\hat{y}_i = \alpha + \beta.x_i$. Um bom estimador, ou seja, um bom α e β, deveria ser aquele que torne o menor possível essa distância entre observado y_i e estimado$\hat{y}_i$, ou seja, minimiza o erro que cometemos ao tentar estimar o valor observado. Nesse sentido, deve minimizar conjuntamente a distância dos pontos (observado) até a linha (estimado). Dessa forma, os erros podem ser assim descritos:

$$e = (y_i - \hat{y}_i) = (y_i - \alpha - \beta.x_i)$$

Como não é importante se os erros são positivos ou negativos, utilizamos aqui a minimização da soma dos erros ao quadrado. Para verem uma simulação sobre esse ajustamento ou minimização dos erros ao qudrado, acesse

[11] Dekking, F.M., et al. A Modern Introdution To Statistics

"https://phet.colorado.edu/en/simulation/least-squares-regression". Portanto devemos minimizar:

$$S(\alpha, \beta) = \sum_{i=1}^{n}(y_i - \hat{y}_i)^2 = \sum_{i=1}^{n}(y_i - \alpha - \beta.x_i)^2$$

Podemos entender essa minimização como o procedimento para encontrar os estimadores $\hat{\alpha}$ e $\hat{\beta}$ que gerem o menor erro quadrático médio. Ou seja, encontraremos os estimadores lineares que reduzem viés e variância.

Minimizando os erros ao quadrado e utilizando a regra da cadeia (considere $z = y_i - \alpha - \beta.x_i$:

$$\begin{aligned}
S(\alpha, \beta) = & \quad \textstyle\sum_{i=1}^{n}(y_i - \alpha - \beta.x_i)^2 \\
\tfrac{\partial S(\alpha,\beta)}{\partial \alpha} = & \quad 2\textstyle\sum(y_i - \hat{\alpha} - \hat{\beta}x_i)(-1) = 0 \\
0 = & \quad -\textstyle\sum y_i + n\hat{\alpha} + \hat{\beta}\sum x_i \\
\hat{\alpha} = & \quad \tfrac{\sum y_i - \hat{\beta}\sum x_i}{n} \\
\hat{\alpha} = & \quad \bar{y} - \hat{\beta}\bar{x}
\end{aligned}$$

Agora derivando em relação a β:

$$\begin{aligned}
\tfrac{\partial S(\alpha,\beta)}{\partial \beta} = & \quad 2\textstyle\sum(y_i - \hat{\alpha} - \hat{\beta}x_i)(-x_i) = 0 \\
0 = & \quad -2\textstyle\sum y_i x_i + 2\sum(x_i\bar{y} - x_i\hat{\beta}\bar{x}) + 2\hat{\beta}\sum x_i^2 \\
0 = & \quad -2\textstyle\sum y_i x_i + 2\bar{y}\sum x_i - 2\hat{\beta}\bar{x}\sum x_i + 2\hat{\beta}\sum x_i^2 \\
2\hat{\beta}(\textstyle\sum x_i^2 - \tfrac{\sum x_i}{n}\sum x_i) = & \quad 2(\textstyle\sum y_i x_i - \tfrac{\sum y_i}{n}\sum x_i) \\
\hat{\beta}(\tfrac{n\sum x_i^2 - (\sum x_i)^2}{n}) = & \quad \tfrac{n\sum y_i x_i - \sum y_i \sum x_i}{n} \\
\hat{\beta} = & \quad \tfrac{n\sum y_i x_i - \sum y_i \sum x_i}{n\sum x_i^2 - (\sum x_i)^2}
\end{aligned}$$

Podemos reescrever a equação acima como:

$$\hat{\beta} = \quad \frac{n\sum y_i x_i - \sum y_i \sum x_i}{n\sum x_i^2 - (\sum x_i)^2} = \frac{\sum(x_i - \bar{x})(\sum y_i - \bar{y})}{\sum(x_i - \bar{x})^2} = \frac{\sum y_i x_i - n\bar{y}\bar{x}}{\sum x_i^2 - n\bar{x}^2}$$

Dessa forma temos dois estimadores, do intercepto, $\hat{\alpha}$ e da inclinação $\hat{\beta}$ e eles representam os estimadores de mínimos qudrados para o modelo de regressão que estavamos discutindo!

Esse é o modelo padrão que iremos estudar em econometria. Entretanto, para fins didáticos podemos utilizar o modelo sem intercepto (ou em casos muito especiais em econometria), o princípio é o mesmo de minimização dos erros ao quadrado conforme derivação abaixo:

Resolvendo temos que:

$$\begin{aligned}
S(\beta) = & \sum_{i=1}^{n}(y_i - \beta.x_i)^2 \\
\frac{\partial S(\beta)}{\partial \beta} = & 2\sum(y_i - \hat{\beta}x_i)(-x_i) = 0 \\
0 = & 2(-\sum x_i y_i + \sum \hat{\beta} x_i^2) \\
\hat{\beta}\sum x_i^2 = & \sum x_i y_i \\
\hat{\beta}_{MQ} = & \frac{\sum x_i y_i}{\sum x_i^2}
\end{aligned}$$

Vamos utilizar os nossos dados apresentados acima e calcular no R o resultado. Faremos na força bruta e utilizando a rotina do programa. Veja abaixo:

```
# Fazendo na mão. Usando a equação que derivamos acima
B<-((sum(educa*ln_salario)-105*(mean(educa)*mean(ln_salario))))/
  ((sum(educa^2)-105*(mean(educa)^2)))
A<-mean(ln_salario-B*mean(educa))
B
```

```
[1] 0.3568401
```

```
A
```

```
[1] 6.092204
```

```
# Usando a rotina do R para Mínimos Quadrados
reg<-lm(ln_salario~educa)
reg
```

```
Call:
lm(formula = ln_salario ~ educa)
```

```
Coefficients:
(Intercept)        educa
     6.0922       0.3568
```

Observe que cada ano a mais de educação que um pais consegue, aumenta em 0.357 o ln da renda per capita. Mostrando que renda e educaçao estão correlacionado! Dessa forma, nossa equação para achar $\hat{Y}$ será:

$$\hat{Y} = \hat{\alpha} + \hat{\beta}.x$$

ou seja,

$$\hat{Y} = 6.092 + 0.357.x$$

Dessa forma um país que consiga atingir 10 anos de média de educação terá o ln da renda estimado em 9.66. Isso pode ser visto no gráfico acima. Um outro ponto que será estudo em econometria e a interpretação do coeficiente. Aqui somente deixamos a interpretação desse coeficiente e não entramos no detalhe da sua explicação. Como é um modelo com Y em ln e x em nível, modelo log-linear, deveremos fazer $exp(0.35) = 1,43$, isso implica que cada aumento de 1 ano de escolaridade média da população aumenta da renda do país em 43%. Importante que cada modelo, log-log, log-linear e linear-linear tem sua própria maneira de interpretar o coeficiente.

17.2 Estimador de Máxima Verossimilhança

17.2.1 Intuição:

Suponha que gostaríamos de saber qual seria uma boa estimativa da esperança da nota do IDEB nos município brasileiros para os primeiros anos do fundamental em 2017. Vamos coletar 500 municipios e vamos plotar o histograma conforme figura 3 abaixo.

```r
# Distribuição da nota dos alunos que fizeram ENEM, X.
smp<-sample(rnorm(5500,mean=5.6, sd= 1.0139),replace = TRUE,size = 500)

# Plotando as médias obtidas
hist(smp, col="steelblue3",freq = FALSE, breaks = 25,main="",
     xlim=c(0, 10), ylab="Dist. das notas IDEB", xlab="notas IDEB ",
     border="steelblue3")
```

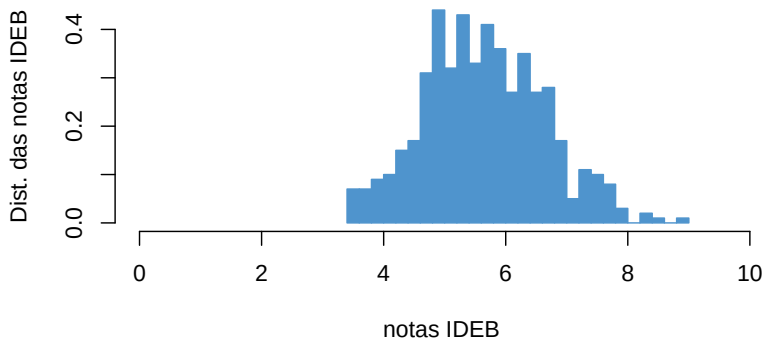

Figure 42: Distribuição da amostra das notas do IDEB 2017, para os primeiros anos do fundamental de 500 municípios

Esse são os dados que observamos, ou seja, uma amostra de 500 elementos onde temos $X_1, X_2, ..., X_{500}$ as 500 medições sendo que todas elas tem a mesma distribuição de e igual a de X, $f(x;\mu)$. O gráfico acima apresenta os valores observados das medições, $x_1, x_2, ..., x_{500}$. Dessa forma temos os valores observados mas não temos ideia de qual distribuição eles vieram, ou seja, de qual $f(x;\mu)$ esses dados foram extraídos.

Supondo que a distribuição populacional é uma normal e que temos os dados acima já observados, a questão é achar qual a fdp de X entre todas as possíveis (alterando o valor do parâmetro) que é a mais provável de ter gerado os dados que observamos.

Vejamos a simulação abaixo, figura 4, que considera os dados coletados e diversas distribuições normais para diferentes valores do parâmetro μ.

```
# Distribuição da nota dos alunos que fizeram ENEM, X.
smp<-sample(rnorm(5500,mean=5.6, sd= 1.0139),replace = TRUE,size = 500)

#Desvio padrão e diversas possibilidades de esperança:
sd<-1.0139
e1<-2.5
e2<-3.5
e3<-5.6
e4<-7.5

# Valores de x que vão de 0 até 10

x <- seq(0, 10, length = 1000)
```

```r
# Distribuição de probabilidade
y1 <- dnorm(x, e1, sd)
y2 <- dnorm(x, e2, sd)
y3 <- dnorm(x, e3, sd)
y4 <- dnorm(x, e4, sd)

# Plotando as médias obtidas
hist(smp, col="steelblue3",freq = FALSE, breaks = 25,main="",
     xlim=c(0, 10), ylim=c(0, 0.39), ylab="Dist. das notas IDEB",
     xlab="notas IDEB ",border="steelblue3")
par(new=TRUE)
plot(x, y1, type="n", xlab = "", ylab = "", axes = FALSE)
lines(x, y1, col="thistle4",lwd = 2)
abline(v=2.5, col="black", lty=2)
text(2.5, 0.03, expression(Theta[1]))
text(1.9, 0.39, expression(paste("f(x" , ";" ,Theta[1],")")))

par(new=TRUE)
plot(x, y2, type="n", xlab = "", ylab = "", axes = FALSE)
lines(x, y2, col="slategray4",lwd = 2)
abline(v=3.5, col="black", lty=2)
text(3.5, 0.03, expression(Theta[2]))
text(4.1, 0.39, expression(paste("f(x" , ";" ,Theta[2],")")))

par(new=TRUE)
plot(x, y3, type="n", xlab = "", ylab = "", axes = FALSE)
lines(x, y3, col="tomato4", lwd = 2)
abline(v=5.6, col="black", lty=2)
text(5.6, 0.03, expression(Theta[3]))
text(6.2, 0.39, expression(paste("f(x" , ";" ,Theta[3],")")))

par(new=TRUE)
plot(x, y4, type="n", xlab = "", ylab = "", axes = FALSE)
lines(x, y4, col="wheat4", lwd = 2)
abline(v=7.5, col="black", lty=2)
text(7.5, 0.03, expression(Theta[4]))
text(8.1, 0.39, expression(paste("f(x" , ";" ,Theta[4],")")))
```

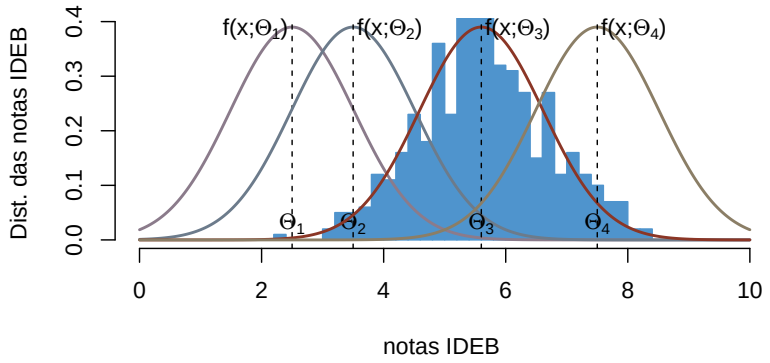

Figure 43: Distribuição da amostra das notas do IDEB 2017, e diversas possibilidades fdp do ideb populacional

Na figura acima observa-se em azul, o histograma das observações coletadas, ou seja, a amostra de 500 municípios. Foram simuladas diversas distribuições POPULACIONAIS normais cada uma com o mesmo valor de desvio padrão mas diversos valores para a esperança que chamamos de Θ. A questão que temos é qual seria a distribuição que torna mais provável termos tirado essa amostra? De qual distribuição $f(x;\Theta_1)$, $f(x;\Theta_2)$, $f(x;\Theta_3)$ ou $f(x;\Theta_4)$ essa amostra pode ter vindo?

Para resolver esse problema utilizamos a função de verossimilhança que representa a verossimilhança de um parâmetro Θ condicional aos valores observados. Dessa forma é função do parâmetro.

17.2.2 A Função de Verossimilhança

A **Função de Verossimilhança** L será:

$$L(\Theta|X_1,...,X_n) = f(x_1|\Theta)f(x_2|\Theta)...f(x_n|\Theta)$$

A função $L(\Theta|X_1,...,X_n)$ representa a verossimilhança do parâmetro Θ dado os valores observados x_i. Vamos fazer uma simulação para a função de verossimilhança para o problema anterior das nostas do IDEB. Consideraremos os 500 municipios amostradosx_i, vamos simular valores de Θ e considerar o $\sigma = 1$ por facilidade.

Haviamos suposto que as notas do IDEB dos município era normalmente distribuída com esperança μ e variância 1. Assim,

$$f(x) = \frac{1}{\sqrt{2\pi}} e^{-1/2(x-\mu)^2}$$

Dessa forma a Função de Verossimilhança será o produtório de normais:

$$L(\mu|x_1, ..., x_n) = \frac{1}{2\pi^{n/2}} exp[-1/2 \sum_i^n (x_i - \mu)^2]$$

Agora vamos simular diversos valores para os parâmetros populacionais e encontrar a função de verossimilhança, veja figura 5.

```
# amostra da nota dos alunos que fizeram ENEM, X. Valores da esperança
set.seed(149)
xi<-sample(rnorm(5500,mean=5.6, sd= 1),replace = TRUE,size = 500)
mu <- seq(0, 10, length = 1000)
L_mu<-numeric()

for ( i in 1:1000){
  for (j in 1:500 ){
  L_mu[i]<-(1/((2*pi)^(500/2)))*exp(-0.5*(sum((xi[j]-mu[i])^2)))
}}

plot(mu, L_mu, type="n", xlab = "Valores de Esperanças - E(X)" ,
     ylab = "Verossimilhança")
lines(mu, L_mu, col="wheat4", lwd = 3)
abline(v=5.6, col="black", lty=2)
text(5.5, 0.00, expression(mu))
```

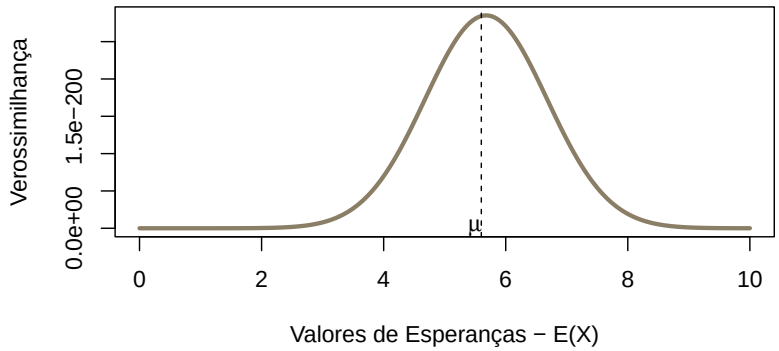

Figure 44: Simulação da Função de Verossimilhança

O que fizemos? Condicional a amostra que obtivemos simulamos diversos valores de $\mathbb{E}(X) = \mu$ e calculamos a função para cada um dos 1000 valores simulados do parâmetro populacional. Ou seja, obtivemos 1000 valores da função de verossimilhança que está plotada acima. Assim, essa função nos fornece a probabilidade de encontrarmos certo valor de parâmetro condicional aos valores observados de x_i. Observe que o ponto de máximo da função de verossimilhança está localizado bem próximo do verdadeiro parâmetro populacional.

A maximização da função de verossimilhança nos indicará qual a formulação do estimador que nos levará próximo ao parâmetro populacional como podemos observar na figura acima. Portanto, buscamos o

$$maxL(\hat{\Theta}|x_1, ..., x_n)$$

Esse será o estimador $\hat{\Theta}$ preferido pois aumenta a probabilidade de obter valores amostrais como $x_1, ..., x_n$. Agora estamos prontos para prosseguirmos de forma mais técnica.

Definição

O estimador MV Máxima de Verossimilhança de Θ, isso é, $\hat{\Theta}$ baseado em uma amostra aleatória $x_1, ...x_n$, é aquele que torna máxima

$$L(\Theta|x_1, ..., x_n)$$

$\rightarrow$ $\hat{\Theta}$ será uma estatística e portanto uma v.a.
$\rightarrow$ Θ pode ser um vetor quando possuímos mais de um parâmetro desconhecido. Por exemplo, $\Theta = (\mu, \sigma)$

Por facilidade computacional e evitar cálculos mais complexos utilizamos a função log-verossimilhança. Essa diminui bastante as exigências computacionais e o ln é uma função crescente, sendo que o máximo na função ln e sem ln serão os mesmos para Θ.

$$l(\Theta|x_1, ..., x_n) = lnL(\Theta|x_1, ..., x_n,)$$

Máximo:

$$\frac{\partial l(\Theta|x_1,...,x_n)}{\partial \Theta} = 0$$

Se temos $\Theta = (\mu, \sigma)$ teremos equações simultâneas:

$$\frac{\partial l(\mu,\sigma|x_1,...,x_n)}{\partial \mu} = 0$$

$$\frac{\partial l(\mu,\sigma|x_1,...,x_n)}{\partial \sigma} = 0$$

17.2.3 Propriedades dos Estimadores de M.V.:

1. Pode ser tendencioso mas pode ser corrigido pela multiplicação de uma constante apropriada
2. Sob condições gerais as estimativas de M.V. são consistentes, ou seja, assintoticamente não viesados e de variância mínima
3. Importante - **Propriedade de invariância**: Supoha que $\hat{\Theta}$ seja uma estimativa M.V. de Θ. Pode-se mostrar que uma estimativa M.V. de $g(\Theta)$ seja $g(\hat{\Theta})$, onde $g(.)$ é uma função monótona contínua. Exemplo: $m^2 = \hat{\Theta}$ ou $m = \sqrt{\hat{\Theta}}$

17.2.4 Exemplos

Vejamos dois exemplos que pode nos ajudar a fixar o conceito.

Exemplo

Considere a distribuição de uma variável T com parâmetro β:

$$f(t) = \beta e^{-\beta t}, t \geq 0$$

Suponha n componentes tal que:

$$L(\beta|t_1, ..., t_n) = f(t_1, \beta)f(t_2, \beta)...f(t_n, \beta)$$

$$= \beta e^{-\beta T_1}...\beta e^{-\beta T_n}$$

$$= \beta^n e^{-\beta \sum T_i}$$

Aplicando o log:

$$lnL(\beta|t_1, ..., t_n) = l(\beta|t_1, ..., t_n) = n.ln\beta - \beta \sum T_i$$

Temos o máximo:

$$\frac{\partial l(.)}{\partial \beta} = \frac{n}{\beta} - \sum T_i = 0$$

$$\frac{n}{\beta} = \sum T_i$$

$$\overline{T} = \frac{1}{\beta}$$

Exemplo

Suponha-se que a variável aleatória X seja normalmente distribuída com esperança μ e variância 1.

$$f(x) = \frac{1}{\sqrt{2\pi}} e^{-1/2(x-\mu)^2}$$

Encontrando o estimador do parâmetro μ. Se $(X_1, ..., X_n)$ uma amostra aleatórida da v.a. X a FMV será:

$$L(\mu|x_1, ..., x_n) = \frac{1}{2\pi^{n/2}} exp[-1/2 \sum_i^n (x_i - \mu)^2]$$

Aplicando o log:

$$l(\mu|x_1, ..., x_n) = ln1 - \frac{\mu}{2} ln2\pi - \frac{1}{2} \sum_i^n (X_i - \mu)^2$$

O ponto de máximo será:

$$\frac{\partial l(.)}{\partial \mu} = \frac{\partial l(.)}{\partial z} \frac{\partial z}{\partial \mu}$$

$$= -\frac{2}{2} \sum_i^n (x_i - \mu)(-1) = 0$$

$$\sum_i^n (x_i - \mu) = 0 \Rightarrow \sum_i^n x_i - n\mu = 0$$

$$\hat{\mu} = \overline{X}$$

17.3 Máxima Verossimilhança e Minimos Quadrados

Como já visto anteriormente supondo $X_1, ...X_n$ fixo e $Y_1, ..., Y_n$ uma variável aleatória, no nosso exemplo X seria educação e Y o ln da renda per capita, por exemplo. Podemos escrever a relação entre renda e educação como:

$$Renda = \alpha + \beta.Educação + u_i$$

ou

$$Y = \alpha + \beta.X + u_i$$

Sendo que $u_i \sim N(0, \sigma^2)$. Considerando os estimadores dos parâmetro populacionais podemos reescrever os erros como sendo:

$$e_i = Y - \hat{\alpha} - \hat{\beta}.X$$

Dessa forma o erro nos indica a diferença entre o salário estimado e o salário observado. Considerando e equação dos residuos e sabendo que $e_i \sim N(0, \sigma^2)$ e assumindo que $X_1, ..., X_n$ fixos. Podemos montar a função de verossimilhança:

$$L(\alpha, \beta, \sigma^2 | Y_1, ..., Y_n) = \frac{1}{(2\pi)^{n/2}\sigma^n} exp[\frac{-1}{(2\sigma^2)} \sum_i^n (e_i - \mu_{e_i})^2]$$

Portanto,

$$L(\alpha, \beta, \sigma^2 | Y_1, ..., Y_n) = \frac{1}{(2\pi)^{n/2}\sigma^n} exp[\frac{-1}{(2\sigma^2)} \sum_i^n (Y_i - \hat{\alpha} - \hat{\beta}.X_i)^2]$$

Como temos o exponencial de um número negativo maximizar $L(\alpha, \beta, \sigma^2 | Y_1, ..., Y_n)$ é equivalente e minimizar a seguinte parte da função de verossimilhança:

$$S = \sum_i^n (Y_i - \hat{\alpha} - \hat{\beta}.X_i)^2$$

Que nada mais é do que minimizar os erros ao quadrados que vimos na seção de estimadores de mínimos quadrados. Portanto, podemos dizer que estimadores de mínimos quadrados são equivalentes aos estimadores de verossimilhança.Ou mais, que mínimos quadrados é um caso especial de máxima verossimilhançaa onde Y e X são linearmente relacionados e existe um erro $e_i \sim N(0, \sigma^2)$.

18 Estimação de Intervalo

18.1 Introdução

Até agora encontramos estatística ou estimadores que geram boas estatimativas de características da função de distribuição populacional, ou seja dos parâmetros. Dessa forma, encontramos estimadores T de θ que são não viesados, eficiêntes e consistêntes.

Entretanto, nunca temos certeza que a estatística é igual ao parâmetro populacional, se precisamos de um valor esse é o que devemos escolher. Este é um valor sacado da distribuição do estimador. Nos exemplos anteriores observamos que ao mudar a amostra mudamos o valor da estimativa. Cada novo processo de amostragem, irá gerar um novo valor para nossa estimativa.

Dada essa incerteza de sabermos se nossa estimativa está próxima do verdadeiro parâmetro populacional, gostariamos de poder dizer que "temos uma grande confiança de que o parâmetro populacional está dentro de certo intervalo". Precisamos definir mais precisamente o que é uma grande confiança e definir a construição do intervalo.

18.2 Intervalo de confiança: Procedimento Geral

De forma geral podemos definir um intervalo em termos de variabilidade ao redor da estimativa. Logo podemos utilizar o desvio padrão do nosso estimador para fazer isso. Assim o procedimento geral será:

$$IC(\theta) = (t - c.\sigma_T; t + c.\sigma_T)$$

Aqui temos nossa estimativa t e somamos e subtraímos $c.\sigma_T$, sendo c um número real podendo ser 2 ou 3, entre outros. A intuição desse princípio é similar ao que estudamos com relação a distribuição normal, que a quantidade de informação que está entre 1 desvio padrão abaixo e acima é de 68,26%, entre 2 desvios 95,44% e entre 3 desvios 99,73%.

Uma definição geral pode ser assim feita:

Definição

Intervalo de Confiança: Seja a amostra aleatória de tamanho n e $X_1, ..., X_n$ as n medições da variável aleatóri X e $x_1, ..., x_n$ os valores observados. Sendo θ o parâmetro de interesse e γ um número entre 0 e 1. Se existirem duas estatística amostrais $L_n = g(X_1, ..., X_n)$ e $U_n = h(X_1, ..., X_n)$, tal que:

$$P(L_n < \theta < U_n) = \gamma$$

Então,

$$l_n = g(x_1, ...,_n), u_n = h(x_1, ..., x_n)$$

é chamado de intervalo de confiança para θ com γ% de nível de confiança.

Podemos definir l_n e u_n de forma similar ao que fizemos no início da seção em termos de desvio padrão. Vamos ver o caso da média quando temos variância conhecida e desconhecida.

18.3 Para dados com Distribuição Normal: a média

Partimos aqui da distribuição de $\bar{X}$ que como já vimos possui uma distribuição normal, $N(\mu, \sigma^2_{\bar{X}})$ ou $N(\mu, \frac{\sigma^2}{n})$. Assumindo aqui que conhecemos σ^2 e que encontramos com facilidade os valores críticos da distribuição normal padrão, z_c. Temos que:

$$Z_{\bar{X}} = \frac{\bar{X} - \mu}{\sigma_{\bar{X}}}$$

Tem distribuição normal padrão $N(0, 1)$. Dessa forma podemos definir:

$$P(-z_c < Z_{\bar{X}} < z_c) = \gamma$$

ou

$$P(|Z_{\bar{X}}| < z_c) = \gamma$$

Se γ for, por exemplo, 95% teremos a seguinte situação apresentada na figura 1, $P(|Z_{\bar{X}}| < 1.96) = 0.95$:

```
x<-seq(-3,3,0.1)
fdnorm<-dnorm(x = x, mean = 0, sd=1)
fdanorm<-pnorm(q = x, mean = 0, sd=1)
regiao=seq(-3,-1.96,0.01)
cord.x <- c(-3,regiao,-1.96)
cord.y <- c(0,dnorm(regiao),0)
regiao=seq(1.96,3,0.01)
cord.z <- c(1.96,regiao,3)
cord.w <- c(0,dnorm(regiao),0)

curve(dnorm(x,0,1),xlim=c(-3,3),main='f.d.p',xlab="z",type="l",
      col="darkblue",lwd=2, ylab="f(z)",cex.axis=0.65, cex.lab=0.8 )
polygon(cord.x,cord.y,col='wheat4')
polygon(cord.z,cord.w,col='wheat4')
text(0, 0.2, expression(paste(gamma , "=" ,95, "%")))
text(2.5, 0.1, expression(paste("(1-", gamma , ")/2" , "=",
                                alpha, "/2", "=2.5", "%")))
text(-2.5, 0.1, expression(paste("(1-", gamma , ")/2" , "=",
                                 alpha, "/2", "=2.5", "%")))
```

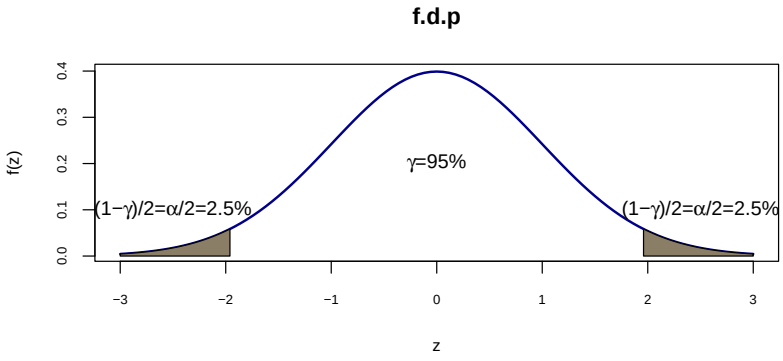

Figure 45: Intervalo de confiança para Normal com nível de confiança de 0.95

Assim, temos no exemplo $\gamma = 0.95$ e $\alpha = 1 - \gamma$. Como visto, data a simetria da distribuição dividimos α igualmente entre as duas caldas da distribuição, ou seja, $\frac{\alpha}{2} = 0.025$. De uma maneira genérica podemos proceder da seguinte maneira:

$$P(|Z_{\bar{X}}| < z_c) = \gamma$$

$$P(|\frac{\bar{X}-\mu}{\sigma_{\bar{X}}}| < z_c) = \gamma$$

$$P(|\bar{X} - \mu| < z_c\sigma_{\bar{X}}) = \gamma$$

$$P(-z_c\sigma_{\bar{X}} < \bar{X} - \mu < z_c\sigma_{\bar{X}}) = \gamma$$

$$P(\bar{X} - z_c\sigma_{\bar{X}} < \mu < \bar{X} + z_c\sigma_{\bar{X}}) = \gamma$$

Assim, a probabilidade da esperança populacional μ estar entre o intervalo $\bar{X} \pm z_c\sigma_{\bar{X}}$ é igual γ.

Sabendo que $\sigma_{\bar{X}} = \frac{\sigma}{\sqrt{n}}$, que dividiremos o nível de confiança nas duas caldas da distribuição, $z_{\frac{\alpha}{2}}$ podemos definir L_n e U_n para os diversos níveis de confiança como:

$$L_n = \bar{X} - z_{\frac{\alpha}{2}}\frac{\sigma}{\sqrt{n}} \quad \text{e} \quad U_n = \bar{X} + z_{\frac{\alpha}{2}}\frac{\sigma}{\sqrt{n}}$$

Dessa forma, pode-se achar a estimativa do intervalo de confiança para o parâmetro μ com nível de confiança de γ, ou $1 - \alpha$, da seguinte maneira:

$$IC(\mu; \gamma) = \left(\bar{x} - z_{\frac{\alpha}{2}}\frac{\sigma}{\sqrt{n}}; \bar{x} + z_{\frac{\alpha}{2}}\frac{\sigma}{\sqrt{n}}\right)$$

Para o exemplo com $\gamma = 95\%$ e portanto, $\alpha = 0.05$, tem-se que $z_{0.025} = 1.96$ e o seguinte intervalo para 95% de confiança:

$$IC(\mu; 0.95) = \left(\bar{x} - 1.96\frac{\sigma}{\sqrt{n}}; \bar{x} + 1.96\frac{\sigma}{\sqrt{n}}\right)$$

A interpretação do intervalo de confiança é que se fizessemos 100 intervalos de confiança, 95% deles conteriam o verdadeiro parâmetro populacional. Ou seja, a propabilidade da esperança populacional estar no intervalo descrito acima é de 0.95 A figura abaixo retirada de Bussab e Morettin, representa o que estamos fazendo:

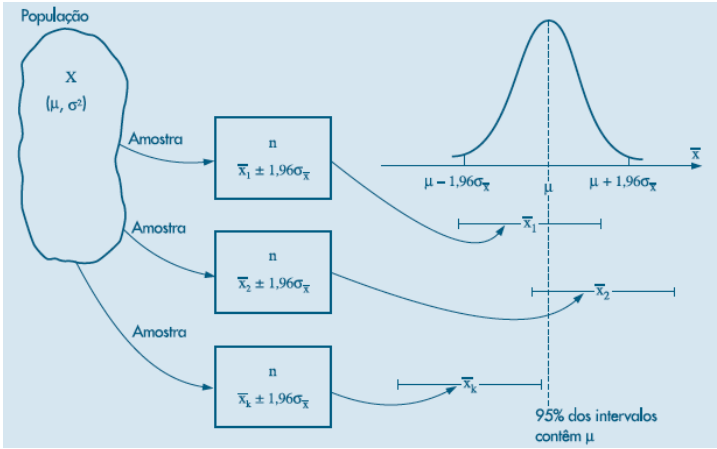

Figure 46: Intervalo de Confiança para a Esperança

Para construir a estimativa do intervalo utilizamos a estatística calculada e abrimos um intervalo a direita, que chamamos de $U_n = \bar{x} - z_{\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}}$ e outro a esquerda que chamamos $L_n = \bar{x} + z_{\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}}$. No exemplo, perceba que utilizamos praticamente dois desvios da média para cima e para baixo do valor calculado ($\alpha = 0.05$). Com isso esperamos que a maior parte dos dados estejam dentro desse intervalo, e principalmente que a confiança nos indique quantos intervalos conterão o verdadeiro parâmetro populacional, o qual está no centro da distribuição da média.

Para solidificar essa ideia, simulamos abaixo a distribuição da estatística $f(\bar{X})$, que veio de um processo de amostragem aleatória de X, ou seja, $X_1, ..., X_n$. Considerando Leis dos Grandes Números e Teorema do Limite Central sabemos que $\bar{X} \sim N(\mu, \frac{\sigma^2}{n})$ Especificamente sabemos aqui que $\bar{X} \sim N(50.000, 1.000^2)$.

Foram feitas 50 repetições do processo de amostragem (foi retirado 50 valores de forma aleatória da distribuição da média) e calculado para cada um o intervalo de confiança, conforme visto acima, U_n e L_n.A parte superior da figura apresenta a distribuição da média $f(\bar{X})$ e a parte inferior mostra os 50 intervalos de confiança. Vejamos a simulação abaixo feita no R e baseadas em Grosse, P.[12].

```
#Simulando um conjunto de 50 médias que vem de uma normal com
#Esperança igual a 50.000. Logo distribuição da média será
# Assumimos 1000 como o desvio padrão da média
library(dplyr)
library(magrittr)
library(ggplot2)
library(ggpubr)
```

[12]https://rpubs.com/pgrosse/545955

```r
meanset <- rnorm(50,50000,1000)
meanset <- as.data.frame(meanset)
colnames(meanset) <- "Mean"

##Calculando as bandas superiorees e inferiores L e U -
#zc*DP(média) = 1960

meanset95 <- meanset %>% mutate(u = Mean + 1960) %>% mutate(l = Mean - 1960)

Sample <- seq(1,50,1)
Sample <- as.data.frame(Sample)
ci95 <- cbind(Sample, meanset95)

# Determinando se um intervalo captura o verdadeiro valor
ci95 <- ci95 %>% mutate(Capture = ifelse(l < 50000,
                                         ifelse(u > 50000, 1, 0), 0))
ci95$Capture <- factor(ci95$Capture, levels = c(0,1))

# Gerando o Gráfico dos diversos Intervalos

# Distribuição da média
colorset = c('0'='red','1'='black')

ci_plot_95 <- ci95 %>% ggplot(aes(x = Sample, y = Mean)) +
  geom_point(aes(color = Capture)) +
  geom_errorbar(aes(ymin = l, ymax = u, color = Capture)) +
  scale_color_manual(values = colorset) + coord_flip() +
  geom_hline(yintercept = 50000, linetype = "dashed", color = "blue")+
  geom_hline(yintercept = 51960, linetype = "dashed", color = "blue")+
  geom_hline(yintercept = 48040, linetype = "dashed", color = "blue")+
  labs(title = ) + theme(plot.title =
  element_text(hjust = 0.5)) + ylim(45000,55000)+
  theme(legend.position="bottom")+ labs(y = "Média", x= "Amostra")

dist_med <- ggplot(data = data.frame(x = c(45000, 55000)), aes(x)) +
  stat_function(fun = dnorm, n = 101, args = list(mean = 50000, sd = 1000)) +
  ylab("") + scale_y_continuous(breaks = NULL)+
  geom_vline(xintercept = 51960, linetype = "dashed", color = "blue")+
  geom_vline(xintercept = 48040, linetype = "dashed", color = "blue")+
   labs(y = expression(paste("f(", "x"[média], ")")), x=element_blank())
```

```r
ggarrange(dist_med, ci_plot_95, heights = c(2, 5),
          ncol = 1, nrow = 2, align = "v")
```

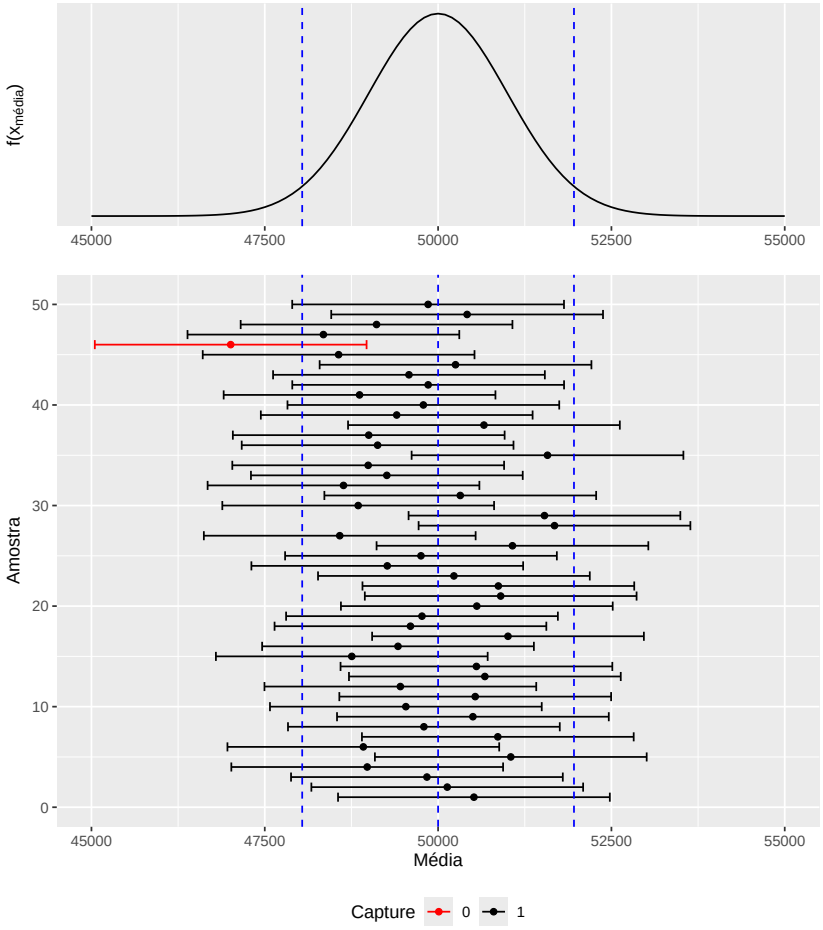

Figure 47: 50 Intervalos de confiança de 0.95

As linhas em azul representam o intervalo do nível de confiança, ou seja, $\gamma = 0.95$ para a distribuição da média. As barras em preto são intervalos que contêm a verdadeira média e os intervalos em vermelho são aqueles que não contêm a verdadeira média. Perceba que em poucos casos isso ocorre, apenas para os casos onde a estimativa pontual da média sai fora da

linha azul. Isso acontece em apenas 5% das vezes, afinal garantimos isso quanto escolhemos o z_c para o nível de confiança desejado.

Dessa forma, observe que para níveis de confiança menores, a linha azul estará mais próximo a média e portanto mais valores de intervalos não conterão o parâmetro populacional, pois agora utilizamos um z_c mais próximo da média, o qual produzirá intervalos de amplitudes menores. Com isso, encontraremos mais intervalos que não contêm o parâmetro populacional. Vejamos o gráfico abaixo:

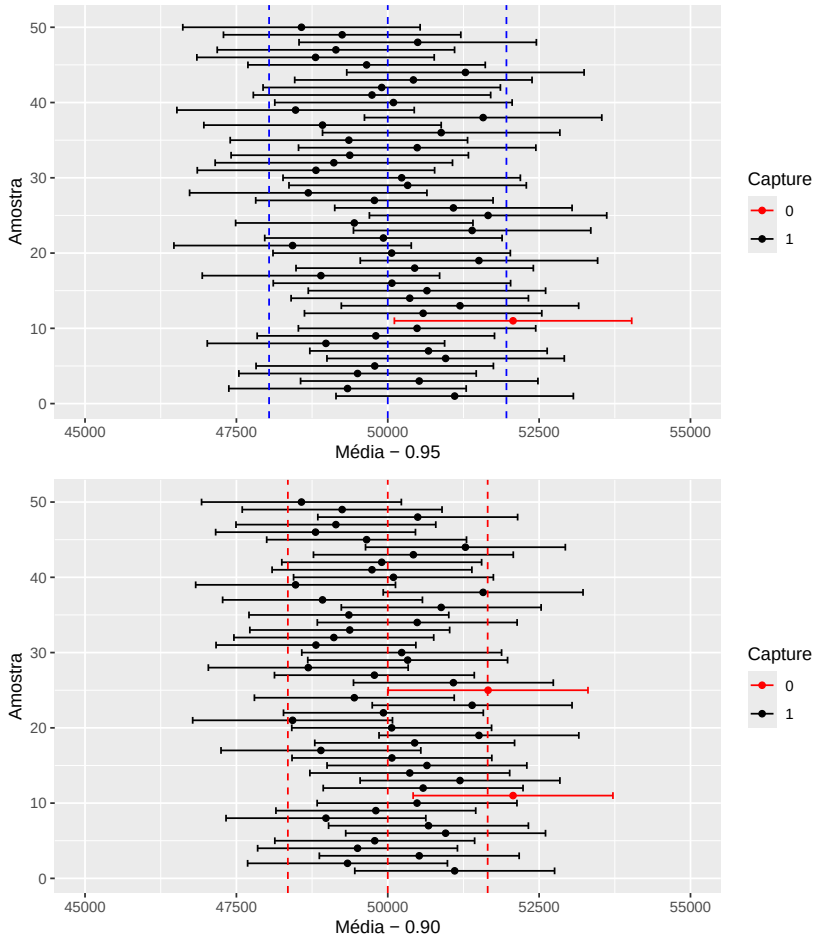

Figure 48: Comparando Intervalos de confiança de 0.90 e 0.95

A linha azul representa o intervalo para 0.95 de confiança e a linha vermelha o intervalo para 0.90 de confiança, esses representam a amplitude do intervalo aplicados para $\bar{X} = \mu$ pra cada nível de confiança. Essa amplitude é replicadanas demais estimativas. Observe que temos barras de amplitude menores no gráfico inferior (0.90) e isso implica que temos uma quantidade maior de intervalos que não contêm o parâmetro populacional (em vermelho).

Logo, a chance de você construir um intervalo e esse não conter o verdadeiro parâmetro é maior para níveis menores de confiança.

Vejamos agora uma aplicação desse resultado.

Exemplo

Temos uma máquina de empacotar café. Normalmente com $\mu = 500$ e $\sigma^2 = 100$. A máquina desregulou e queremos saber qual a nova média μ.
Temos uma amostra: $n = 25$; $\overline{X} = 485$
Queremos estimar μ com $\gamma = 0,95$. Isso representa o seguinte intervalo de confiança:

$$IC(\mu; 0,95) = 485 \pm 1,96\sigma_{\overline{X}}$$

$$= 485 \pm 1,96\sqrt{\frac{100}{25}} = 485 \pm 1,96 * 2$$

$$IC(\mu; 0,95) =]481.08, 489.96[$$

18.3.1 Quando a variância é desconhecida

Anteriomente tinhamos que:

$$Z_{\bar{X}} = \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} \sim N(0,1)$$

Entretanto, não possuimos mais os valores de σ e a formulação não nos ajuda mais. Uma alternativa é trocar σ pelo seu estimador S_n. Assim teriamos a segiunte formulação:

$$T_{\bar{X}} = \frac{\bar{X} - \mu}{\frac{S_n}{\sqrt{n}}}$$

Essa nova estatística terá a seguinte definição:

Definição

Para uma amostra aleatória $X_1, ..., X_n$ de uma variável aleatória $X \sim N(\mu, \sigma^2)$ desconhecidos, tem-se que:

$$T_{\bar{X}} = \frac{\bar{X} - \mu}{\frac{S_n}{\sqrt{n}}} \sim t(n-1)$$

tem distribuição t-student com $n-1$ graus de liberdade, $t(n-1)$, para qualquer valor de μ e σ.

Dessa forma podemos definir o intervalo de confiança como:

$$P(\bar{X} - t_{n-1,\alpha/2}\frac{S_n}{\sqrt{n}} < \mu < \bar{X} + t_{n-1,\alpha/2}\frac{S_n}{\sqrt{n}}) = 1 - \alpha$$

Ou seja, o intervalo de confiança para a esperança populacional será:

$$IC(\mu; \gamma) = \left(\bar{x} - t_{n-1,\alpha/2}\frac{S_n}{\sqrt{n}}; \bar{x} + t_{n-1,\alpha/2}\frac{S_n}{\sqrt{n}}\right)$$

Para um amostra suficientemente grande podemos aproximar a distribuição t-student por uma normal padrão e assim calculamos o intervalo de confiança com base na normal mesmo sendo utilizado o estimador da variância.

19 Teste de Hipótese

19.1 Introdução

Até o momento estimamos características da população, fizemos a estimativa pontual e a estimativa de intervalo de um parâmetro. Neste último associamos um grau de confiabilidade de que encontrariamos o verdadeiro parâmetro dentro desse intervalo. Entretanto algumas vezes temos teorias diferentes e gostariamos de testar se uma teoria é mais plausível do que outra com base na realidade. Dessa forma, gostariamos de testar se uma *hipótese* sobre a população é mais plausível, ou seja, se os dados amostrais trazem evidências que apoiam ou não essa hipótese. Por exemplo:

- Verificar se um determinado medicamento não tem efeito sobre a mortalidade causada por um determinado virus ou se possui efeito.
- Verificar se a quantidade de gordura anunciado pelo fabricante de um produto realmente está correta ou é maior.

- Se a afirmativa de um canditado de que possui a maioria dos votos é verdadeira ou é menor.
- Verificar se as rendas entre duas comunidades são as mesmas para podermos lançar uma política de apoio
- Verifcar se uma política do aumento do recurso as empresas não afeta falência ou se tem efeito.

Aqui faremos algo muito parecido com os tribunais, assumimos que a pessoa ou empresa é "inocente". Que o medicamento não tem efeito, que o teor de gordura está certo, que o candidato tem maioria, que as comunidades possuem a mesma renda e que o recurso não afeta o número de falências. Partimos da premissa de que a hipótese inicial é a correta e tentamos verificar com os fatos (dados amostrais) se essa hipótese colocada é verossímil.

19.2 Construíndo a Hipótese Nula

Imaginemos o seguinte caso. Uma ONG que combate fome e pobreza afirma que uma determinada comunidade deveria receber um programa do governo pois possui renda per capita de R$600,00, a qual a torna elegível ao programa. Entretanto, os gestores do programa acham que esse valor está subestimado e que na verdade a renda seria maior. A questão é como saber quem está correto, a ONG ou o Governo?

Dessa forma temos duas hipóteses distintas a que diz que a esperança da renda pc é de R$600 e a outra proposição que diz que a renda dessa população é maior que R$600. Vamos assumir que a ONG tem razão, que acreditamos na sua palavra até que se prove o contrário, e chamaremos essa afirmativa de *hipótese nula* ou H_0. Ela afirma que a esperança da renda pc, μ é de R$600. Podemos de forma condensada dizer:

$$H_0 : \qquad \mu = 600$$

Já o governo que está contextando chamaremos sua hipótese de alternativa, H_1. Ou seja, a teoria concorrente do governo é de que a renda é maior. Dessa forma:

$$H_1 : \qquad \mu > 600$$

Nosso problema então é decidir quem tem razão nessa história, ou seja, devemos aceitar ou rejeitar a hipótese nula H_0 - de que a esperança da renda pc é de 600 - em detrimento a hipótese alternativa H_1 que afirma que a renda é maior do que 600. Juntas:

$$H_0 : \qquad \mu = 600$$

$$H_1: \qquad \mu > 600$$

19.3 O Teste Estatístico

Colocada as duas teorias concorrentes, temos que decidir como testar qual dessas duas hipóteses é mais plausível. Para isso devemos nos valer de um processo de amostragem, onde faremos n medições da renda pc (que chamaremos de X), $X_1, X_2, ..., X_n$, e obteremos os valores de renda pc $x_1, x_2, ...x_n$. Com base na amostra devemos ter algum tipo de cálculo que nos permite inferir se rejeitamos ou não H_0, se é plausível ou não a hipótese colocada. Isso é o que chamamos de teste estatístico:

Definição

Teste Estatístico:
Suponha um processo de amostragem com n medições de X, $X_1, X_2, ..., X_n$, com valores observados $x_1, x_2, ..., x_n$. Um teste estatístico é uma estatística:

$$T = h(X_1, X_2, ..., X_n)$$

a qual será utilizada para decidir se aceitamos ou rejeitamos H_0

Decidindo qual o T utilizar - a função h que será aplicado aos valores da amostra - devemos compreender qual é a distribuição dessa estatística sob a condição de que a hipótese H_0 for a verdadeira. Queremos aqui saber se a amostra tivesse sido extraída de uma população com esperança da renda pc, $\mathbb{E}(\mathbb{X})$, de R$ 600, quais seriam os valores típicos para a distribuição do estimador T? Dessa forma, podemos comparar esses valores típicos com o que obtivemos no processo de amostragem.

Vejamos no nosso exemplo, gostariamos de verificar a hipótese de que a esperança da renda pc, μ é de R$600. Como já vimos uma boa alternativa de teste estatístico poderia ser a média, $\bar{X}$. Assim o teste estatístico seria:

$$\bar{X} = \frac{\sum_i^n (X_i)}{n}$$

Com base na amostra observada $x_1, x_2, ..., x_3$ poderiamos obter a estimativa da renda pc, ou seja, $\bar{x}$. Como saber se essa média calculada nos traz mais evidência a favor de H_0 ou H_1? Veja a Figura abaixo para pensarmos no problema.

A figura considera o estimador $\bar{X}$. A esquerda temos os valores do estimador que atestam que a hipótese H_0 é a mais plausível, quando mais próxima a estimativa de R$600 maior evidência que H_0 é verdadeira. Ao caminhar para a direita, os valores do estimador se distanciam de 600, e mais evidência de que H_0 não é plausível.

Dessa forma, precisamos de um ponto no qual (interrogação na figura) onde valores menores do estimador são favoráveis a hipótese nula e valores maiores são mais favoráveis a hipótese alternativa. Por exemplo, se no nosso processo de amostragem obtivemos a estimativa de $\bar{x} = 700$, isso é mais favorável a H_0 ou H_1?

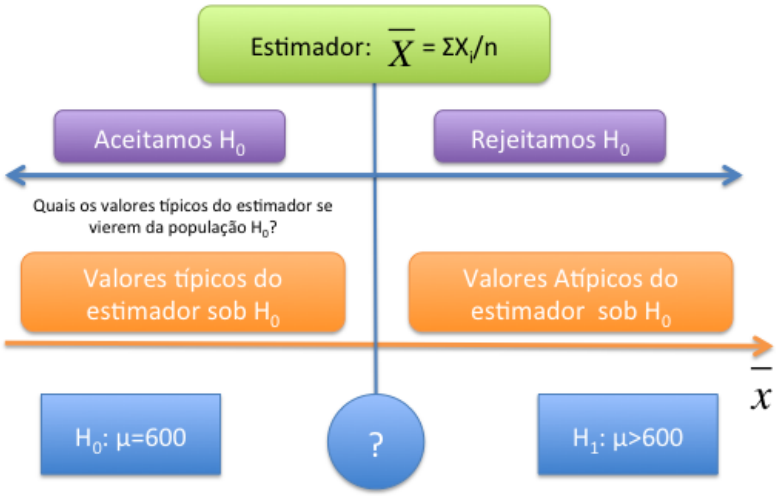

Figure 49: Teste de Hipótese - intuição

Para saber se esse valor é mais favorável a qual hipótese, precisamos descobrir quais seriam os valores típicos do estimador $\bar{X}$ se o processo de amostragem fosse feito em uma população onde H_0 é verdadeira. Isso está presente a esquerda da figura, quais os valores típicos para $\bar{X}$ que veio de uma população com $\mu = 600$?

Para saber qual seriam os valores típicos do estimador $\bar{X}$ sob H_0 imagine que a população X seja $N(600, 100^2)$, ou seja, tem esperança 600 e desvio padrão populacional de 100. Essa é a afirmação da ONG, ou seja, nosso H_0.

Já sabemos que um processo de amostragem cada uma das n medições $X_1, X_2, ..., X_n$ possuem a mesma distribuição de X. E também sabemos que o estimador $\bar{X}$ terá uma distribuição $N(600, \frac{100^2}{n})$. Supondo que retiramos uma amostra de 25 pessoas, logo os valores típicos do estimador sob H_0 são $N(600, \frac{100^2}{25})$. Vejamos abaixo a simulação do estimador $\bar{X}$, os valores típicos para esse caso, e onde se encontra o valor de 700.

```
x<-seq(500,700,0.1)
fdnorm<-dnorm(x = x, mean = 600, sd=20)
regiao=seq(560,640,0.01)
cord.x <- c(min(regiao),regiao,max(regiao))
cord.y <- c(0,dnorm(regiao,mean=600, sd=20),0)
curve(dnorm(x,600,20),xlim=c(500,700),xlab=expression(bar(x)),type="l",
```

```
      col="steelblue4",lwd=2, ylab=expression(paste("f(", bar(x),
      ")")),xaxt="n",cex.axis=0.65, cex.lab=0.8 )
axis(1,at=c(500,540,560,580, 600, 620, 640,660, 700),labels =
       c(500,540,560,580, 600, 620, 640,660, 700),cex.axis=0.7,
     cex.lab=0.8)
polygon(cord.x,cord.y,col='lightgray')
abline(v=600, col="steelblue4", lty=2, lwd=2)
text(602, 0.001, expression(mu))
```

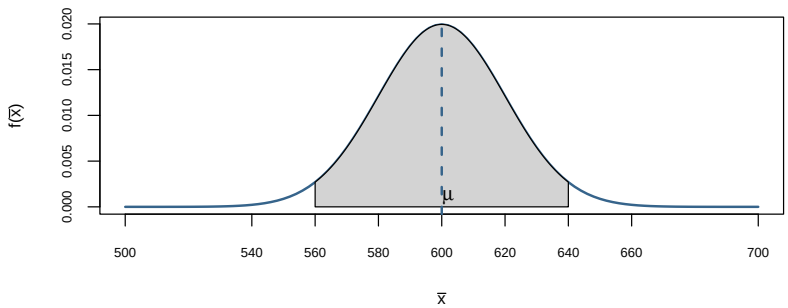

Figure 50: Valores típicos da distribuiçao da média sob H0

Observe a simulação da distribuição do teste estatístico, $\bar{X}$ a qual foi extraída de uma população que possui as características H_0. No centro temos a $E(\bar{X}) = \mu = 600$. Observamos que para o tamanho amostral que retiramos e sob H_0 os valores típicos oscilam mais ou menos entre 560 e 640 - dois desvios padrão para cima e para baixo (lembrem-se que nesse intervalo temos mais de 95% das observaçoes).

Quanto retiramos a amostra e calculamos o valor da média obtivemos $\bar{x} = 700$. Observe no gráfico acima onde está o valor de 700, muita a frente e notamos claramente que a probabilidade de obtermos esse valor de média com uma amostra retirada da população $N(600, 100^2)$, é praticamente 0.

Portanto, existem evidências de que essa amostra não veio de uma população conforme descrita pela ONG e sim de uma população com esperança maior do que R$600. Portanto, dizemos que rejeitamos H_0

19.4 Probabilidade da cauda e o p-valor

Uma outra maneira que podemos olhar o valor de 700 é por meio da probabilidade da cauda acima dele. Vamos considerar a figura acima que mostra a distribuição da média retirada de

uma população sob H_0, ou seja, $N(600, 100^2)$. Podemos estimar qual seria a probabilidade de acharmos valores iguais ou maiores do que 700 nessa distribuição. Essa é chamada probabilidade de cauda a direita $P(\bar{X} \geq 700|H_0)$ e mais conhecida como *p-valor*. Podemos computar esse valor para a cauda inferior, para a superior ou para ambas, a depender da hipótese feita. Esse valor nos mostra que quando mais a direita estiver o nosso valor calculado, menor será essa probabilidade e maior serão as evidências contra H_0. Para o nosso exemplo anterior temos:

$$P(\bar{X} \geq 700|H_0 \Rightarrow \bar{X} \sim N(600, \frac{100^2}{25}))$$

$$P(Z_{\bar{X}} \geq \frac{700 - 600}{100/5}|H_0)$$

$$P(Z_{\bar{X}} \geq \frac{100}{20}) = P(Z_{\bar{X}} \geq 5) = 0$$

Notamos que esse valor de z_c é muito alto e nem aparece na tabela da normal padrão. Mostrando que essa probabilidade é de zero. Ou seja, o p-valor nesse caso é igual a 0, mostrando uma forte evidência de que a ONG está enganada com relação a sua medida da renda dessa população.

Esse foi um exemplo extremo para compreender a intuição do processo. Entretanto, precisamos decidir a partir de que ponto exatamente dizemos que pertence a população sob H_0 e a partir de que ponto não pertence. Para isso precisamos entender os erros que podemos cometer ao fazer esse julgamento.

19.5 Erro Tipo I (EI) e Erro Tipo II (EII)

Aqui precisamos distinguir duas ideias, a primeiro é a existência da verdadeira população e a segunda é o que achamos ser a verdadeira população com base na análise que fizemos. Aqui surge o que chamamos de erro estatístico. Não temos como fugir dele, somente controlá-lo. Vejamos a tabela abaixo que resume as possibilidades:

Table 6: Tipos de Erros em Estatística, EI e EII.

A Decisão	Estatística	
	H_0 é verdadeiro	H_1 é verdadeiro
Rejeitar H_0	Erro Tipo I (EI)	Correto
Não Rejeitar H_0	Correto	Erro Tipo II (EII)

Observe que a nossa decisão pode incorrer em dois erros diversos. O Erro Tipo I (EI) o qual informa que erramos ao rejeitar que a população veio de H_0 e na realidade tinha vindo, e o segundo tipo (EII) que nos diz que aceitamos H_0 quando na verdade não veio de H_0. O primeiro erro é o chamado na literatura médica de falso negativo, ou seja, classifica a pessoa não portadora da doença (negativa) e na verdade ela possui. O segundo tipo é o falso positivo,

onde classifica-se a pessoa com a doença quando na realidade ela não possui. Assim tem-se a seguinte definição:

Definição

Erro Tipo I e Erro Tipo II
Erro Tipo I (EI) ocorre quando "indevidamente" rejeitamemos H_0. Nesse caso H_0 era verdadeira e rejeitamos.
Erro Tipo II (EII) ocorre quando "indevidamente" não rejeitamos H_0. Nesse caso não rejeitamos H_0 e na verdade H_1 é verdadeira.

Nosso desafio agora é estabelecer um critério de decisão, o ponto a partir do qual dizemos que H_0 não parece mais provável,ou seja, rejeitamos H_0. Essa chamaremos de região crítica ou de rejeição, que são os valores a partir dos quais entendemos que H_0 não é mais plausível. Conforme a Figura 1 - a interrogação. Vejamos o nosso problema em termos de erros:

- EI (α)- Dizer que a renda é maior que 600, quando na realizadade ela é de 600.
- EII (β)- Dizer que a renda é de 600 quando na realidade ela é maior do que 600.

Nota-se que conseguimos calcular o Erro Tipo I (α) com base na distribuição sob H_0, entretanto, como não sabemos qual é a distribuição sob H_1, fica difícil calcular o EII (β). Veremos isso com mais detalhe a frente.

Vamos retomar o nosso exemplo onde a ONG afirma que uma comunidade tem renda de R$600 e portanto deveria estar inclusa no programa de governo. O governo contexta. Foi retirada uma amostra de $n = 25$ e a distribuição de $\bar{X}$ sob H_0 será $N(600, \frac{100^2}{25})$ e a hipótese a ser testada será:

$$\begin{aligned} H_0 : &\qquad \mu = 600 \\ H_1 : &\qquad \mu > 600 \end{aligned}$$

Uma maneira de acharmos o valor a partir do qual teremos a região crítica ou de rejeição, seria controlar o Erro Tipo I (α). Podemos dizer que gostariamos de cometer o Erro Tipo I em apenas 5% dos casos. Ou seja, a chance de retirarmos um amostra e o valor da estimativa ser maior que o valor de decisão é de 5% dos casos, os outros 95% sempre cairão na área de aceitação. Vejamos como podemos encontrar o critério de decisão para o nosso caso, unicaudal.

$$P(Z_{\bar{X}} \geq z_c | H_0) = 0.05 = \alpha$$

Olhando a tabela temos:

$$P(Z_{\bar{X}} \geq 1.65 | H_0) = 0.05 = \alpha$$

$$z_c = \frac{\bar{X} + 600}{100/5}$$

$$1.65 = \frac{\bar{X} + 600}{20}$$

$$\bar{X} = 600 + 1.65 * 20 = 633$$

Portanto,

$$P(\bar{X} \geq 633|H_0) = 0.05 = \alpha$$

Logo, temos agora uma regra de decisão que tenta controlar o Erro Tipo I. A nossa regra de decisão agora é rejeitar H_0 toda vez que o valor calculado da estimativa de $\bar{X}$ for maior do que 633 e aceitar quando for menor. Assim nossa região crítica será:

$$RC = \{\bar{x} \in \mathbb{R}|\bar{x} \geq 633\}$$

Isso implica que a probabilidade de rejeitarmos H_0 (de que a renda média não é de 600), e na verdade ela ser de 600 é de 5%. Vejamos o gráfico:

```
x<-seq(500,700,0.1)
fdnorm<-dnorm(x = x, mean = 600, sd=20)
fdnorm1<-dnorm(x = x, mean = 660, sd=20)
regiao=seq(633,700,0.01)
cord.x <- c(min(regiao),regiao,max(regiao))
cord.y <- c(0,dnorm(regiao,mean=600, sd=20),0)
curve(dnorm(x,600,20),xlim=c(500,700),xlab=expression(bar(x)),type="l",
      col="steelblue4",lwd=2, ylab=expression(paste("f(", bar(x),
      ")")),xaxt="n",cex.axis=0.65, cex.lab=0.8 )
axis(1,at=c(500,540,560,580, 600, 620, 633,660, 700),labels =
       c(500,540,560,580, 600, 620, 633,660, 700),cex.axis=0.7, cex.lab=0.8)
polygon(cord.x,cord.y,col='wheat4')
abline(v=633, col="steelblue4", lty=2, lwd=2)
text(600, 0.001, expression(mu))
text(660, 0.005, expression(paste("EI=", alpha, "=0.05")))
```

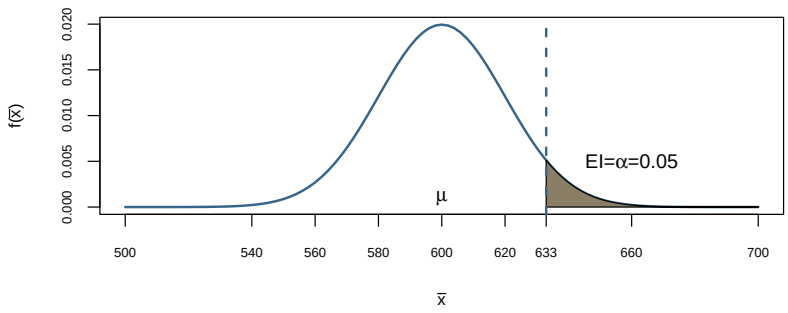

Figure 51: Erro Tipo I e a Região Crítica

Vemos em cinza a região crítica descrita acima. Logo todos os valores calculados de $\bar{X}$ que cairem acima de 633, dizemos que rejeitamos H_0. Entretanto percebam que poderiam fazer parte desta distribuição, apesar da chance ser pequena, 5%.

Como não sabemos a distribuição sob H_1 não conseguimos calcular a probabilidade de não rejeitar H_0 e na verdade ela pertencer a distribuição de H_1.

Vamos supor que o governo diga que na verdade a renda é de R$ 660 com a mesma variância que a ONG afirmou. Nesse caso temos as duas teorias concorrentes explicitadas. Agora sabemos H_1 e H_0. Dada a nossa regra de decisão, temos:

$$P(EI) = P(\overline{X} \in RC|H_0 \quad \text{é verdadeira} \Rightarrow \overline{X} \sim N(600; 100^2/25)) = \alpha = 0.05$$

Podemos calcular também o Erro Tipo II:

$$P(EII) = P(\overline{X} \notin RC|H_1 \quad \text{verdadeiro }) = \beta$$

$$= P(\overline{X} < 633)|\overline{X} \sim N(660; 100^2/25)).$$

$$= P(z < \tfrac{633-660}{20})$$

$$= P(z < -1,35) = 8.85\% = \beta$$

Esses dois tipos de erros estão no gráfico abaixo.

```
x<-seq(500,700,0.1)
fdnorm<-dnorm(x = x, mean = 600, sd=20)
fdnorm1<-dnorm(x = x, mean = 660, sd=20)
regiao=seq(633,700,0.01)
cord.x <- c(min(regiao),regiao,max(regiao))
cord.y <- c(0,dnorm(regiao,mean=600, sd=20),0)
curve(dnorm(x,600,20),xlim=c(500,700),xlab=expression(bar(x)),type="l",
      col="steelblue4",lwd=2, ylab=expression(paste("f(", bar(x),
      ")")),xaxt="n",cex.axis=0.65, cex.lab=0.8 )
axis(1,at=c(500,540,560,580, 600, 620, 633,660, 700),labels =
       c(500,540,560,580, 600, 620, 633,660, 700),cex.axis=0.7, cex.lab=0.8)
polygon(cord.x,cord.y,col='wheat4')
abline(v=633, col="steelblue4", lty=2, lwd=2)
text(600, 0.001, expression(mu))
text(660, 0.005, expression(paste("EI=", alpha, "=0.05")))
par(new=TRUE)
curve(dnorm(x,660,20),xlim=c(500,700),xlab=expression(bar(x)),type="l",
      col="steelblue4",lwd=2, ylab=expression(paste("f(", bar(x),
      ")")),xaxt="n",cex.axis=0.65, cex.lab=0.8 )
regiao=seq(500,633,0.01)
cord.x <- c(min(regiao),regiao,max(regiao))
cord.y <- c(0,dnorm(regiao,mean=660, sd=20),0)
polygon(cord.x,cord.y,col='steelblue4')
text(600, 0.005, expression(paste("EII=", beta, "=0.088")))
```

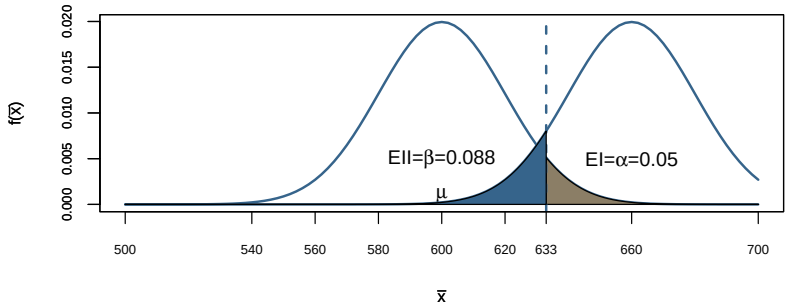

Figure 52: Erro Tipo I e a Região Crítica

Importante notar que se mudamos o ponto de corte de 633 para 640, por exemplo, o valor do EI diminui e o valor do EII aumenta. Se mudarmos o ponto de corte de 633 para 620

aumentamos o EI e diminuimos o erro EII.

Importante notar que em geral não conhecemos qual a distribuição está sob H_1, lembre-se que o que tinhamos era apenas uma afirmativa que era maior, ou seja, que era diferente de 600. Isso é a prática mais comum e controlamos então o EI o qual conseguimos calcular e a partir desse controle encontramos os valores da nossa região crítica e montamos nosso teste de hipótese.

19.6 Procedimento Geral do Teste de Hipótese

19.6.1 Teste para um parâmetro populacional

Temos interesse em uma caracteristica da população. Como vimos por exemplo, na renda pc de uma população X, ou mais especificamente na sua esperança $E(X) = \mu$. Contruímos o teste sobre o parâmetro, podendo ser unicaudal ou bicaudal.

Hipótese Unicaudal

Ocorre quando temos algum conhecimento do processo. Como no caso anterior, observamos que a ONG tinha dito que a renda era 600 e o governo contextava e dizia que era maior. Logo temos a seguinte formulação geral para o teste unilateral:

$$H_0: \quad \theta = \theta_0$$
$$H_1: \quad \theta > \theta_0 \quad ou \quad \theta < \theta_0$$

Hipótese Bicaudal

Já para o teste bilateral ou bicaudal podemos observar valores maiores ou menores em relação a hipótese nula. Assim não temos nenhum conhecimento que nos permita dizer que podemos ter valores somente maiores ou somente menores. Temos a seguinte formulação geral:

$$H_0: \quad \theta = \theta_0$$

$$H_1: \quad \theta \neq \theta_0$$

19.6.2 Nível de significância

Retomando o nosso exemplo, ao rejeitarmos H_0 podemos cometer o erro de dizer que a renda pc é maior de 600, o que implicaria em não recebimento do benefício, mas na realidade a renda era efetivamente 600 e as pessoas mereciam ter recebido. Tentamos controlar esse tipo de erro que é o nosso Erro Tipo I (EI). Temos que definir qual seria o tamanho desse erro, 10%, 5%, 1% etc. Esse percentual é o que chamamos de nível de significância. Quem define esse tamanho é o pesquisador e em geral, em economia, utilizamos os níveis acima.

Definição

Nível de Significância:
É a probabilidade máxima aceitável de cometer o erro tipo I e chamamos de α, sendo um valor entre $0 < \alpha < 1$

Dessa forma, faremos o teste de hipótese para o parâmetro θ ao nível de significância de α. No nosso caso dizemos que iremos testar se a renda pc é de 600, $H_0 : \mu = 600$, ao nível de 5% de significância.

19.6.3 Estabelencendo Valor Crítico e Região Crítica.

Com base no nível de significância conseguiremos estabelecer qual é o valor crítico e qual seria a região de rejeição. Para o nosso caso encontramos o valor crítico de 633 e a nossa região foi estabelecida como $RC = \{\bar{x} \in R | \bar{x} \geq 633\}$. Conforme calculamos anteiormente. A região crítica engloba os valores que julgamos não serem mais pertencentes a distribuição sob H_0. Em nosso caso todos os valores da estimativa calculada que ficarem acima de 633 dizemos que não vierem da distribuição sob H_0

Definição

Valor e região crítica:
Ao relizar o teste de hipótese de H_0 contra H_1 utilizando o teste estatístico T ao nível de significância de α, o conjunto $C \subset \mathbb{R}$ o qual corresponde a todos os valores de T para os quais rejeitamos a hipótese nula H_0, é chamado de **Região Crítica**. O valor na fronteira é o chamado valor crítico

Assim, de forma geral tem-se:

$$RC = \{T \in C | H_0\}$$
$$P(T \in C | H_0) \leq \alpha$$

Dessa forma, a região critica depende do teste estatístico escolhido e se a hipótese é unilateral, ou seja, apenas de um lado da distribuição ou bilateral, os dois lados da distribuição. No caso unilateral utilizamos o nível de siginifcância, α, todo de um lado apenas. Se for o teste bilateral dividimos o nível de significância, ou seja, utilizamos $\alpha/2$, metade para cada lado.

Outro ponto que altera a região crítica é o nível de significância escolhido. Quando mais alto α maior a probabilidade de se obter uma amostra com estimativas pertencentes a região crítica. Assim, α maiores implicam em maiores regiões crítica.

19.6.4 O Teste de Hipótese

Fazemos nosso processo de amostragem e obtemos o valor do teste estatístico. Se o valor do teste ficar fora da região crítica dizemos que não rejeitamos H_0. Para o nosso caso, que não existe evidências de que a renda é maior do 600 reais. Caso o teste estatítico produza uma estimativa na região crítica, rejeitamos H_0, há evidências de que a renda pc é maior do que aquela postulada pela ONG. Isso conclui o nosso teste de hipótese.

19.6.5 Relação entre a Probabilidade de cauda, p-valor, e região crítica

Considere o caso anterior onde tinhamos um teste estatístico realizado para a renda pc de uma comunidade $H_0 : \mu = 600$. Retomando o que fizemos anteriormente e no qual consideramos o nível de 5% de significância para o teste unilateral, obtivemos a seguinte Região Crítica:

$RC = \{\bar{x} \in \mathbb{R} | \bar{x} \geq 633\}$

Vamos supor agora que realizamos uma nova amostragem e a estimativa do nosso teste com base em uma amostragem de 25 elementos foi de 645. Com base no valor do teste e na nossa região crítica construída, rejeitariamos H_0. Podemos agora calcular a probbilidade de cauda, ou seja, o p-valor, o qual mostra a probabilidade de obtermos valores iguais ou maiores do que 645 sob a hipótese nula. Assim:

$$P(\bar{X} \geq 645 | H_0 \Rightarrow \bar{X} \sim N(600, \frac{100^2}{25}))$$

$$P(Z_{\bar{X}} \geq \frac{645 - 600}{100/5} | H_0)$$

$$P(Z_{\bar{X}} \geq \frac{45}{20}) = P(Z_{\bar{X}} \geq 2.25) = 0.0122$$

Logo a chance de termos valores iguais ou maiores de 645 para o teste estatístico considerando H_0 como verdadeiro é de 1.22%. Veja o gráfico abaixo que possui a região crítica e o p-valor.

```
x<-seq(500,700,0.1)
fdnorm<-dnorm(x = x, mean = 600, sd=20)
fdnorm1<-dnorm(x = x, mean = 600, sd=20)
regiao=seq(633,700,0.01)
cord.x <- c(min(regiao),regiao,max(regiao))
cord.y <- c(0,dnorm(regiao,mean=600, sd=20),0)
curve(dnorm(x,600,20),xlim=c(500,700),xlab=expression(bar(x)),type="l",
      col="steelblue4",lwd=2, ylab=expression(paste("f(", bar(x),
      ")")),xaxt="n",cex.axis=0.65, cex.lab=0.8 )
axis(1,at=c(500,540,560,580, 600, 620, 633,645,660, 700),labels =
       c(500,540,560,580, 600, 620, 633,645, 660, 700),cex.axis=0.7, cex.lab=0.8)
```

```
polygon(cord.x,cord.y,col='wheat4')
abline(v=633, col="wheat4", lty=2, lwd=2)
text(600, 0.001, expression(mu))
text(670, 0.005, expression(paste("EI=", alpha, "=0.05=Região Crítica")))
par(new=TRUE)
curve(dnorm(x,600,20),xlim=c(500,700),xlab=expression(bar(x)),type="l",
      col="steelblue4",lwd=2, ylab=expression(paste("f(", bar(x),
      ")")),xaxt="n",cex.axis=0.65, cex.lab=0.8 )
regiao=seq(645,700,0.01)
cord.x <- c(min(regiao),regiao,max(regiao))
cord.y <- c(0,dnorm(regiao,mean=600, sd=20),0)
polygon(cord.x,cord.y,col='steelblue4')
abline(v=645, col="steelblue4", lty=2, lwd=2)
text(665, 0.002, expression(paste("p-value=0.0122")))
```

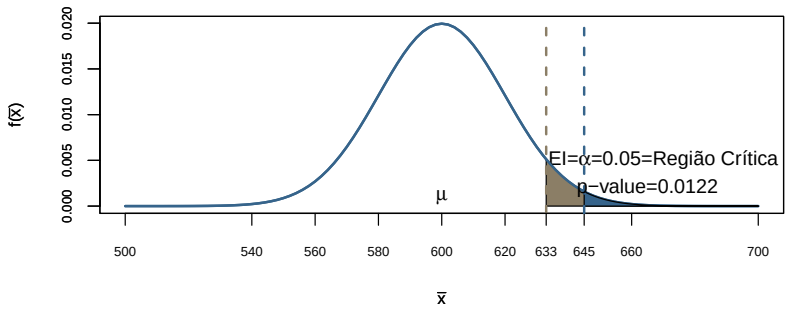

Figure 53: Nível de significância e p-valor

Em marrom, linha mais a esquerda, temos o limite da região crítica, ou seja, o valor a partir do qual rejeitariamos H_0. Note que podemos montar essa região sem efetivamente retiramos uma amostra, somente com base na teoria e no tamanho amostral que poderiamos coletar. Ela especifica todas os valores sob os quais rejeitamos H_0. O p-valor está indicado pela linha azul no gráfico e nos fornece a ideia de quão forte é essa rejeição, observa-se que quanto menor o p-valor (valores mais extremos) mais evidências temos de que a hipótese nula H_0 não é adequada, ou seja, mais forte são as evidências para a rejeição.

19.7 Os Cinco passos para a contrução do teste de hipótese

1. Estabeleça as hipótese nula H_0 e a hipótese alternativa H_1

2. Defina qual estimador do parâmetro populacional θ que será usado para testar H_0: média, desvio padrão amostral, proporção amostral etc
3. Defina o nível de significância - α e estabeleça qual o valor e a região crítica.
4. Calcule a estimativa do teste estatístico.
5. Se não pertencer a Região Crítica não rejeitamos H_0, caso contrário rejeitamos a hipótese nula H_0.

20 Teste de Hipótese na prática

20.1 Introdução

Vamos separar em dois grupos de testes. Os testes sobre os parâmetros locacionais e os testes sobre probabilidades. Apesar do procedimento ser sempre aquele apresentado acima, existe mudanças na estatística que iremos utilizar dado a situação em questão.

20.2 Testes paramétricos para parâmetros locacional

20.2.1 Testes sobre Esperança de uma população com variância conhecida

Esse é nosso primeiro teste sobre a esperança populacional, μ e ele parte do pressuposto que conhecemos a variância populacional, ou seja, $\sigma^2 = \sigma_0^2$. Vamos seguir os passos que mostramos anteriormente e construir o que seria a forma geral de testar uma hipótese neste caso;

1- Definindo a Hipótese

Podemos definir de forma Bicaudal ou Unicaudal

$$H_0 : \mu = \mu_0$$

$$H_1 : \mu \neq \mu_0$$

ou

$$H_0 : \mu = \mu_0$$

$$H_1 : \mu > \mu_0 \quad ou \quad H_1 : \mu < \mu_0$$

2 - Definindo o Estimador

O estimador para a esperança já conhecemos, a média ($\bar{X}$). Para encontrar estimadores podemos utilizar uma das técnicas anteriores que vimos.

$$\bar{X} = \frac{\sum_i X_i}{n}$$

Sabemos que ao realizar um processo de amostragem aleatório, temos n medições de X (X_i) e cada uma dessas tem a mesma probabilidade de X. Observamos x_i. Dessa forma, considerando o TLC e a LGN tem-se:

$$\bar{X} \sim N(\mu, \sigma^2/n)$$

Esse resultado é independente da distribuição de X. Somente precisamos assumir normalidade de X para amostras pequenas, pois neste caso não conseguimos garantir as convergências em distribuição. Sob H_0 temos o seguinte:

$$\bar{X} \overset{H_0}{\sim} N(\mu_0, \sigma_0^2/n)$$

Logo o nosso Teste Estatístico T, sob H_0 será:

$$T = \frac{\bar{X} - \mu_0}{\sigma_0/\sqrt{n}} \overset{H_0}{\sim} N(0,1)$$

3 - Nivel de Significância e Região Crítica

O controle do Erro Tipo I ou o nível de significância é uma escolha do pesquisador. Em economia utilizamos 10%, 5% e 1%. Com base na sua escolha podemos estabelecer as regiões críticas para o teste. Para:

$$H_0 : \mu = \mu_0$$
$$H_1 : \mu \neq \mu_0$$

$$RC = \{t \in \mathbb{R} | t \leq -z_{c,\alpha/2} \quad \cup \quad t \geq z_{c,\alpha/2}\}$$

$$H_0 : \mu = \mu_0$$
$$H_1 : \mu > \mu_0 \quad ou \quad H_1 : \mu < \mu_0$$
$$RC_1 = \{t \in \mathbb{R} | t \geq z_{c,\alpha}\}$$

ou

$$RC_2 = \{t \in \mathbb{R} | t \leq -z_{c,\alpha}\}$$

4 - Cálculo do Teste Estatístico

Calcular o valor do teste estatístico com base na amostra retirada da população sob estudo. Agora teremos uma realização da média amostral das diversas possibilidades fornecidas pela distribuição de $\bar{X}$. Tem-se:

$$\bar{x} = \frac{\sum_i x_i}{n}$$

Logo o valor do nosso teste estatístico será:

$$t = \frac{\bar{x} - \mu_0}{\sigma_0/\sqrt{n}}$$

Agora podemos comparar esse valor obtido com os valores ditos mais prováveis de ocorrerem sob H_0. Basicamente faremos isso comparando o valor obtido, t com a nossa região crítica.

5 - Teste de hipótese

Assim se a nossa estimativa t pertencer a regiao crítica rejeitamos H_0, ou seja, há evidências de que a afirmativa esteja errada. Caso não esteja na RC não rejeitamos H_0 e portanto temos evidência de que esteja correto.

Vejamos agora um exemplo.

Exemplo

Suponha que temos uma máquina de empacotar que tem uma regulagem original com $\mu = 500$ e $\sigma^2 = 400$. O gerente de qualidade da empresa mensalmente faz a aferição para verificar se a máquina está desregulada. Ele coleta aleatóriamente $n = 16$ pacotes e obteve a média $\bar{x} = 492$. O gerente deve parar a produção e chamar a equipe de manutenção ao nível de 1% de significância?

Resolvendo:

1 - Definindo a hipótese

Vamos adotar como hipótese nula a afirmação de que a máquina não desregulou. A hipótese alternativa é que a máquina pode ter desregulado para cima ou para baixo.

$$H_0 : \mu = 500g$$

$$H_1 : \mu \neq 500g$$

Nesse caso utilizamos a hipótese bilateral.

2 - Definindo o Estimador

O estimador de μ é a média $\bar{X}$:

$$\bar{X} = \frac{\sum_i X_i}{16}$$

Sendo a distribuição desse estimador:

$$\bar{X} \sim N(\mu, \sigma^2/16)$$

Sob H_0 temos a seguinte definição:

$$\bar{X} \overset{H_0}{\sim} N(500, 400/16)$$

Logo o nosso Teste Estatístico T, que nesse caso é a normal padronizada, sob H_0 será :

$$T = \frac{\bar{X} - 500}{20/\sqrt{16}} \overset{H_0}{\sim} N(0, 1)$$

3 - Nivel de Significância e Região Crítica

Considerando o nível de 1% de significância temos a seguinte região crítica para T, com base na tabela:

$$RC = \{t \in \mathbb{R} | t \leq -z_{c,0.025} \quad \cup \quad t \geq z_{c,0.025}\} = \{t \in \mathbb{R} | t \leq -2.58 \quad \cup \quad t \geq 2,58\}$$

4 - Cálculo do Teste Estatístico

Com base nas 16 elementos amostrados de X, obtivemos:

$$\bar{x} = \frac{\sum_i x_i}{16} = 492$$

Logo o valor do nosso teste estatístico será:

$$t = \frac{492 - 500}{20/4} = \frac{-8}{5} = 1.6$$

Agora podemos comparar esse valor obtido com os valores ditos mais prováveis de ocorrerem sob H_0. Basicamente faremos isso comparando o valor obtido, t com a nossa região crítica.

5 - Teste de Hipótese

Com base no t calculado procedemos o teste de hipótese. Sadendo que a RC é:

$$RC = \{t \in \mathbb{R} | t \leq -2.58 \quad \cup \quad t \geq 2,58\}$$

Como $t = 1.6$ ele não pertence a região, logo não rejeitamos H_0, não há evidências de que a máquina desregulou e o gerente não deveria parar a produção para fazer a manutenção.

Uma outra maneira de fazermos é ao invés de utilizarmos a normal padronizada, encontrarmos quais são os limites da região crítica na distribuição de $\bar{X}$. Assim poderemos fazer para o nível de significância, α de 1%:

$$z_{c_1} = -2,58 = (\overline{x}_{c1} - 500)/5 = 487,1$$

$$Z_{c_2} = 2,58 = (\overline{x}_{c2} - 500)/5 = 512,9$$

Logo a região crítica análoga na distribuição de $\bar{X}$ será:

$$RC = \{\overline{x} \in R | \overline{x} \leq 487,1 \text{ ou } \overline{x} \geq 512,9\}$$

Como a amostra tem média $\overline{x} = 492$ ela não pertence à região críitica então não rejeitamos H_0.

Vejamos a simulação e os valores críticos e o $\bar{x}$ calculado.

```
x<-seq(480,520,0.1)
fdnorm<-dnorm(x = x, mean = 500, sd=5)
fdnorm1<-dnorm(x = x, mean = 500, sd=5)
regiao=seq(512.9,520,0.01)
cord.x <- c(min(regiao),regiao,max(regiao))
cord.y <- c(0,dnorm(regiao,mean=500, sd=5),0)
curve(dnorm(x,500,5),xlim=c(480,520),xlab=expression(bar(x)),type="l",
      col="steelblue4",lwd=2, ylab=expression(paste("f(", bar(x),
      ")")),xaxt="n",cex.axis=0.65, cex.lab=0.8 )
axis(1,at=c(487.1, 492, 495, 500, 505, 510, 512.9, 515),labels =
       c(487.1, 492, 495, 500, 505, 510, 512.9, 515),cex.axis=0.7, cex.lab=0.8)
polygon(cord.x,cord.y,col='steelblue4')
abline(v=512.9, col="steelblue4", lty=2, lwd=2)
abline(v=492, col="wheat4", lty=2, lwd=2)
text(500, 0.001, expression(mu))
text(517, 0.01, expression(paste(alpha,"/2", "=0.025")))
text(517, 0.04, expression("RC"))
```

```
text(494, 0.01, expression(paste(bar(x),"=492")))

par(new=TRUE)
curve(dnorm(x,500,5),xlim=c(480,520),xlab=expression(bar(x)),type="l",
      col="steelblue4",lwd=2, ylab=expression(paste("f(", bar(x),
      ")")),xaxt="n",cex.axis=0.65, cex.lab=0.8 )
axis(1,at=c(487.1, 492, 495, 500, 505, 510, 512.9, 515),labels =
       c(487.1, 492, 495, 500, 505, 510, 512.9, 515),cex.axis=0.7, cex.lab=0.8)
regiao=seq(480,487.1,0.01)
cord.x <- c(min(regiao),regiao,max(regiao))
cord.y <- c(0,dnorm(regiao,mean=500, sd=5),0)
polygon(cord.x,cord.y,col='steelblue4')
abline(v=487.1, col="steelblue4", lty=2, lwd=2)
text(483, 0.01, expression(paste(alpha,"/2", "=0.025")))
text(483, 0.04, expression("RC"))
```

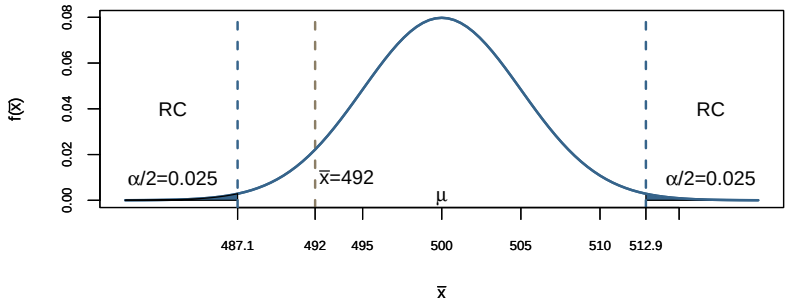

Figure 54: Nível de significância e p-valor

Observamos na distribuição de $\bar{X}$, a qual foi construída considerando H_0 verdadeira, os valores críticos 487.1 e 512.9, bem como as regiões críticas. Nota-se que o valor de $\bar{x}$ não está dentro da RC e portanto, não rejeitamos H_0.

20.2.2 Utilizando a Probabilidade de Cauda ou Probilidade de Significância ou p-valor

Para fixarmos a ideia de p-valor, vamos fazer agora um teste de hipótese considerando apenas a probabilidade de cauda, ou probabilidade de significância ou o p-valor. O nome mais comum

é p-valor. Agora não construiremos mais a região crítica e iremos calcular com base na estatística:

$$P(T \geq t_0|H_0) = p - valor = \hat{\alpha}$$

Vejamos um exemplo:

Exemplo

Uma empresa de transporte intermunicipal que ganhou uma concessão do Estado afirma que o tempo de viagem, X, entre duas cidades de acordo com seus estudos preliminares pode ser assim descrito:

$$X \sim N(300, 30^2)$$

Inclusive esse tempo foi um dos critérios utilizados no processo de cessão. O Ministério Público desconfia e acredita que esse valor é maior. O MP faz um estudo considerando 10 viagens aleatórias e encontra que $\overline{x} = 314$. O MP deve se reunir com a empresa e pedir um ajustamento de conduta?

Resolvendo:

1 - Definindo a hipótese

$$H_0 : \mu = 300$$

$$H_1 : \mu \geq 300$$

2 - Definindo o Estimador

Sabemos que $\bar{X}$ será:

$$\overline{X} \sim N(\mu; \sigma^2/10)$$

e considerando que a empresa está correta, ou seja, sob H_0:

$$\overline{X} \sim N(300; 900/10)$$

3 - Nivel de Significância e Região Crítica

Não precisamos mais calcular!!

4 - Cálculo do Teste Estatístico

Com $\bar{x}_0 = 314$ e sob H_0, calculamos a probabilidade de ocorrência de amostras com o valor iguais ou superiores a $\overline{x} = 314$:

$$P(\bar{x} > 314) = P(z > \tfrac{314-300}{9.49}) = P(z > 1,48) = 0,07$$

$$\hat{\alpha} = p - valor = 7\%$$

Caso fosse bicaudal e sabendo que a distribuição é simétrica poderiamos considerar: $\hat{\alpha} = 14\%$

5 - Teste de Hipótese

Considerando o teste unilateral, temos agora a força da rejeição. A chance de retirarmos 314 ou mais é de 7%. Apesar de baixo poderia ocorrer. Não parece muito improvável, tanto que se considerarmos $\alpha = 1\%$ ou $\alpha = 5\%$ não rejeitamos. Só rejeitariamos H_0 se $\alpha = 10\%$. Podemos concluir que as evidências não nos revelam que a empresa está tendo um tempo maior de viagem, apesar dessa conclusão não ser tão forte.

20.2.3 Teste sobre a Esperança de uma população normal com variância desconhecida

O procedimento aqui é análogo ao que fizemos anteriormente para testar a média quando conheciamos o desvio populacional σ. Entretanto o nosso teste estatístico que era:

$$T = \frac{\bar{X} - \mu_0}{\sigma_0/\sqrt{n}}$$

Não pode ser calculado pois não conhecemos mais σ_0. Temos que substituir esse parâmetro pela sua estimativa.

$$S_X^2 = \frac{1}{n-1}\sum_i (X - \bar{X})^2$$

Dessa forma, nosso novo teste estatístico será:

$$T = \frac{\bar{X} - \mu_0}{S_X/\sqrt{n}}$$

Nossa questão agora é qual a distruibuição desse teste? Agora tanto $\bar{X}$ como S_X são variáveis aleatórias e possuem distriuição. Para verificar, vamos dividir o numerador e o denominador por uma constante - desvio, σ

$$\frac{\bar{X}-\mu}{S_X/\sqrt{n}} = \frac{\sqrt{n}(\bar{X}-\mu)}{S_X} \div \sigma \rightarrow \frac{\sqrt{n}(\overline{X}-\mu)/\sigma}{s/\sigma}$$

Analisando o numerador:

$$z = \frac{(\bar{x}-\mu)}{\sigma/\sqrt{n}} \sim N(0,1)$$

Analisando o denominador e assumindo que X tem uma distribuição normal:

$$(s/\sigma)^2 \Rightarrow \frac{(n-1)S^2}{\sigma^2}/(n-1) \sim \chi^2_{(n-1)}$$

Temos a divisão de uma normal $N(0,1)$ por $\sqrt{\chi^2_{n-1}}$ dividido pelo número de graus de liberdade

$$\left[\frac{N(0,1)}{\sqrt{\chi^2_{n-1}/n-1}}\right]$$

Portanto nosso teste estatístico será:

$$T = \frac{\sqrt{n}(\bar{X}-\mu)}{S_X} \sim t(n-1)$$

E terá uma distribuição t-student com n-1 graus de liberdade. Agora nossa região crítica tem que ser construída com base na tabela da distribuição t.Para o caso bicaudal:

$$RC = \{t \in \mathbb{R} | t \leq -t_{c,\alpha/2} \quad ou \quad t \geq t_{c,\alpha/2}\}$$

Para o caso unicaudal:

$$RC_1 = \{t \in \mathbb{R} | t \geq t_{c,\alpha}\} \quad ou \quad RC_2 = \{t \in \mathbb{R} | t \leq -t_{c,\alpha}\}$$

Agora vejamos um exemplo:

Exemplo

Um fabricante afirma que seus cigarros não contém mais do que 30mg de nicotina. O Ministério da Saúde está desconfiado dessa afirmativa e acredita que o conteúdo de nicotina é maior do que o anunciado (teste unilateral). Foi realizada uma amostra de 25 cigarros e o teor médio de nicotina nos mesmos foi $\overline{x_0} = 31,5mg$ e o desvio padrão amostral $S_X = 3mg$. Com $\alpha = 5\%$ os dados confirmam a informação?

1 - Definindo a hipótese

$$H_0 : \mu = 30$$

$$H_1 : \mu \geq 30$$

2 - Definindo o Estimador

O estimador de μ é a média $\bar{X}$:

$$\bar{X} = \frac{\sum_i X_i}{25}$$

Logo o nosso Teste Estatístico T, que nesse caso é a padronização de $\bar{X}$ e considerando o estimador da variância será, sob H_0:

$$T = \frac{\bar{X} - 30}{3/\sqrt{25}} \overset{H_0}{\sim} t(24)$$

3 - Nivel de Significância e Região Crítica

Considerando o nível de 5% de significância e teste unilateral temos a seguinte região crítica para T, com base na tabela t-student:

$$RC = \{t \in \mathbb{R} | t \geq t_{24,0.05}\} = \{t \in \mathbb{R} | t \geq 1,711\}$$

Todos os valores da estatística acima de 1,711 fazem parte da nossa região crítica.

4 - Cálculo do Teste Estatístico

Foram amostrado 25 elementos de X, obtivemos:

$$\bar{x} = \frac{\sum_i x_i}{25} = 31.5$$

Logo o valor do nosso teste estatístico será:

$$t = \frac{31.5 - 30}{3/5} = \frac{1.5}{0.6} = 2.5$$

Agora podemos comparar o valor obtido, t com a nossa região crítica.

5 - Teste de Hipótese

Nosso teste foi $T = 2.5$ e nossa região crítica $RC = \{t \geq 1,711\}$. Logo pertence à região crítica. Dessa forma, rejeitamos H_0 mostrando que há evidências de que o teor de nicotina é maior do que o anunciado pela firma.

6 - Extra 1: Probabilidade de cauda ou p-valor

Vamos ver qual a probabilidade de encontrarmos os valores $T = 2.5$ ou maiores em uma amostra que veio de uma população sob H_0 ou seja, $\mu = 30g$.

$$\hat{\alpha} = P\left(T > t_0 | H_0\right) = P\left(T > 2,5 | H_0\right) = 0,01$$

O que também leva à rejeição de H_0 ao nível de 5% de confiança.

7 - Extra 2: O Intervalo e Confiança

Como rejeitamos, poderiamos estar interessados em descobrir onde estaria a verdadeira média populacional ao nível de 5% de confiança. Vamos calcular o intervalo de confiança para 5% ($t_\gamma = 2,064$):

$$IC(\mu; 0.95) = 31,5 \pm (2.064)3/\sqrt{25}$$

$$IC(\mu; 0.95) = \{30.26; 32.74\}$$

Logo o verdadeiro parâmetro populacional μ estaria entre 30.26 e 32.74.

8 - Extra 3: Simulando o nosso problema

Vamos agora simular a distribuição t-student sob H_0 e verificar o valor obitido, a RC e o p-valor

```
x<-seq(-4,4,0.1)
fdt<-dt(x = x, df = 24)
fdt1<-dt(x = x, df = 24)
regiao=seq(1.711,4,0.01)
cord.x <- c(min(regiao),regiao,max(regiao))
cord.y <- c(0,dt(regiao,df=24),0)
curve(dt(x,df = 24),xlim=c(-4,4),xlab=expression(t),type="l",
      col="steelblue4",lwd=2, ylab=expression(paste("f(", bar(t),
```

```
      ")")),xaxt="n",cex.axis=0.65, cex.lab=0.8 )
axis(1,at=c(-4,-3,-2,-1, 0, 1, 1.71,2.5,3, 4),labels =
       c(-4,-3,-2,-1, 0, 1, 1.71,2.5,3, 4),cex.axis=0.7, cex.lab=0.8)
polygon(cord.x,cord.y,col='wheat4')
abline(v=1.711, col="wheat4", lty=2, lwd=2)
text(0, 0.001, expression(mu))
text(2.2, 0.15, expression(paste(alpha, "=0.05")))
text(3, 0.25, expression("Região Crítica"))

par(new=TRUE)
curve(dt(x,df = 24),xlim=c(-4,4),xlab=expression(t),type="l",
      col="steelblue4",lwd=2, ylab=expression(paste("f(", bar(t),
      ")")),xaxt="n",cex.axis=0.65, cex.lab=0.8 )
regiao=seq(2.5,4,0.01)
cord.x <- c(min(regiao),regiao,max(regiao))
cord.y <- c(0,dt(regiao,df=24),0)
polygon(cord.x,cord.y,col='steelblue4')
abline(v=2.5, col="steelblue4", lty=2, lwd=2)
text(3.3, 0.05, expression(paste("p-value=0.01")))
```

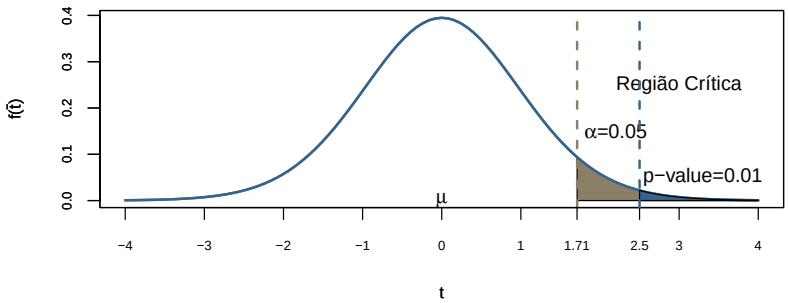

Figure 55: Nível de significância e p-valor para distribuição t-student

20.2.4 Comparação de duas populações normais: amostra independente

Nesse caso não quero mais saber se a esperança de uma população é igual a um determinado valor $H_0 : \mu = k$ agora queremos saber se uma população possui o mesmo valor de esperança que a outra população. Por exemplo se a renda per capita é da cidade é igual a renda per capita no campo. Agora comparamos duas médias $H_0 : \mu_1 = \mu_2$. Aqui assumimos que elas são normais e as amostras são independentes:

$$P_1 \sim N(\mu_1, \sigma_1^2)$$

$$P_2 \sim N(\mu_2, \sigma_2^2)$$

1 - Definindo a hipótese

$H_0 : \mu_1 = \mu_2$

$H_1 : \mu_1 \neq \mu_2$

2 - Definindo o Estimador

Supondo que retiramos uma amostra de n elementos da população 1 X e de m elementos da população 2, Y. Sob H_0 temos:

$$\mathbb{E}(\overline{X} - \overline{Y}) = \mathbb{E}(\overline{X}) - \mathbb{E}(\overline{Y}) = \mu_X - \mu_Y = 0$$
$$Var(\overline{X} - \overline{Y}) = Var(\overline{X}) + Var(\overline{Y}) = \frac{\sigma_X^2}{n} + \frac{\sigma_Y^2}{m}$$

2.1 - Caso 1: Para variâncias conhecidas

Sob a hipótese de que H_0 é verdadeira:

$$T = \frac{(\overline{X} - \overline{Y}) - (\mu_X - \mu_Y)}{\sqrt{\frac{\sigma_X^2}{n} + \frac{\sigma_Y^2}{m}}}$$

$$T = \frac{(\overline{X} - \overline{Y})}{\sqrt{\frac{\sigma_X^2}{n} + \frac{\sigma_Y^2}{m}}} \sim N(0, 1)$$

Dessa forma construímos nossa região crítica com base nos valores críticos determinados pelo nosso nível de significância (α) na normal padrão (ϕ), ou seja, $z_{c,\alpha}$

O intervalo de confiança nesse casos seria:

$$IC(\theta; \gamma) = (\overline{x_0} - \overline{y_0}) \pm z_\gamma \sqrt{\frac{\sigma_X^2}{n} + \frac{\sigma_Y^2}{m}}$$

2.2 - Caso 2: Para variância desconhecida e iguais

No teste de igualdade de variância essa não foi rejeitada. Temos que S_1^2 e S_2^2 são dois estimadores não viesados de σ^2. Novamente retiramos uma amostra de n elementos da população 1 X e de m elementos da população 2, Y. Assim:

$$S_p^2 = \frac{(n-1)S_X^2 + (m-1)S_Y^2}{n+m-2}$$

Para testar a hipótese nula utiliza-se:

$$T = \frac{\overline{X} - \overline{Y}}{S_p\sqrt{\frac{1}{n} + \frac{1}{m}}} \sim t_{(n+m-2)}$$

Dessa forma construímos nossa região crítica com base nos valores críticos determinados pelo nosso nível de significância (α) na t-student $t(n+m-2)$), ou seja, $t_{\alpha,(n+m-2)}$

Construímos o seguinte Intervalo de confiança:

$$IC(\theta;\gamma) = (\overline{x_0} - \overline{y_0}) \pm t_{\gamma,(n+m-2)} S_p\sqrt{\frac{1}{n} + \frac{1}{m}}$$

2.3 - Caso 3: Para variância desconhecida e desiguais

Agora a hipótese de igualdade de variância for rejeitada, as duas populações possuem variâncias distintas, logo:

$$T = \frac{\overline{X} - \overline{Y}}{\sqrt{S_X^2/n + S_Y^2/m}} \sim t_{(v)}$$

Para encontrar o grau de liberdade v:

$$v = \frac{(A+B)^2}{\frac{A^2}{(n-1)} + \frac{B^2}{(m-1)}}$$

onde:

$$A = \frac{S_X^2}{n} \qquad B = \frac{S_Y^2}{m}$$

Novamente, nossa região crítica é elaborada com base nos valores críticos determinados pelo nosso nível de significância (α) na t-student $t(v)$, ou seja, $t_{\alpha,(v)}$

Construímos o seguinte Intervalo de confiança:

$$IC(\theta;\gamma) = (\overline{x_0} - \overline{y_0}) \pm t_{\gamma,(v)}\sqrt{S_1^2/n + S_2^2/m}$$

Vejamos agora dois exemplos. O primeiro é para as variâncias conhecidas e o segundo para variâncias desconhecidas mas iguais!

Exemplo

Teste de diferença de médias com variância conhecidas
Uma empresa propos um novo sistema de monitoramento de processo e quer verificar se esse faz com que os funcionarios tenham melhor performance. Foi feito um ensaio com 8 funcionários sob o monitoramento atual (X) e a performance média registrada foi de 80.5 pontos. Sabe-se que o desvio padrão populacional, $\sigma_X = 1.5$. Foi feito outro ensaio com 10 funcionários sob o novo monitoramento (Y) e a performance foi de 81.3 pontos. Aqui também conhecemos o desvio padrão populacional, $\sigma_X = 3.8$

1 - Definindo a hipótese

Vamos adotar o teste unilateral pois sabemos que o novo processo pode performar igual ou melhor e não pior.

$$H_0 : \mu_X = \mu_Y$$

$$H_1 : \mu_X \leq \mu_Y$$

2 - Defindo o Estimador

Para variância conhecida e considerando a a hipótese nula utiliza-se o seguinte estimador:

$$T = \frac{(\overline{X} - \overline{Y})}{\sqrt{\frac{\sigma_X^2}{n} + \frac{\sigma_Y^2}{m}}} \sim N(0,1)$$

3 - Nivel de Significância e Região Crítica

Considerando o nível de 5% de significância e teste unilateral temos a seguinte região crítica para T, com base na tabela normal padrão, $z_{c,0.05}$:

$$RC = \{t \in \mathbb{R} | t \leq z_{c,0.05}\} = \{t \in \mathbb{R} | t \leq -1.645\}$$

4 - Cálculo do Teste Estatístico

Calculando a variância ponderada:

$$T = \frac{(\overline{X} - \overline{Y})}{\sqrt{\frac{\sigma_X^2}{n} + \frac{\sigma_Y^2}{m}}} = \frac{(80.5 - 81.3)}{\sqrt{\frac{1.5^2}{8} + \frac{3.8^2}{10}}} = -0.61 \sim N(0,1)$$

5 - Teste de Hipótese

Como -0.61 não está na região crítica, não rejeitamos a hipótese nula de que os dois processos de monitoramento produzem o mesmo resultado. Isso indica que se houver algum custo adicional na implementação do monitoramento 2, esse será um prejuízo para a empresa.

6 - Simulando as duas distribuições

Veja nas simulações como as duas distribuições estão próxima uma da outra indicando que não conseguimos diferenciar. Isso é a explicação visual do porque não houve diferença entre as médias dos dois monitoramentos.

```
x<-seq(77,85,0.1)
curve(dnorm(x,80.5,0.53),xlim=c(77,85),xlab=expression(bar(x)),type="l",
      col="steelblue4",lwd=2, ylab=expression(paste("f(", bar(x),
      ")")),xaxt="n",cex.axis=0.65, cex.lab=0.8 )
axis(1,at=c(77,80.5,81.3, 85),labels =
       c(77,80.5,81.3, 85),cex.axis=0.7, cex.lab=0.8)
abline(v=80.5, col="steelblue4", lty=2, lwd=2)
par(new=TRUE)
curve(dnorm(x,81.3,1.2),xlim=c(77,85),xlab=expression(bar(x)),type="l",
      col="wheat4",lwd=2, ylab=expression(paste("f(", bar(x),
      ")")),xaxt="n",yaxt="n",cex.axis=0.65, cex.lab=0.8 )
abline(v=81.3, col="wheat4", lty=2, lwd=2)
```

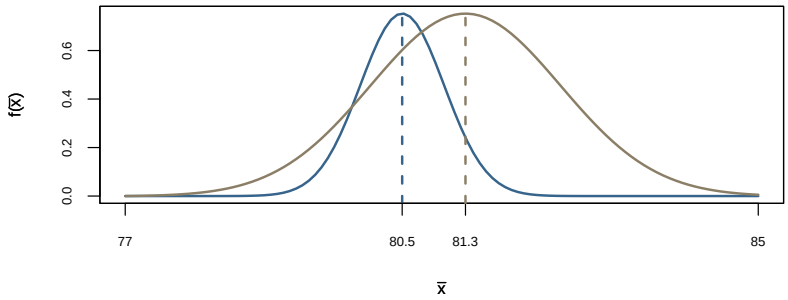

Figure 56: Simulando as duas distribuições do monitoramento, supondo normalidade

Exemplo

Teste de diferença de médias com variância desconhecidas e iguais
Uma empresa está testando duas misturas de concretos os quais são feitos com cimento de diferentes minas. A mistura 1 é a mistura padrão feita com o cimento já conhecido. A mistura 2 usa a mesma receita mas utiliza um cimento vindo de uma nova mina. A empresa quer saber se as duas misturas produzem a mesma qualidade de produto, ou seja, que a carga de ruptura do concreto após 28 dias é a mesma em kg/cm^2. A tabela abaixo traz os testes laboratoriais e gostariamos de saber se ao nível de 5% de confiança as duas misturas possuem a mesma esperança?

Table 7: Resistência de diversas amostras de concreto

	Carga de Ruptura kg/cm^2											
Mistura 1	15,4	15,7	14,8	15,7	14,8	15,6	15,4	14,6	15,8	15,3	15,5	15,2
Mistura 2	14,7	14,3	14,5	14,2	15,0	14,8	15,2	15,3	14,9	15,4		

Resolvendo:

Considerando que X é a carga de ruptura da mistura 1 $(x_1, x_2, ..., x_{12})$ e que Y é a carga de ruptura da mistura 2 $(y_1, y_2, ..., y_{10})$. Vamos calcular as médias e desvio padrões amostrais:

$$n = 12 \qquad \sum_i X_i = 183.8 \qquad \sum_i X_i^2 = 2816.92$$

$$m = 10 \qquad \sum_i Y_i = 148.3 \qquad \sum_i Y_i^2 = 2200.81$$

$$\overline{X} = \frac{\sum_i X_i}{n} = 15.316$$

$$\overline{Y} = \frac{\sum_i Y_i}{n} = 14.83$$

$$S_X^2 = \frac{\sum_i X_i^2 - 2\overline{X}\sum_i X_i + n\overline{X}^2}{n-1} = 0.1561 \Rightarrow S_X = 0.395$$

$$S_Y^2 = 0,1690 \Rightarrow S_Y = 0.411$$

1 - Definindo a hipótese

$$H_0 : \mu_X = \mu_Y$$

$$H_1 : \mu_X \neq \mu_Y$$

2 - Defindo o Estimador

Para variância desconhecida e iguais e assumindo que ambas as populações possuem distribuição normal. Sob a hipótese nula utiliza-se utiliza-se o seguinte estimador:

$$T = \frac{\overline{X} - \overline{Y}}{S_p\sqrt{\frac{1}{n} + \frac{1}{m}}} \sim t_{(n+m-2)}$$

Sendo:

$$S_p^2 = \frac{(n-1)S_X^2 + (m-1)S_Y^2}{n+m-2}$$

3 - Nivel de Significância e Região Crítica

Considerando o nível de 5% de significância e teste bilateral temos a seguinte região crítica para T, com base na tabela t-student, $t_{(12+10-2)} = t_{(20)}$

$$RC = \{t \in \mathbb{R} | t \leq t_{(20),0.025} \quad \cup \quad t \leq t_{(20),0.025}\} = \{t \in \mathbb{R} | t \leq -2.086 \quad \cup \quad t \geq 2.086\}$$

4 - Cálculo do Teste Estatístico

Calculando a variância ponderada:

$$S_p^2 = \frac{(n-1)S_X^2 + (m-1)S_Y^2}{n+m-2} = \frac{(11)0.1561 + (9)0.169}{12+10-2} = 0.1619$$

Portanto o teste estatístico será:

$$T = \frac{\overline{X} - \overline{Y}}{S_p\sqrt{\frac{1}{n} + \frac{1}{m}}} = \frac{15.316 - 14.83}{0.1619\sqrt{\frac{1}{12} + \frac{1}{10}}} = 2.84 \sim t_{(12+10-2)}$$

5 - Teste de Hipótese

Como 2.84 está na região crítica rejeitamos a hipótese de que as duas misturas produzem concretos com a mesma carga de ruptura, indicando que há evidências de que a carga de ruptura da nova mistura 2 é menor do que a mistura original.

6 - Extra: Simulando as duas distribuições

Podemos observar as duas distribuições da média para a mistura 1 e para a mistura 2. Observa-se que elas estão distantes uma da outra indicando visualmente que elas vem de populações distintas.

```
x<-seq(14.3,15.8,0.1)
curve(dnorm(x,15.316,0.1140),xlim=c(14.3,15.8),xlab=expression(bar(x)),type="l",
      col="steelblue4",lwd=2, ylab=expression(paste("f(", bar(x),
      ")")),xaxt="n",cex.axis=0.65, cex.lab=0.8 )
axis(1,at=c( 14.5, 14.83, 15, 15.31,15.5),labels =
       c( 14.5, 14.83, 15, 15.31,15.5),cex.axis=0.7, cex.lab=0.8)
abline(v=15.316, col="steelblue4", lty=2, lwd=2)
text(14.83, 1.5, expression(paste("Mistura 1")))
par(new=TRUE)
curve(dnorm(x,14.83,0.13),xlim=c(14.3,15.8),xlab=expression(bar(x)),type="l",
      col="wheat4",lwd=2, ylab=expression(paste("f(", bar(x),
      ")")),xaxt="n",yaxt="n",cex.axis=0.65, cex.lab=0.8 )
```

```r
abline(v=14.83, col="wheat4", lty=2, lwd=2)
text(15.31, 1.5, expression(paste("Mistura 2")))
```

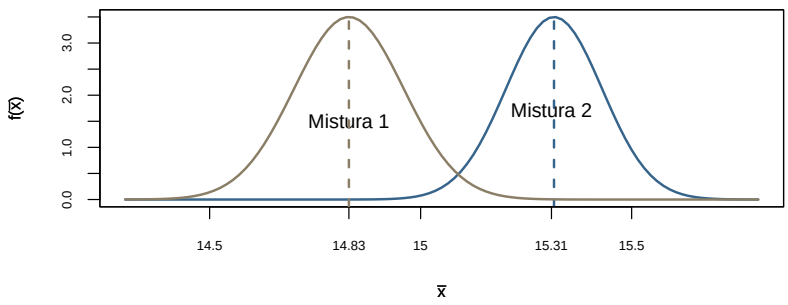

Figure 57: Simulando as duas distribuições do monitoramento, supondo normalidade.

20.3 Testes Paramétricos sobre Probabilidades

20.3.1 Teste para proporção

Aqui estamos interessados em eventos que podem ocorrer (1) e que não podem ocorrer (0), tratados em geral por uma distribuição Binomial. Aqui podemos citar exemplos de pesquisas eleitorais, pessoas favoráveis a uma política, empresas que entraram em recuperação judicial, indiívuos que possuem dívida em atraso etc. Vamos trabalhar aqui com a estratégia de aproximação da binomial pela normal.

1- Definindo a Hipótese

Podemos definir de forma Bicaudal ou Unicaudal

$$H_0 : p = p_0$$
$$H_1 : p \neq p_0$$

ou

$$H_0 : p = p_0$$
$$H_1 : p > p_0 \quad ou \quad H_1 : p < p_0$$

2 - Definindo o Estimador

O estimador para a proporção seria $\hat{p} = \frac{\sum_i X_i}{n}$. Para encontrar o teste estatístico utilizaremos a ideia de aproximação da binomial pela normal.
Sabemos pelo que vimos anteriormente que ao realizar um processo de amostragem aleatório, temos n medições de X (X_i) e cada uma com a mesma distribuição de X - binomial. Observamos x_i. Dessa forma, considerando o TLC e a LGN tem-se:

$\mu = np$ e que $\sigma^2 = np(1-p)$. Para um n suficientemente grande,$X \sim b(n,p)$ pode ser aproximado por $N(np, np(1-p))$.

Como, $\hat{p} = \frac{\sum_i X_i}{n}$, a distribuição da proporção amostral será $\hat{p} \sim N(p, p(1-p)/n)$

Portanto Sob H_0 o nosso Teste Estatístico T, será:

$$T = \frac{\hat{p} - p_0}{\sqrt{p_0(1-p_0)}}\sqrt{n} \overset{H_0}{\sim} N(0,1)$$

3 - Nivel de Significância e Região Crítica

Novamente em economia utilizamos 10%, 5% e 1%. Com base na sua escolha podemos estabelecer as regiões críticas para o teste. Para:

$$H_0 : p = p_0$$

$$H_1 : p \neq p_0$$

$$RC = \{t \in \mathbb{R} | t \leq -z_{c,\alpha/2} \quad \cup \quad t \geq z_{c,\alpha/2}\}$$

$$H_0 : p = p_0$$

$$H_1 : p > p_0 \quad ou \quad H_1 : p < p_0$$

$$RC_1 = \{t \in \mathbb{R} | t \geq z_{c,\alpha}\}$$

ou

$$RC_2 = \{t \in \mathbb{R} | t \leq -z_{c,\alpha}\}$$

4 - Cálculo do Teste Estatístico

Calcular o valor do teste estatístico com base na amostra retirada da população sob estudo. Agora teremos uma realização da proporção amostral das diversas possibilidades fornecidas pela distribuição de $\hat{p}$. Tem-se:

$$\hat{p} = \frac{\sum_i x_i}{n}$$

Logo o valor do nosso teste estatístico será:

$$t = \frac{\hat{p} - p_0}{\sqrt{p_0(1-p_0)}/\sqrt{n}}$$

Comparamos o valor obtido, t com a nossa região crítica.

5 - Teste de hipótese

Assim se a nossa estimativa t pertencer a região crítica rejeitamos H_0. Caso não esteja na RC não rejeitamos H_0.

Vejamos agora um exemplo extraído de Bussab e Moretim:

Exemplo

Temos uma estação de TV que afirma que 60% das Tv's estavam sintonizadas no seu programa as 20h. Uma emissora concorrente contesta essa afirmação dizendo que na verdade esse percentual é bem menor. Ela contrata uma empresa para verificar quem está com a razão, pois isso tem impactos diretos sobre a quantidade de propaganda que conseguem negociar. Essa empresa contratou você para realizar o teste. Já antecipando fez um processo de amostragem com 200 famílias e ao nível de significância de 5% quem teria razão? (teste unilateral)

Resolvendo:

1- Definindo a Hipótese

Definindo de forma Unicaudal

$H_0 : p = 0,60$

$H_1 : p < 0,60$

2 - Definindo o Estimador

Sob H_0 temos o seguinte Teste Estatístico.

$$T = \frac{\hat{p} - p_0}{\sqrt{p_0(1-p_0)}/\sqrt{n}} = \frac{\hat{p} - 0.6}{\sqrt{0.6(0.4)}}\sqrt{200} \sim N(0;1)$$

3 - Nivel de Significância e Região Crítica

Supondo H_0 verdadeira, $\alpha = 0,05$ e utilizando a tabela da Normal Padrão:

$$RC = \{t \in \mathbb{R} | t \leq -1.645\}$$

4 - Cálculo do Teste Estatístico A mostra de 200 elementos mostrou que 104 lares estavam ligado no programa, ou seja, 52%. Dessa forma podemos calcular nosso Teste Estatístico:

$$t = \frac{0.52 - 0.6}{\sqrt{0.6(0.4)}}\sqrt{200} = -2.309$$

o qual pertence a região crítica.

Uma outra maneira de proceder seria utilizar a distribuição de $\hat{p} \sim N(0.6; 0.24/200)$ sob H_0 para encontrarmos o valor crítico e a região crítica na distribuição de $\hat{p}$. Procedemos da seguinte maneira:

$$\frac{p_c - 0,6}{\sqrt{\frac{0,24}{200}}} = \frac{p_c - 0,6}{0,03464} = -1,65 \Rightarrow p_c - 0,6 = 0,057157 \Rightarrow p_c = 0,5428$$
$$RC = \{\hat{p} \subset R | \hat{p} \leq 0,5428\}\}$$

Como $\hat{p} = 0.52$ esse pertence a região crítica. Os resultados são análogos.

5 - Teste de hipótese Assim, como -2.309 (ou 0.52) está na região crítica rejeitamos H_0. Há evidências de que a emissora não teve 60% da audiência e sim menos.